

ETAT DE L'ART DES ARCHITECTURES CLOUD-NATIVES : MICROSERVICES ET API MANAGEMENT

Nancy NJEUNDJI

(Document en cours de rédaction, Version non définitive, toutes remarques ou critiques est fortement appréciée, merci 😊 : nancy.njeundji@gmail.com)

REMERCIEMENTS

Je remercie tout spécialement ma famille pour m'avoir soutenue moralement et financièrement dans les choix et prises de décisions qui m'ont permis de délivrer ce travail.

Je remercie tous les architectes que j'ai côtoyé tout au long de ma carrière pour les précieux conseils, revues et observations qu'ils m'ont prodigués et pour avoir pris la peine de répondre à toutes mes questions

Sujet

Dans un contexte où les entreprises ouvrent leurs Systèmes d'Information vers l'extérieur avec des applications orientées Web exposées à leurs clients et partenaires, où des styles architecturaux comme REST s'imposent de plus en plus, où la capacité de monter en charge et de résilience sont de plus en plus importantes, développer une application implique aujourd'hui de savoir concevoir une API qui expose des services en interne et en externe.

L'intégration inter applications ne passe plus forcément par une plateforme d'intégration centrale lourde et complexe à gérer mais peut s'appuyer sur des solutions plus légères d'interconnexion entre des microservices.

Cette étude portera sur les approches actuelles pour concevoir une application sous forme de services et la connecter avec d'autres applications, les bénéfices à en tirer et les contraintes à prendre en compte.

Glossaire

A

ACID	Atomicité Cohérence Isolation et Durabilité : groupe de propriété s'appliquant à une transaction de base de données.
API	Application Programming Interface : Interface de programmation applicative
API	Management Gestion des API
APM	Applications Performance Monitoring : Surveillance de la performance des applications
Autoscaling	Scalabilité automatique : capacité d'un produit à s'adapter à un changement d'ordre de grandeur de la demande de façon automatique

B

B2B	Business To Business : vente de professionnel à professionnel
B2B2C	Business To Business To Customers : vente de professionnel à professionnel et particuliers
B2C	Business To Customers : vente de professionnel à particuliers
Back-End	Partie applicative qui gère les fonctionnalités et les accès aux données
BASE	Basically Available Soft state Eventually consistent : groupe de propriété s'appliquant à une transaction de base de données.
BDD	Base de données
Build	Construire/compiler/empaqueter les fichiers d'un projet

C

Caching	Mise en cache : enregistrement en mémoire de certaines données pour améliorer la rapidité de consultation des données.
Commit	Enregistrement effectif d'une transaction dans une base de données.
Cookie	Témoin de connexion : suite d'informations envoyée par un serveur HTTP chaque fois que ce dernier est interrogé et sous certaines conditions
Cross-devices	Expérience de transfert de données en simultanées sur divers appareils (mobile, tablette, ordinateurs, objets connectés, etc.) via internet
CRUD	Opérations « Create Read Update Delete » sur une base de données
CI/CD	Continuous Intégration/Continuous Delivery : Intégration continue/ Livraison continue

D

DDD	Domain-Driven Design : Conception orientée design
Dos	Deny of Services – type d'attaque de piraterie informatique

E

Endpoint	Point de terminaison ou point d'accès à un service
ESB	Enterprise Service Bus : Bus d'échange de données (progiciel)

F

Framework	Ensemble de briques logicielles factorisant du code technique ou des modèles de conception
Front-End	Partie applicative qui gère les interactions Homme machine
FTP	File Transfert Protocole: Protocole de transfert de fichier

H, I, J, L

HTTP/HTTPS	Protocole de transfert hypertexte/ Protocole de transfert hypertexte sécurisé
IHM	Interface Homme-Machine - les pages d'applications
JSON	JavaScript Object Notation: format de données textuelles dérivé de la notation des objets du langage JavaScript
LDAP	Lightweight Directory Access Protocol: protocole permettant l'interrogation et la modification des services d'annuaire
Load balancing	Technique de distribution des charges sur différents appareils d'un même réseau

M,O

Middleware	intergiciel – logiciel tiers qui crée un réseau d'échange d'informations entre plusieurs applications informatiques
Monitoring	surveillance des mesures d'une activité
MSA	Microservices Architecture :architecture de microservices
Multicanal	Utilisation simultanée de plusieurs moyens de communication
OAuth1/Oauth2	Protocole standardisés de sécurité et d'autorisation d'application tierce
Package	Dossier compressé contenant les archives d'une application
Payload	Contenu structuré du corps d'une requête
Pool	(de connexion). lot de connexions à la base de données enregistrées en cache afin d'être réutilisées pour gagner en performance.
Proxy	Pare-feu : logiciel intermédiaire de surveillance des échanges entre deux hôtes

R

Reporting	Ensemble de données de rapports et de statistiques
REST	REpresentational State Transfert: style d'architecture pour les systèmes hypermédia distribués

S

SLA	Service-level agreement : entente de niveau de service - document qui définit la qualité de service pour prestation de service d'un fournisseur à un client
SOA	Services-Oriented architecture : architecture orientée services
SOAP	Simple Objet Access Protocol protocole de messagerie écrit en XML et permettant à des systèmes d'exploitation distincts de communiquer via HTTP
SSL	(un type de connexion)
Dispatching	
Queuing	

T

Throttling	
------------	--

Time-to-market (delivery) Livraison juste à temps sur le marché commercial

TLS Transport Layer Security – norme de sécurisation par chiffrement du transport de l'information au sein d'un réseau informatique

U, V, W

URL Uniform Resource Locator – nommage universel de la location d'une ressource

UUID Universal Unique Identifier : identifiant universel unique

VM Virtual Machine: Machine virtuelle

Workflow Flux de travail – modélisation du processus de circulation des flux d'informations

Webhook

Table des matières

Sujet.....	3
Glossaire	4
Introduction générale	9
1. Contexte	10
2. Architecture de microservices.....	12
2.1. Définitions microservice et API	12
2.2. Conception d'une architecture de microservices.....	17
2.2.1. Le Domain-Driven-Design.....	17
2.2.2. Les contextes bornés.....	19
2.2.3. La carte des contextes.....	20
2.3. Communication entre les microservices	22
2.3.1. Les API REST (REpresentationnal State Transfer).....	22
2.3.2. Le JSON, format d'échange de données préférentiel	28
2.3.3. L'API Gateway.....	33
2.3.4. Le synchronisme vs l'asynchronisme.....	37
2.3.5. Le service Discovery	40
3. API management	44
3.1. Les API publiques et privées.....	45
3.2. Les services principaux	49
3.3. La documentation.....	52
3.4. La gestion du trafic	55
3.5. Les métriques	56
3.6. Le portail de développeur	58
3.7. Quelques solutions sur le marché	60
4. Etude du cas CoMove	64
5. La sécurité	74
5.1. L'authentification et l'autorisation.....	74
5.2. La sécurité entre les services.....	76
5.3. La sécurité entre les API	77
5.4. Quelques menaces à considérer	78
6. Déploiement.....	79
6.1. L'intégration continue	79
6.2. La livraison continue.....	81
6.3. Les stratégies de déploiement	83

7. Le monitoring	87
8. Transformer un monolithe en microservices	90
Conclusion générale (EN COURS)	94
BIBLIOGRAPHIE.....	101
LISTE DES FIGURES.....	102

Introduction générale

En raison du succès des géants du web tel que Google, Amazon, Facebook et notamment Uber lors de la conception de nouvelles architectures informatiques permettant de répondre à plusieurs problématiques liées à la gestion de volumes colossaux d'utilisateurs et de données, l'année 2015 a marqué ce que l'on pourrait appeler le pic d'une nouvelle ère digitale qui a contraint les entreprises traditionnelles à se remettre véritablement en questions quant à leur propre architectures et à enclencher divers chantiers de transformations digitales.

En effet, comment des entreprises telles que celles évoquées plus haut ont pu gérer des défis d'une telle ampleur alors que les moyennes et grandes entreprises ont du mal à le faire sur une base d'utilisateurs et de données 1000 fois moindre ?

Bien avant de se pencher sur les solutions architecturales des entreprises qui semblent ne pas être adaptées remarquons d'abord ceci : L'essor des applications et technologies mobiles qui a permis aux utilisateurs d'être ultra connectés, en tout lieu et à tout moment de la journée, a eu pour conséquence majeure la nécessité de mettre en place des systèmes très disponibles, distribués et sécurisés et cela a complétement bousculé les entreprises sur de nombreux plans :

sur le plan logiciel : La naissance de nombreux Frameworks client offrant de meilleures expériences utilisateurs dont il faille absolument s'approprier pour fidéliser la clientèle et les montées en versions drastiques des Frameworks coté serveur pour redoubler de performance dans le traitement de données, de gestion de la mémoire, de la montée en charge, de sécurisation des accès aux ressources. La nécessité d'adopter les modèles de données NoSQL pour dépasser les limites des systèmes de gestion de base de données relationnels afin de pouvoir "passer à grande échelle".

sur le plan de l'infrastructure : L'importance accrue de mettre en place des chaînes d'intégration et livraison continues de plus en plus automatisées qui brisent les frontières entre les développeurs de solutions et les opérationnels chargés des mises en productions de ces dites solutions, créant ainsi le concept de DevOps. De plus à une certaine échelle, l'infrastructure est devenue une commodité, l'ouverture du marché du *Cloud Computing* offrant des formules de **Everything As A Service* est devenue une opportunité d'externaliser l'informatique et d'en confier la gestion à des spécialistes avec une promesse de fast-delivery et d'infrastructure élastique à la demande.

sur le plan organisationnel et économique : La nécessité de mettre en place des techniques d'agilité pour travailler rapidement et efficacement dans un milieu de plus en plus concurrentiel, forçant à changer le modèle de gestion des projets et par conséquent celui de la gouvernance. Le business model va au-delà du service métier principal de l'entreprise, le savoir-faire et l'accès aux ressources peut être proposée dans des échantillons B2B et B2C monétisés.

En Bonus : Cette nouvelle ère du digital est à cheval sur une certaine ère de la piraterie informatique, demandant un niveau de vigilance un peu plus accru en ce qui concerne la sécurisation des données et des systèmes.

La rencontre de cet ensemble de contraintes aura permis aux géants de concevoir des solutions, concepts et pratiques qui ont changé l'horizon du digital tel que l'on le connaît à l'heure actuelle. Mais au centre de cet écosystème, réside principalement les micro-services et les interfaces de

programmations (API) dont les caractéristiques et spécificités ont orchestré la mise en place d'un panel élevé de pratiques et de solutions.

Sachant qu'une grande partie des entreprises implémentent de la SOA et que quelques-unes ont dans leur portefeuille de projets réalisés, quelques monolithes, les DSI aimeraient prendre des décisions et mesures afin d'éviter d'éventuelles disruption qui pourraient être fatale à leur entreprise. Plusieurs questions se posent :

- Quelles sont les spécificités de ce type de services qui permettent qu'on puisse mettre en place tout un écosystème capable de gérer des problématiques de distribution, de scalabilité, de sécurité, d'agilité et tout en effectuant des livraisons fréquentes permettant de rester compétitifs ?
- Quels sont les impacts, les possibilités, les avantages et les inconvénients de l'implémentation d'une architecture de microservices au sein d'une entreprise ?
- Compte tenu du métier et des besoins d'une entreprise, comment jauger la nécessité de mettre en place cette architecture ?
- Et finalement, si l'entreprise prend la décision de mettre en place cette architecture, comment effectuer la transformation ?

Autant de questions pour lesquelles un ensemble de réponses seront apportées tout au long de ce document. Tout d'abord avec une approche explorative allant de la phase de conception à la phase d'intégration en passant par plusieurs notions clés et bonnes pratiques spécifiquement liées à cette architecture. Ensuite l'accent sera mis sur l'API management afin d'analyser la mise en place de la gouvernance des micro-services. Enfin un état des lieux des bénéfices et contraintes devrait permettre de prendre une décision quant à la nécessité d'amorcer une éventuelle migration d'architecture.

Démontrer par l'exemple, une mise en place de cette architecture, une étude de cas de l'application mobile **CoMove**, qui fournit un service de covoiturage dans l'agglomération de Toulouse, sera présentée dans le document.

1. Contexte

Comme évoqué succinctement en introduction de ce document, un ensemble d'industries leaders du logiciel, plus communément connus sur l'appellation de géants du web, ont entrepris des transformations architecturales profondes de leurs structures sur tous les plans (entreprise, logiciel et infrastructure). Ces transformations ont eu un impact qui a littéralement changé l'aspect de l'industrie du web tel qu'on le connaît aujourd'hui et de ce fait marqué une nouvelle ère digitale portée par le cloud.

A la question qui consiste à se demander pourquoi ces entreprises ont t'elles opérées de tels changements pour la mise en place d'applications dites cloud-native, on pourrait observer un ensemble de motivations qu'elles ont toutes en commun :

- **La rapidité** : Dans un marché du service, relativement concurrentiel, la capacité de mettre son produit à disposition de l'utilisateur final le plus vite possible est une valeur clé du succès de vente et de fidélisation. En essayant de répondre à la question « comment devenir ready-

to-market », elles ont été capable d'innover, d'expérimenter et de proposer des solutions logicielles et des techniques de gestion de projet qui ne servaient qu'à cet objectif. L'agilité et l'automatisation des chaînes de production, ont permis d'augmenter la fréquence des déploiements à une centaine de fois par jour, réduisant par cette occasion les marges de d'erreurs, favorisant la prise de risque et la réutilisabilité au travers des APIs.

- **La sécurité** : Les architectures basées sur le cloud on permet de démontrer qu'il est tout à fait possible d'allier vitesse et sécurité en mettant en place un ensemble de procédures et technique permettant entre autres :
 - D'avoir de la visibilité à l'aide de métriques permettant de corriger des erreurs, combler des failles et contre-attaquer ([cf. chapitre 7](#))
 - De faire de l'isolation afin de contrôler et limiter les risques associés aux échecs en cascade notamment à l'aide d'une conception du système en microservices ([cf. chapitre 2](#))
 - D'être tolérant aux pannes qui est également un avantage d'avoir un système décomposé en composants indépendamment déployables (microservices).
 - De faire de la récupération automatique après avoir pu identifier les échecs et de les avoir traités.
- **La mise à l'échelle horizontale** : plutôt que d'avoir des applications de plus en plus grosses entrainant ainsi l'achat de plus gros serveurs afin de supporter de plus grands calculs et de montées en charge, ces entreprises ont trouvé plus judicieux de réduire la taille des applications et de répartir les instances de ces dernières sur un grand nombre de serveurs peu couteux, facile à acquérir et rapide à déployer. De plus, cette conception a permis d'améliorer les techniques de virtualisation et d'optimiser les ressources des serveurs avec la conteneurisation ([cf. point 6.3.](#)). L'infrastructure externalisée sur le cloud est devenue un service hautement commercialisé proposant aux entreprises plus petites de déployer leur logiciel à moindre coût.
- **Des applications centrées sur le mobile** : Les entreprises ont vite compris qu'avec un taux de pénétration du mobile très élevé à l'échelle planétaire et avec la performance de plus en plus élevée dans la conception de ces derniers, permettant aux utilisateurs d'accéder aux ressources à n'importe quel moment et cela de n'importe où, l'ère des applications de bureau était révolue. Une approche mobile-first a eu un impact très structurant sur la façon d'aborder les architectures, du fait de la diversité des plateformes mobiles et de la nécessité d'avoir un élément telle qu'une API Gateway ([voir point 2.3.3](#)) dans son modèle de conception qui va faire le routage des demandes et l'agrégation des requêtes, afin de fournir au plus vite les informations demandées par l'utilisateur pour le fidéliser.
- **L'innovation** : L'idée derrière une architecture de microservices est la capacité à ajouter de fonctionnalités sans impacter l'existant. La modularité de cette architecture permet de s'engager sur de nouveaux produits, langages, frameworks et marchés sans risquer l'effondrement du système. La capacité à innover est l'un des éléments importants ayant permis à ces entreprises à se placer en tête de l'industrie.
- **L'API Economy** : l'idée avant la mise en place de ce nouveau modèle économique basée sur la monétisation des APIs, était de pouvoir utiliser des fonctionnalités existantes chez des

tiers, dans un souci de réutilisabilité et de rapidité. L'émergence des réseaux sociaux a fortement contribué à la montée de ce modèle économique très B2B, ce qui a permis de structurer et normaliser les APIs pour mieux gérer l'accès aux ressources. Les notions d'API Restful, publiques et privées et d'API management ont été une nécessité dans la réussite de stratégie économique

Afin d'obtenir les résultats présentés ci-dessus, les géants du web ont dû se délester d'applications traditionnelles monolithique, constituées d'une grande base de code, difficile à appréhender, à maintenir et à faire évoluer. De plus, les déploiements fréquents rendaient les applications indisponibles quand survenaient le moindre échec, cela devenait une manœuvre risquée et coûteuse. En termes de scalabilité, chacune des instances ayant accès aux données, les stratégies de mise en cache de d'une partie des données augmentait considérablement la consommation de mémoire et de trafic d'E/S. Sans compter que le load balancing n'était pas assez optimal car ne permettant pas de différencier les composants qui ayant des besoins en ressources nécessitant une utilisation intensive de la mémoire de celles nécessitant une utilisation intensive du processeur...

D'après ces observations, on pourrait s'intéresser aux architectures cloud-native dans le but :

- D'être plus rapide dans la mise en production des solutions
- Avoir des applications plus sécurisées avec l'analyse des flux de données
- De profiter des avantages d'une scalabilité horizontale
- D'avoir une approche conceptuelle centrée sur le mobile
- D'avoir la capacité d'innover grâce à l'aspect modulaire de l'architecture.
- D'avoir une stratégie économique dans la commercialisation des APIs

La mise en place d'une architecture basée sur le cloud nécessite de comprendre les fondamentaux de cette architecture, en commençant par la conception et l'implémentation des microservices et des APIs, la communication entre ces services et l'exposition des API qui les regroupent, les différentes stratégies de déploiement actuelles et la gouvernance au travers de la notion d'API management. Tous ces concepts devraient être autant d'éléments à prendre en compte pour aider à la prise de décision d'une éventuelle migration vers ces systèmes.

2. Architecture de microservices

2.1. Définitions microservice et API

Microservices et architecture

Dans son blog, Martin Fowler, auteur conférencier et porte-parole du développement logiciel, explique que le terme « Architecture de microservices » apparu ces dernières années pour décrire une manière particulière de concevoir les applications logicielles est une approche permettant de développer une application sous forme d'une suite de petits services.

Chaque service s'exécutant dans son propre processus, serait capable de communiquer à l'aide d'un protocole léger, le plus souvent à base de ressources HTTP. Le service est construit autour d'une capacité métier bien définie et peut être déployé indépendamment par des machines de déploiement entièrement automatisées. Grâce à une gestion centralisée d'un microservice, ce dernier peut respecter le principe de responsabilité unique, en étant écrit dans un langage de programmation qui lui est propre et utiliser différentes technologies de stockage. Ceci permet de donner libre choix aux outils et langages les plus pertinents à même de répondre à l'objectif auquel doit tenir un microservice.

Bien que faisant parti d'un ensemble, il est important de comprendre qu'un microservice est avant tout un **service métier** regroupant des *services techniques* (REST, SOAP...) qui ensemble fournissent une fonctionnalité précise, cohérente et logique qui a un **sens métier**.


Selon Martin Fowler, une architecture de microservices serait un ensemble de **composants** indépendamment remplaçables et maintenables qui communiquent via des mécanismes tels que les requêtes de services web ou les appels de procédures à distance. L'utilisation du terme "composant" pour désigner le microservice permet de souligner dans un premier temps son unicité et par la même occasion, le fait qu'il fasse partie d'un système global fonctionnel et cohérent.

Cette architecture à l'échelle du service a été créée pour pallier les difficultés liées aux systèmes monolithiques rencontrés sur les grands projets :


A monolithic application puts all its functionality into a single process...




A microservices architecture puts each element of functionality into a separate service...



... and scales by replicating the monolith on multiple servers



... and scales by distributing these services across servers, replicating as needed.



Source : www.martinfowler.com

- *Une application monolithique met toute sa fonctionnalité dans un unique processus...et évolue en le répliquant le monolithe sur plusieurs serveurs*
- *Une architecture de microservices met chaque fonctionnalité dans un service séparé ...et évolue en répartissant ces services sur plusieurs serveurs en les répliquant au besoin*

En somme, un microservice peut être défini comme un service métier autonome, ayant son propre code, son propre cycle de vie, gérant ses propres données sans les partager directement avec les autres services et basé sur une technologie permettant de répondre à l'objectif métier de ce dernier. Ainsi une architecture de microservices devrait permettre d'améliorer la performance d'un système par :

- L'évolutivité et la fiabilité
- La scalabilité horizontale
- L'innovation technologique
- L'innovation métier
- Une distribution plus large du système
- Le time-to-market delivery (la livraison juste à temps)

APIs et gestion

“Dans l’industrie contemporaine du logiciel, une interface de programmation applicative (souvent désignée par le terme API pour application programming interface) est un ensemble normalisé de classes, de méthodes ou de fonctions qui sert de façade par laquelle un logiciel offre des services à d’autres logiciels. Elle est offerte par une bibliothèque logicielle ou un service web, le plus souvent accompagnée d’une description qui spécifie comment des programmes consommateurs peuvent se servir des fonctionnalités du programme fournisseur.”

Source : Wikipédia

Autrement dit, une API est ce qui permet à un programme informatique d'utiliser les fonctionnalités d'un autre sans avoir à implémenter ni même connaître le processus de réalisation et la complexité de ces derniers. Les bonnes pratiques suggèrent qu'une API spécifie, au travers d'une page web statique ou tout autre outil visuel, une description pour chacune des fonctionnalités. Cette mise en place de la documentation des services suggère que ces derniers sont viables et propice à être utilisé pour accéder aux ressources de l'entreprise, on parle donc *“d'exposition de services”*.

En règle générale, dans l'industrie informatique, les utilisateurs finaux des API sont les développeurs, c'est cette raison qui définit l'état d'esprit et l'ensemble des normes qui régissent la création des services à exposer. Cela suggère alors que les fonctionnalités soient l'implémentation de services plus ou moins simples ou tâches basiques offrant ainsi un large champ de possibilité pour les processus

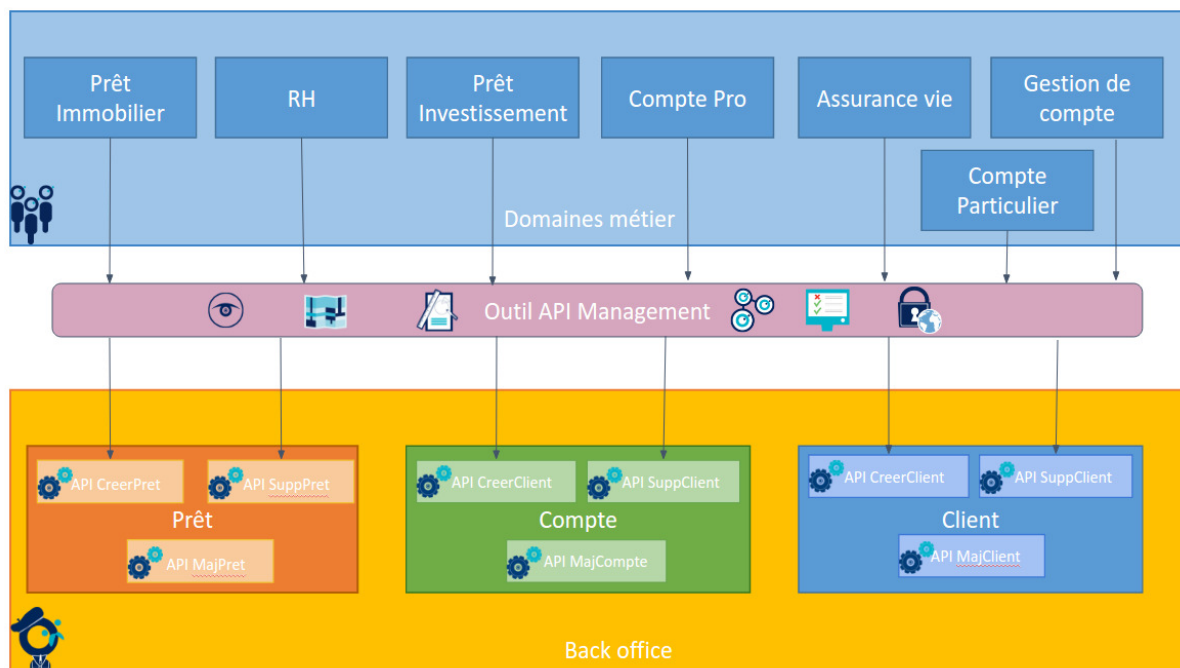
que l'on souhaite réaliser et incorporer dans les applications. Les API exposent des services à l'extérieur de leur système souvent dans une stratégie B2B, mais les développeurs peuvent aussi créer et utiliser des API pour leur propre besoin.

La gestion des API ou API management, est un processus qui permet à une entreprise de publier des APIs et de superviser leur cycle de vie au sein d'un environnement sécurisé et évolutif. La mise en place d'un tel processus devrait permettre entre autres :

- L'implémentation de la sécurité
- L'exposition et la documentation des services, définition de l'interface et des règles de nomenclatures appliquées.
- L'enrôlement vers des consoles interactives via un portail pour les développeurs et un autre pour les administrateurs
- La gestion des authentifications et habilitations (en création directe ou en s'appuyant sur une brique existante telle qu'un LDAP par exemple)
- La supervision des services exposés (monitoring) au travers de métriques techniques telles que : les nombres d'appels et de réponses KO, les temps de réponses, les taux d'utilisations de la mémoire ou du cache.
- La gestion du trafic (quotas, caching, arrêt rapide, limitations/throttling)
- L'application de la stratégie de gouvernance des services fondée sur la granularité et la politique de gestion des versions de ces derniers

Il est à noter que la mise en place d'un tel outil nécessite au préalable d'avoir étudié le système auquel on souhaite l'appliquer, d'avoir posé une stratégie claire de l'architecture et défini les services répondant aux besoins métiers.

Il existe sur le marché, plusieurs plateformes ayant des fonctionnalités répondant à différents besoins (type d'expositions, monitoring ; cache, outil de transformation...) et cette opération en mode Bottom-top (les APIs d'abord et l'outil d'API management ensuite) facilite grandement le choix des outils, surtout si l'on souhaite implémenter une solution externe.



Source : blog.octo.com

Mise en situation d'un outil d'Api management

Sachant qu'un microservice est un composant métier d'une application et qu'il est défini par un ou plusieurs services techniques appelés **opérations**, une API est une interface permettant d'accéder à un ou plusieurs microservices et par conséquent à leur opération. De ce fait, un Microservice peut ne pas être accessible via une API si cette dernière ne l'expose pas.

La source ci-dessus (blog.octo.com) Montre qu'il existe une API de gestion de prêt permettant d'exposer les opérations *créerPret*, *SuppPret* et *MajPret* du microservice Prêt de telle sorte que des domaines métiers qui existent au sein de l'organisation tels que Prêt-Immobilier ou Prêt-investissement puissent accéder à des ressources et effectuer des opérations.

Les APIs devenant ainsi des points d'accès aux ressources d'une organisation, l'importance d'avoir un outil d'API management au sein de cette organisation permet d'instaurer une stratégie de gouvernance, d'autant plus si le nombre de microservices est élevé. L'outil devrait faciliter des réponses et des prises de décisions concernant des questions telles que celles-ci :

- Quelle API exposera quels microservices
 - Dans quel objectif ?
 - Qui y aura accès ?
 - Quelles sont les informations que révèlent le trafic au sein de cette API
 - Quel est le niveau de sécurité de l'API par rapport à la criticité des ressources ?
- Etc.

2.2. Conception d'une architecture de microservices

2.2.1. Le Domain-Driven-Design

Initialement introduit et rendu populaire par Eric Evans en 2003 dans son livre « *Domain-Driven Design : Tackling Complexity in the Heart of Software* », la conception pilotée par domaine, DDD, est une approche de conception préconisée pour le développement de systèmes complexes axés sur la cartographie d'activités, de tâches, d'événements et de données d'un domaine métier.

Le Domain-Driven Design met l'accent sur la compréhension du domaine afin de créer un modèle abstrait de celui-ci pouvant ensuite être mis en œuvre dans un ensemble particulier de technologies. Cette méthodologie fournit des indications sur la manière dont le développement de modèle et le développement de technologie peuvent aboutir à un système qui répond aux besoins de ceux qui l'utilisent tout en restant robuste face aux changements dans le dit domaine.

Les processus du Domain-Driven Design impliquent une étroite collaboration entre les experts du domaine (les personnes connaissant les problématiques liés au domaine) et des experts en conception / architecture/ développement (les personnes connaissant les solutions pouvant être apportées pour résoudre les problématiques liées au domaine). La finalité étant de disposer d'un modèle commun avec un langage commun de sorte que les différents interlocuteurs quel que soit leur domaine d'expertise (développeurs, analystes, commerciaux, clients etc.) puissent échanger sur une base de connaissance partagées avec des concepts partagés.

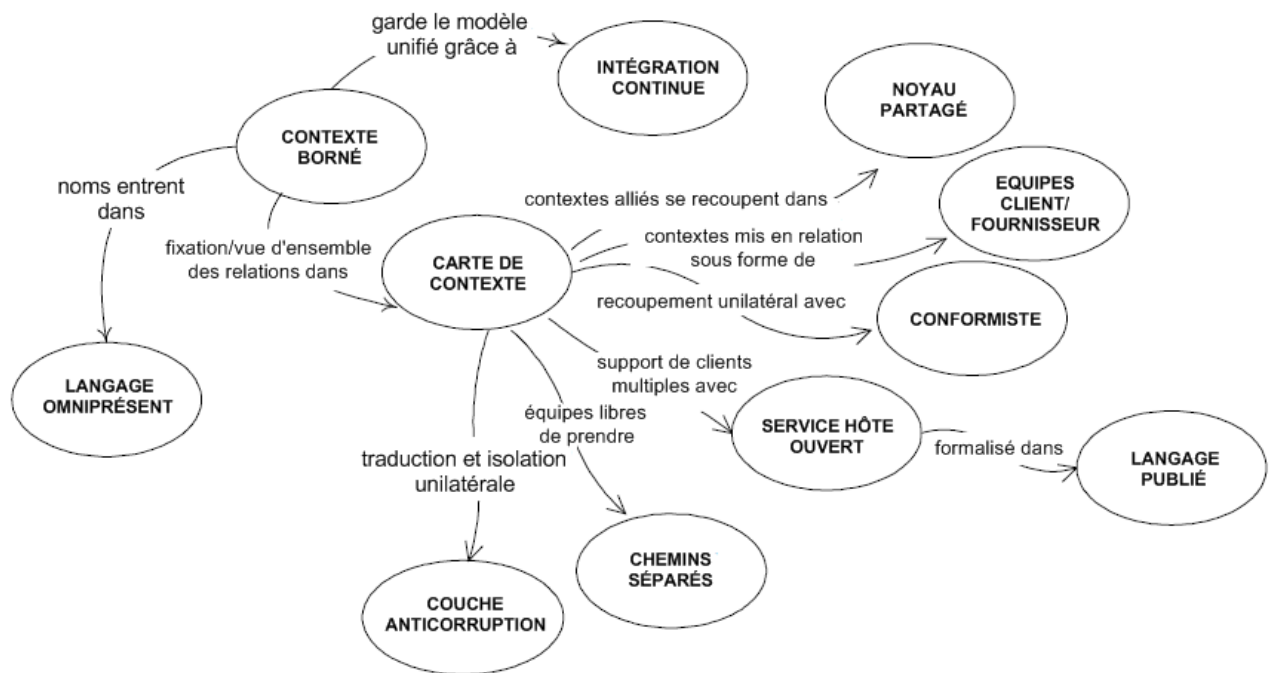
Le Domain Driven Design permet de remédier à toute difficultés profondes liées à la compréhension du domaine d'étude lors de la conception d'application complexe en connectant des éléments connexes du logiciel dans un modèle en constante évolution. C'est plus que d'avoir un modèle objet, l'accent est mis sur la communication partagée et l'amélioration de la collaboration afin que les besoins réels dans le domaine étudié puissent être découverts et qu'une solution appropriée soit créée pour répondre à ces besoins. Ceci de façon agile.

Le DDD se repose sur un ensemble de principes parmi lesquels nous pouvons citer :

- **Le langage omniprésent** : ce principe de DDD met l'accent sur le fait de briser les barrières de la communication entre les experts du domaine et les spécialistes de l'informatique en les faisant travailler ensemble sur le modèle du domaine. Ceci devrait permettre de surmonter la différence de style de communication, d'échanger sur les éléments impliqués dans le modèle, de la manière dont ils sont reliés les uns aux autres et de la pertinence de certains. La création du langage omniprésent devrait permettre aux différents interlocuteurs quel que soit leur domaine d'expertise (développeurs, analystes, commerciaux, clients etc.) échantent sur une base de connaissance partagées avec des concepts partagés
- **La conception dirigée par le modèle** : Dans la continuité du point précédent, ce principe énonce les avantages à ce que tous les acteurs du projet travaillent ensemble sur le modèle de conception. Car il arrive que les analystes détaillent beaucoup certains aspects du modèle et pas suffisamment d'autres. A ajouter qu'à cela les développeurs ont tendance à utiliser le modèle d'analyse comme une référence pour créer un modèle de conception qui s'éloigne de l'analyse avec le temps. L'objectif de rassembler tous les acteurs durant cette phase étant

de combler les idées des uns et des autres tant sur le point de l'analyse que de la conception du modèle. Cette phase devrait permettre d'obtenir un modèle utile suite à l'obtention d'éléments de conception tels que :

- Les blocs de constructions d'une conception orientée modèle
 - L'architecture en couches
 - Les entités
 - Les objets-Valeurs
 - Les services
 - Les modules
 - Les agrégats
 - Les Fabriques
 - Les entrepôts
-
- **Le refactoring profond** : L'auteur traite de ce principe en énonçant que le refactoring est quelque chose d'inévitable lors de la phase de conception d'un logiciel. Il est important de s'arrêter régulièrement pour inspecter le code et de le reconcevoir en vue de l'améliorer sans introduire de bugs. Le refactoring ajoute de la clarté au design et des conditions pour une avancée majeure (modification impactant fortement le modèle), qui est une source de grand progrès pour un projet. Toute avancée majeure implique un vaste refactoring et par conséquent du temps et des ressources (pas toujours disponible) et c'est de là que vient la notion de refactoring profond dans la mesure où il faut se repencher sur le modèle et rendre explicite tous les éléments implicites qui ont permis de conclure à un changement drastique de la conception. À savoir que cela rajoutera de la souplesse et de la modularité au logiciel.
 - **La préservation de l'intégrité du modèle** : Ce principe est particulièrement applicable aux projets où l'on a confié à plusieurs équipes dans des conditions de management, de coordination et de technologies diverses, la tâche de développer une solution logicielle. Chaque équipe développe du code en parallèle en se voyant assigner une partie du modèle. Chacune de ses parties doivent pouvoir communiquer avec les autres sans altérer les données. L'ensemble des techniques suggérées par le DDD à combiner pour maintenir l'intégrité du modèle sont :
 - Les définitions des contextes bornés
 - L'intégration continue
 - La mise en place de la carte des contextes
 - Le noyau partagé
 - La compréhension du client-fournisseur
 - Le conformisme



Source : « *Domain-Driven Design : Tackling Complexity in the Heart of Software* », Eric Evans.
Ce schéma crée par l’auteur, permet de montrer l’ensemble des techniques de DDD et les interrelations entre elles.

Le DDD étant particulièrement vaste, les projets en architecture de microservices ont une nécessité à implémenter le point sur la *préservation de l’intégrité du modèle* car il répond aux différentes problématiques liées à ce type d’architecture et spécifiquement à la difficulté de découper le modèle aux bons endroits afin de limiter les dépendances. Dans le cadre de l’étude ce document, il est deux notions clés sur lesquels les experts de ces architectures s’accordent à dire qu’il ne faudrait pas faire d’impasse, il s’agit des notions de contexte borné et carte de contextes.

2.2.2. Les contextes bornés

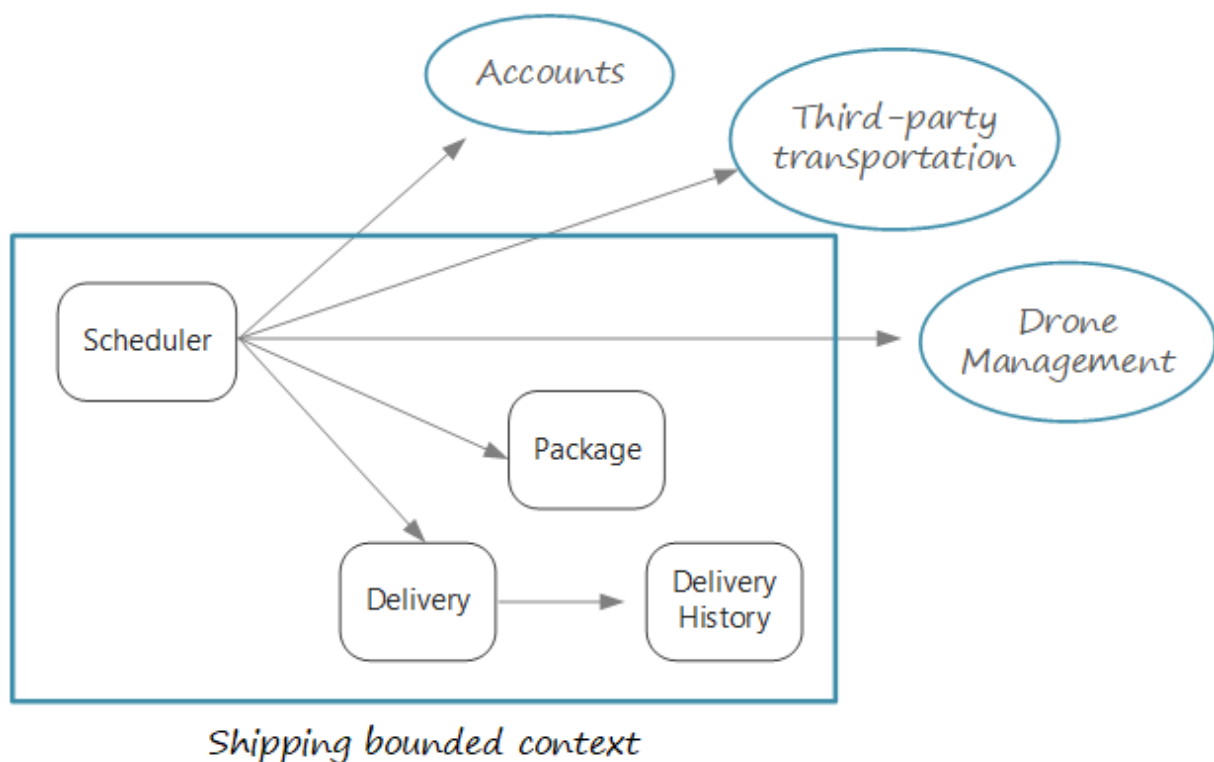
Chaque domaine réfère à un contexte précis, c’est-à-dire à un ensemble de conditions qu’on doit appliquer pour s’assurer que les termes, notions et interrelations utilisées prennent un sens précis.

Ce contexte peut être constitué d’un ou plusieurs modèles, de ce fait peu importe le modèle, il est toujours lié à un contexte précis. Cependant dans les grandes applications d’entreprises, plusieurs modèles entrent en jeu. En combinant les morceaux de codes basés sur les modèles distinct, on obtient une solution buggée, peu fiable, difficile à comprendre et de ce fait difficile à maintenir.

Le travail qui consiste à scinder les modèles en modèles plus petit est d’essayer de regrouper les éléments liés par un concept naturel, la finalité étant d’obtenir un modèle assez petit et suffisamment autonome pour pouvoir être assigné à une seule équipe.

Le contexte borné est le cadre logique à l’intérieur duquel sera amené à évoluer ce type de modèle, Un contexte borné devrait donc permettre :

- De connaître les limites du modèle
- A une équipe de rester autonome à l'intérieur de ce périmètre
- De faciliter la pureté, la cohérence et l'unicité d'un modèle
- Faciliter le refactoring sans répercussion sur les autres modèles
- D'avoir une visibilité très spécifique sur une partie du domaine
- De limiter les dépendances avec les autres modèles en gardant uniquement les points de liaison explicites
- De faciliter la gestion des impacts
- D'englober un ou plusieurs modules permettant de développer des microservices



Source : <https://docs.microsoft.com/en-us/azure/architecture/microservices/model/microservice-boundaries>

Dans cet exemple d'analyse de domaine pour le scénario de livraison de drone sur la plateforme Microsoft Azure, on met l'accent sur le contexte de livraison afin de montrer les limites du modèle et ce qu'il intègre ainsi qu'une communication directe avec d'autres contextes bornés.

2.2.3. La carte des contextes

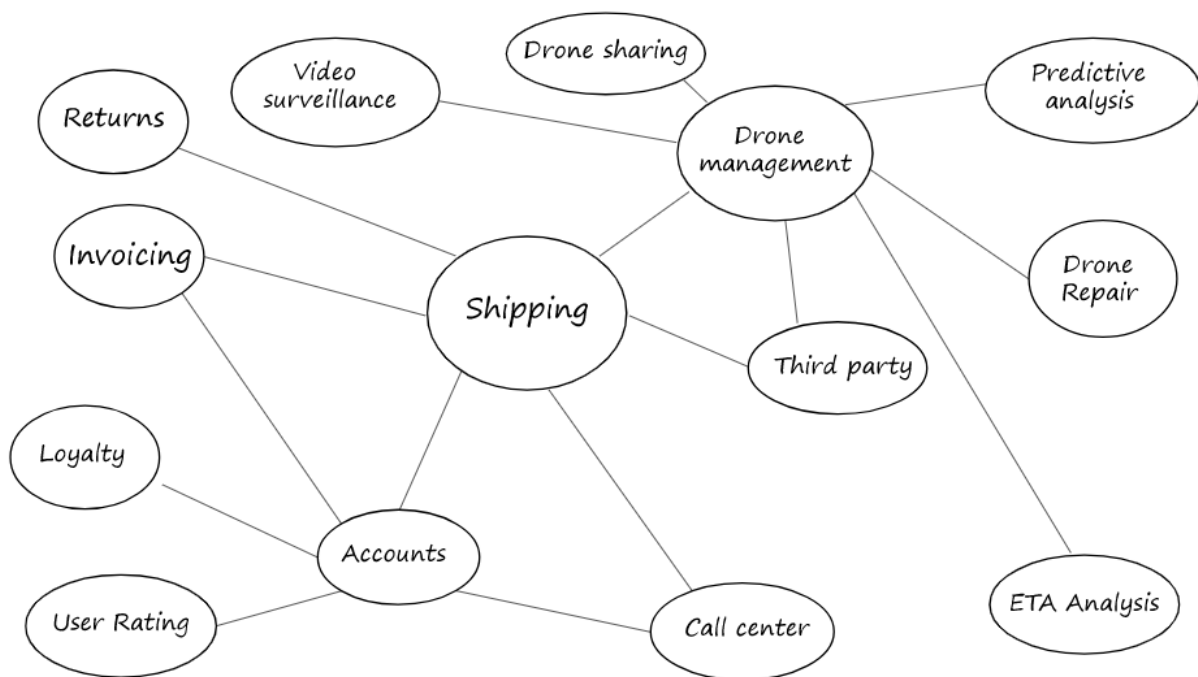
Dans une stratégie qui consiste à avoir de multiples modèles ayant chacun un contexte borné, on a une visibilité très spécifique sur certaines parties du domaine, cela permet de mieux encadrer les

impacts et gérer les dépendances. Les individus d'une même équipe, communiquent plus facilement et travaillent plus efficacement à intégrer un modèle au sein d'un contexte borné.

Une carte de contexte est un diagramme, un schéma ou n'importe quel document écrit avec un niveau de détail variable, qui permet de mettre en évidence les différents contextes bornés, les langages utilisés et les liens entre eux. Car même si chaque équipe travaille sur son modèle il est important de que toutes les équipes aient une vision d'ensemble sur le projet et puisse se situer géographiquement sur l'ensemble de tout le périmètre du projet.

L'importance d'une carte de contexte est de constituer une visibilité globale du domaine et de cartographier les liens entre les contextes bornés et par conséquent les modèles. Cela devrait permettre de mieux penser la stratégie d'organisation du code, des ressources et des équipes de développements afin de prendre des responsabilités sur certains sujets

La carte de contexte est fortement liée à la notion d'intégration du système global. La finalité étant qu'une fois toutes les pièces rassemblées, le système fonctionne correctement. Cela permet aussi de vite constater les systèmes qui se chevauchent ou qui sont susceptible de l'être. Si les liaisons entre les contextes ne sont pas clairement définies et mis en évidence, le risque d'échec au niveau de l'intégration du système est accru.



Source : <https://docs.microsoft.com/en-us/azure/architecture/microservices/model/domain-analysis>

Dans cet exemple d'analyse de domaine pour le scénario de livraison de drone sur la plateforme Microsoft Azure, on représente la carte de tous les contextes permettant la mise en place de l'application de gestion de livraison d'un drone, ainsi que tous les liens entre ces derniers.

En somme, mettre en place la DDD dépend du niveau d'isolation et d'encapsulation que l'on souhaite conserver au niveau du modèle. Aussi il faut tenir compte du coût d'entrée qui va augmenter car il faut absolument être formé à la méthode pour intervenir sur un projet désigné.

2.3. Communication entre les microservices

Après un travail de conception sur le découpage fonctionnel qui permet de distinguer les premiers microservices et API, on doit se pencher sur l'importante question de savoir comment on intègre les microservices au sein d'une architecture et comment ces derniers pourraient communiquer entre eux.

Plus qu'une architecture, la MSA est un ensemble de concepts fonctionnels, techniques et organisationnels. Et en ce qui concerne l'intégration il y'a un ensemble de bonnes pratiques dont il faut tenir compte et qui pourraient fortement influencer les choix technologiques conformément à la solution que l'on souhaitera implémenter :

- **Garder les APIs « technology-agnostic »** : Etant donné que le marché est en constante mutation, les communications entre les services ne doivent pas dépendre d'un stack technologique en particulier mais de normes connues de tous. N'importe quel client, peu importe sa technologie devrait pouvoir accéder à une API et n'importe quel microservice, peu importe sa technologie devrait pouvoir exposer des ressources via une API.
- **Rendre le service simple pour les consommateurs** : Un service doit être le plus simple et exposé le plus rapidement possible pour laisser le choix à l'utilisateur de l'intégrer à son modèle technique. Cette simplicité peut s'avérer utile quand il s'agit de mettre à jour le service ou d'en recréer un autre sur la base de ce dernier.
- **Masquer les détails de l'implémentation** : ceci est une recommandation pour éviter un couplage entre un consommateur et la mise en œuvre externe du service afin de ne pas casser la liaison de communication et /ou d'avoir des mises à jour obligatoires et fréquentes du côté du consommateur.

Partant de ces objectifs, certains processus et technologies ont évolué, émergé, gagné en popularité et sont très souvent associés en premier aux architectures de microservices.

2.3.1. Les API REST (REpresentational State Transfer)

Emergence

C'est en 2000 que **Roy Fielding**, à l'époque directeur de la fondation Apache, a introduit le REST lors de sa thèse de doctorat « **Architectural Styles and the Design of Network-based Software architectures** » à l'université de Californie à Irvine.

Dans le chapitre 5 de cette thèse, qui y est particulièrement consacré, Fielding définit le REST comme un style architectural basé sur un ensemble de contraintes permettant de créer des services web. Lesquelles sont :

- **Une communication Client-serveur** : le client doit être séparé du serveur
- **Une communication sans état** : Une requête doit contenir toutes les informations nécessaires à son exécution et les perd toutes une fois utilisées.

- **La mise en cache** : une réponse du serveur doit contenir des informations permettant au client de mettre en cache ladite réponse.
- **Des interfaces uniformes** : les interfaces doivent permettre d'identifier les ressources disponibles
- **Un système hiérarchisé en couche** : un client doit pouvoir se connecter à un serveur final ou à un intermédiaire sans qu'il ne s'en aperçoive.
- **Du Code à la demande** : cette contrainte permet d'exécuter des scripts récupérés à partir du serveur

Avant l'apparition du REST les normes pour concevoir une API étaient approximatives et pas particulièrement formalisées, de plus leur intégration nécessitaient l'utilisation de protocole tels que SOAP qui étaient notoirement complexe à créer, à gérer et à corriger. Bien que le REST impose beaucoup de règles, la plupart d'entre elles sont universelles, la finalité étant d'avoir des API plus simples et faciliter considérablement l'intégration

• Les premières API REST

Une API RESTful est une API donc la conception, l'intégration et l'exploitation respectent l'ensemble des contraintes du REST et les premiers à s'intéresser à ce phénomène sont les géants du commerce électronique, **EBay**, suivis **d'Amazon**.

L'accès à l'API REST d'EBay, facile à utiliser et disposant d'une documentation solide, a été offert à une sélection de partenaires. Il a montré à quel point les API nouvellement accessibles pouvaient être lucratives. Par conséquent, sa place de marché n'était plus limitée aux seuls visiteurs sur son site Web, mais à tout site Web accédant à son API.

L'avantage était évident : une visibilité accrue de son offre de produits et donc, une augmentation considérable des opportunités de vente ! La simplicité du système a immédiatement séduit d'autres plateformes en ligne qui ont commencé à réfléchir à la valeur de leur code et non plus uniquement à leurs produits grand public

• L'API Economy

En 2004, **Flickr** a lancé sa propre API REST juste à temps pour la montée en puissance des réseaux sociaux et des blogs. Devenant rapidement la plate-forme photo de référence, Flickr a ainsi ouvert la voie au partage social auquel **Facebook** et plus tard **Twitter** ont rapidement adhéré. La demande d'API publique a augmenté, des API REST facilement accessibles permettent désormais à tous d'ajouter une fonctionnalité à un site Web en un temps record.

En 2006, **Amazon** a contribué au lancement du cloud grâce à son API REST. Depuis lors, les API REST sont devenues la colonne vertébrale d'Internet et les créateurs d'énormes opportunités commerciales en raison de leur capacité à étendre la portée d'une marque au-delà du public d'un site Web. Au cours des dix dernières années, le nombre d'API disponibles au public a donc été multiplié par 50.

• Les perspectives d'avenir

De nos jours, la construction de logiciels ne nécessite plus une équipe d'ingénieurs ou de serveurs coûteux. Une clé d'API et sa documentation sont majoritairement ce dont on a besoin pour intégrer facilement une fonctionnalité existante et disponible à l'externe.

Sachant que les utilisateurs finaux des API sont les développeurs, les API ont été de plus en plus simplifiées au fil du temps pour repousser le maximum de limites et de laisser libre cours à la mise en place de solutions de plus en plus ingénieuses. De ce fait le nombre d'outils pour automatiser certains processus lors de la conception des API ont été automatisés (Exemple : générer la documentation d'une API)

L'utilisation et l'exploitation des API REST est de plus en plus prise en compte dans le modèle économique des entreprises dans les aspects tant B2C que B2B. Les API ont accru les affaires de sociétés de logiciels et sont devenus des éléments essentiels du modèle commercial. Les API sont non seulement en train de changer la face du Web mais aussi celle du modèle économique de nombreuses entreprises.

REST vs SOAP

REST et SOAP sont des éléments souvent comparés à tort l'un à l'autre dans la conception des applications client-serveur. REST est un style architectural qui définit un ensemble de contraintes à respecter si l'on souhaite fournir des services web dit RESTful, par exemple les transmissions sans état et l'utilisation du HTTP, tandis que SOAP est un protocole dont les spécifications sont des normes Web officielles, maintenues et développées par le World Wide Web Consortium (W3C).

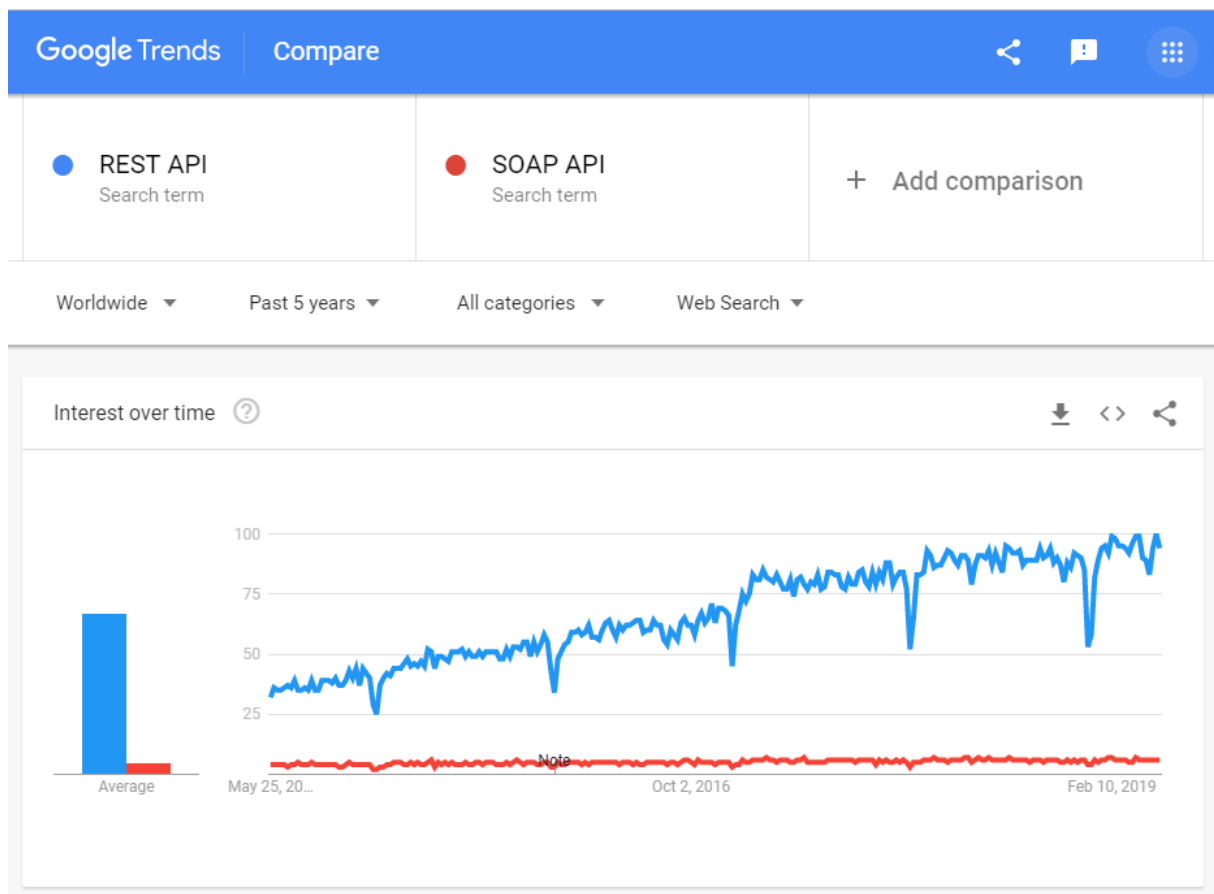
En partant du principe que, dans la conscience collective, SOAP et REST symbolisent deux concepts de création de services web qui abordent la question de transmission de données d'un point de vue différent, les deux styles permettent de créer des API. Le tableau comparatif ci-dessous permet de mettre en évidence les caractéristiques de chacun et ainsi aider à la prise de décision pour choisir l'un ou l'autre des styles :

	SOAP	REST
Définition	Simple Object Access Protocol	REpresentational State Transfer
Conception	Protocole standardisé avec des règles prédéfinies à suivre	Style architectural avec des guidelines et recommandations
Approche	Axée fonction : les données sont accessibles comme services, exple : getUser	Axée Ressource : les données sont accessibles comme ressources, exple : User
Gestion des états	Sans état par défaut. Il est à noter qu'il est possible de rendre une API SOAP stateful	Sans état uniquement. Il n'y a pas de gestion des sessions côté serveur
Caching	Les appels d'API ne peuvent pas être mis en cache	Les appels d'API peuvent être mis en cache
Sécurité	Intègre les normes de sécurité du protocole WS-Security, offre un support SSL et intègre les conformités ACID	Supporte HTTPS et SSL
Performance	Requiert plus de bande passante et de puissance machine	Requiert moins de ressources

Format des messages	XML uniquement	Du texte, HTML, XML, JSON, YML, PDF, et autres MEDIA
Protocoles de transfert	HTTP, SMTP, UDP et d'autres	HTTP uniquement
Recommandations d'utilisation	Les applications d'entreprises, les applications qui demandent une haute sécurité, les environnements distribués, les services financiers, les passerelles de paiement, les services de télécommunication	Les API publiques, les services web, les services mobiles, les réseaux sociaux
Avantages	Une grande sécurité, une grande standardisation	La scalabilité, une grande performance, pour l'amélioration de l'expérience utilisateur (navigateur friendly), la flexibilité
Inconvénients	Moins performant, plus complexe et moins flexibles	Moins sécuritaire, ne convient pas aux environnements distribués, les ressources doivent être disponibles en local

SOAP étant un protocole officiel, il est soumis à des règles strictes et à des fonctionnalités de sécurité avancées telles que la conformité et l'autorisation ACID intégrées. Plus complexe, il nécessite plus de bande passante et de ressource, ce qui peut ralentir les temps de réponses et de chargement des pages. REST a été créé pour résoudre les problèmes de SOAP. Par conséquent, il ne s'agit que de directives générales permettant aux développeurs de mettre en œuvre les recommandations à leur manière. Il autorise différents formats de messagerie tels que le HTML, JSON, XML et du texte brut, tandis que SOAP autorise uniquement le XML.

REST étant également une architecture plus légère, les services web RESTful offrent de meilleures performances. À cause de cela, le REST est devenu particulièrement populaire, surtout à cette ère de la téléphonie mobile où même quelques secondes (notamment en ce qui concerne le temps de chargement des contenus) comptent énormément pour l'amélioration de l'expérience utilisateur.



Source : statistiques Google Trends pour les tendances des API REST vs SOAP sur les 5 dernières années dans le monde entier : la tendance est aux REST comme choix de conception des API

Le modèle de maturité de Richardson

I am getting frustrated by the number of people calling any HTTP-based interface a REST API. [...]. Please try to adhere to them or choose some other buzzword for your API

Source : article du 20/10/2008 du blog de Roy Fielding, <https://roy.gbiv.com/untangled/2008/rest-apis-must-be-hypertext-driven>

Dans les lignes précédentes, une API RESTful a été désignée comme une API respectant l'ensemble des contraintes du REST cependant dans la pratique, toutes les règles ne sont pas exploitées. Dans l'article de son blog, « **Untangled musing of Roy T. Fielding** », l'auteur insiste sur le fait que tant qu'une API n'est pas hypertext-driven, autrement dit quand les données remontées par un appel ne permettent pas d'avoir des liens vers les autres données de l'API, à ce stade il ne s'agit pas d'une API REST, mais plutôt d'une simple API HTTP.

Cette notion d'HyperText vient de Léonard Richardson, un expert de la conception des API RESTful (développeur de la librairie en Python appelée Beautiful Soup), qui a créé un modèle qui décompose

les principaux éléments d'une approche REST en 4 niveaux (0-3) permettant d'évaluer une API par rapport aux contraintes REST. Ce modèle introduit successivement les ressources, les verbes HTTP et les contrôles hypermédia :

Niveau de maturité :	Caractéristiques :
Niveau 0	<p>Le PRC sur HTTP en Plain Old XML :</p> <ul style="list-style-type: none"> - Le protocole ne sert qu'à transporter le message - Tout circule via un seul point d'entrée - Chaque requête contient l'action à effectuer, l'objet cible sur lequel va porter l'action et tout autre paramètres nécessaires à l'exécution de l'action.
Niveau 1	<p>Introduction des Ressources :</p> <ul style="list-style-type: none"> - Les ressources sont identifiées via des URI - Pas de sémantique particulière lors des appels - L'identifiant d'une ressource est obligatoirement rangé dans un champ nommé « Id » - Chaque requête contient l'action à effectuer auprès de la ressource ainsi que les paramètres nécessaires à l'exécution de toute action sur ces ressources
Niveau 2	<p>Utilisation des verbes et codes de retours HTTP :</p> <ul style="list-style-type: none"> - En mode multi ressources - L'utilisation des verbes HTTP (GET, POST, DELETE, PUT) est sémantiquement correcte - L'exploitation des codes de retour HTTP est correcte
Niveau 3	<p>Le contrôle Hypermédia :</p> <ul style="list-style-type: none"> - Basée sur le principe d'HATEOAS (HyperText As The Engine Of Application State) - Les réponses contiennent des liens permettant de parcourir les ressources de l'API - Les opérations sont indiquées sous formes d'hyperliens

Avec le modèle de maturité de Richardson, les API de type 0 et 1 n'utilisent que des POST, au niveau 2 l'API paraît plus formalisée et au niveau 3 on a une API auto descriptive grâce à la contrainte HATEOAS qui permet d'indiquer dans la réponse à une requête GET toutes les autres opérations possibles sur l'API.

L'intérêt du niveau du MMR, n'est pas nécessairement d'implémenter le niveau le plus élevé pour une API, mais juste pour voir où l'on se situe et ce qu'il faut améliorer, force est de constater que **la moyenne des API sur le marché sont de niveau 2.**

Avantages et inconvénients

Les architectures REST, que ce soit dans le cadre des microservices ou pas ont l'avantage :

- D'être plus facile à mettre en œuvre que les alternatives classiques
- De nécessiter que l'utilisation d'un navigateur pour accéder aux ressources d'un services
- De permettre une mise en cache des ressources pour accélérer certaines opérations
- De ne pas consommer excessivement la mémoire
- De répartir les requêtes sur plusieurs serveurs, notamment grâce à l'absence d'état
- De permettre l'utilisation d'un vaste panel de format de données (JSON, XML, Atom, etc.)
- De permettre l'échange des requêtes entre diverses application ou média grâce aux URLs
- De disposer des avantages du HTTP (redirection, cache) qui est supporté par plusieurs plateformes et plusieurs technologies

Il faut cependant tenir compte que toute cette flexibilité nécessite aussi de garder une certaine vigilance sur certains aspects :

- Ne pas perdre de vue qu'il s'agit d'une architecture orientée ressource et en créant les services, il y a une résistance au changement qui consiste à raisonner en termes de fonctions, or ce type de raisonnement amène à créer des fonctionnalités qui multiplie les appels.
- Les données nécessaires à l'utilisation d'un service REST doivent être conservées localement
- Un modèle orienté ressource nécessite la création d'un modèle de données robuste
- En matière de sécurité, les architectures REST sont moins sûres que celles basées sur le protocole SOAP et nécessite des ajustements via une expertise en sécurité

En somme, à l'instar de type de communication tels que le SOAP, XML-RPC et certains protocoles tampons, la mise en place du REST dans les architectures de microservices respecte en quelque sorte l'objectif de technologie agnostique.

2.3.2. Le JSON, format d'échange de données préférentiel

Dans le point précédent traitant du REST, une représentation des données reçue après un appel de service vers l'une des API du projet CoMove, met en évidence un type de format spécifique appelé **JSON (JavaScript Object Notation)**.

Pour cause, l'architecture REST permet aux fournisseurs d'API d'exposer des données dans plusieurs formats, tels que du texte brut, du HTML, du XML, du YAML et du JSON, qui est l'une de ses fonctionnalités les plus appréciées.

Grâce à la popularité croissante de REST, le format JSON léger, lisible et facilement analysable par l'homme a également rapidement gagné du terrain, car il convient parfaitement à un échange de données rapide et très intuitif.

Bien que son nom ne le laisse pas sous-entendre, le JSON est totalement indépendant du langage Javascript et peut donc être utilisé avec n'importe quel langage de programmation. Sa syntaxe est un sous-ensemble de la 3ème édition de la **norme ECMA-262**. Les fichiers JSON se composent de collections de paires nom / valeur et de listes de valeurs ordonnées qui sont des structures de données universelles utilisées par la plupart des langages de programmation. Par conséquent, JSON peut être facilement intégré à n'importe quel langage.

Historique

Le JSON est un format d'échange de données né d'une association entre le langage Javascript et le scripting coté client. Il a été inventé entre 2002 et 2005 par **Douglas Crockford**, architecte logiciel chez PayPal, connu pour ses apports conséquents au développement du langage Javascript, notamment pour ce qui est de la création de l'outil **JSLint** qui permet de détecter les erreurs de syntaxes et de mauvaise pratique lors de l'utilisation du Javascript comme langage de programmation.

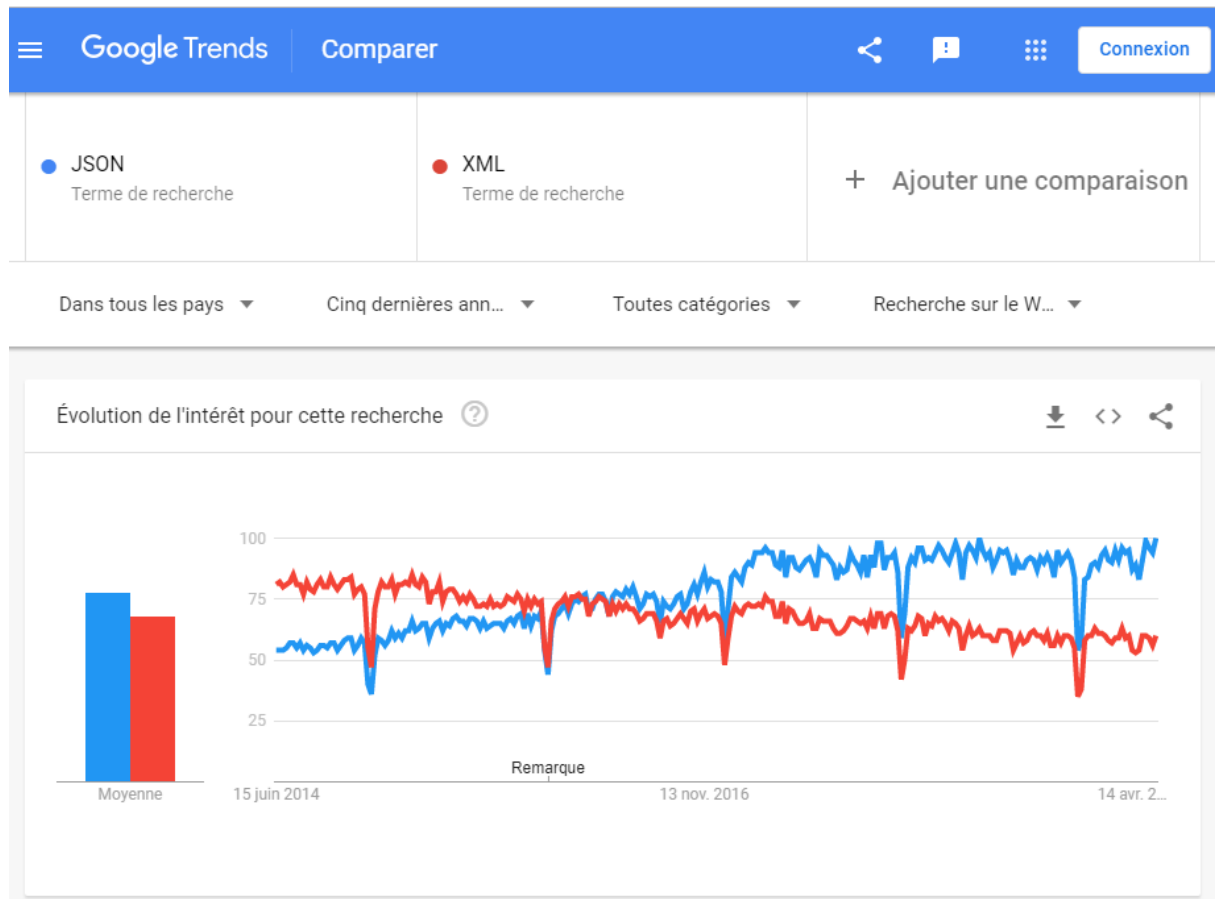
Le JSON est né d'un besoin d'avoir une communication sans état et en temps réel entre le serveur et le navigateur sans l'utilisation de plugins non sécuritaire tels que Flash ou les applets Java, qui dominaient le marché au début des années 2000. L'idée étant de créer un système utilisant les fonctionnalités du navigateur standard et fournissant une couche d'abstraction aux développeurs Web pour la création d'applications Web avec état. Ceci était fait en maintenant une connexion duplex persistante à un serveur Web en maintenant deux connexions http ouvertes et en les recyclant avant les délais d'expiration standard du navigateur si aucune donnée n'était échangée. Crockford a découvert que le langage Javascript pouvait être utilisé comme format de messagerie objet lors de la mise en place d'un tel système.

Le système a été vendu à Sun Microsystems, Amazon et EDS, le site web JSON.org a été lancé en 2002. En 2005, Yahoo a commencé à proposer certains de services Web en JSON, et a été suivi de près en 2006 par Google dans cette démarche.

A l'origine destiné à être un sous-ensemble de Javascript avec la 3^{ème} édition de la norme **ECMA-262** de l'ECMA (European Computer Manufacturers Association), un organisme de standardisation dans le domaine informatique au niveau de l'Europe, on s'est vite rendu compte que le JSON pouvait être intégré à n'importe quel langage de programmation. Ainsi à l'heure actuelle, la syntaxe du JSON est actuellement décrite par deux normes concurrentes : **RFC 8259** de l'IETF (Internet Engineering Task Force) pour les standards internet en Amérique du nord et **ECMA-404** de l'ECMA.

Bien que le XML soit toujours très utilisé pour décrire les données, le JSON a beaucoup gagné en popularité du fait de sa légèreté et de la facilité d'analyse car très intuitif pour l'humain. De plus, selon Douglas Crockford, ce format présente plusieurs avantages par rapport au XML

JSON vs XML



Source : Analyse comparative de l'utilisation du JSON et du XML sur les 5 dernières années dans le monde - Google Trends.

Cette analyse statistique proposée par Google Trends permet de mettre en évidence une certaine popularité montante du JSON. Bien que le XML ait été standardisé en 1998 pour structurer les pages HTML, essayons de comparer les deux standards sur certaines bases de leur utilisation :

Base de comparaison	JSON	XML
Définition	Javascript Object Notation	eXtensible Markup Language
Origine	Dérivée du langage Javascript	Dérivée du SGML
Applicabilité	Transmettre les données de manière analysable via Internet	Pour que les données soient structurées de manière à ce que l'utilisateur puisse utiliser pour annoter les métadonnées, analysez les

		scripts.
Code de représentation des objets	<pre>{ "Paragraphs": [{ "align": "center", "content": ["Here ", { "style": "bold", "content": ["is"] }], "some text" }] }</pre>	<pre><Document> <Paragraph Align = "Center"> Here <Bold> is </Bold> some text </Paragraph> </Document></pre>
Représentation des éléments en hiérarchie	<pre>{ "firstName": "Mr.", "lastName": "A", "details": ["Height", "Weight", "Color", "Age", "Sex", "Language"] }</pre>	<pre><Person> <FirstName>Mr</FirstName> <LastName>A</LastName> <Details> <Detail>Height</Detail> <Detail>Weight</Detail> <Detail>Color</Detail> <Detail>Age</Detail> <Detail>Sex</Detail> <Detail>Language</Detail> </Details> </Person></pre>
Raison de la popularité	Moins verbeux et rapide	Très verbeux (plus que nécessaire). Travail d'analyse fastidieux. Coûts en termes de consommation de mémoire
Structure de donné	Sous forme de carte. La carte est similaire aux paires clé / valeur et est utile lorsque l'interprétation et la prévisibilité sont nécessaires.	Sous forme d'arbre. Il s'agit d'une représentation arborescente des données. Rend l'analyse fastidieuse.
Information de données	A préférer pour la transmission de données entre serveurs et navigateurs	A préférer pour le stockage des informations coté serveur
Communication navigateur-serveur	OK	OK
Marquage des métadonnées	Fastidieux : Il faut transformer une entité en un objet ensuite l'attribut doit être ajouté en tant que membre de l'objet.	Simple : utilisation des balises
Contenu mixte (les chaînes contenant des balises structurées)	Fastidieux : Il faut transformer une entité en un objet ensuite l'attribut doit être ajouté en tant que membre de l'objet.	Simple et efficace : placer le texte baliser dans une balise enfant du parent auquel il appartient
Gestion des namespaces	Aucun support	Supporté

Gestion des listes	Supporté	Non supporté
Sécurité	Moins sécurisé	Plus sécurisé
Gestion des commentaires	Non supporté	Supporté
Encodage	UTF-8 seulement	Varié

Au vu de ces éléments, on peut conclure que le JSON et el XML sont tous les deux un moyen d'organiser les données dans un format compréhensible pour de nombreux langages de programmation et les API. Ces deux types, sont pour la plupart des cas, utilisés au sein de même applications. Ce qui est certain c'est que le XML est définitivement plus ancien et largement répandu dans les applications d'entreprises. Récemment le JSON a gagné en popularité auprès de sa communauté très active d'utilisateurs (en grande partie, les développeurs) en raison de l'essor du JavaScript.

Aucune de ces solutions n'est véritablement supérieure à l'autre. Cependant, elles s'accordent chacune à des cas d'utilisation bien précis :

- Le JSON est plus simple pour extraire des données sur un serveur et les manipuler. Il faut maîtriser la structure des données pour l'utiliser (Être propriétaire des données). Il est léger et économise les ressources. Il est particulièrement prisé par les utilisateurs du JavaScript et peut être pluggé à plusieurs langages de programmations, ce qui peut particulièrement faciliter les développements.
- Le XML, bien que verbeux, convient mieux quand il s'agit de représenter les données, il peut être utilisé en provenance de sources externes et créer des bases de données. Il existe une multitude d'outils d'aide pour traiter le XML et c'est le format de traitement de documents. Il reste aujourd'hui encore le langage de nombreuses interfaces graphiques.

Avantages et inconvénients

Le principal avantage du JSON et à qui il doit sa popularité est sa complétude et sa simplicité de mise en œuvre dans le cadre d'un développement :

- Peu verbeux, il est facilement lisible par l'être humain et interprétable par la machine
- La montée en compétence sur la prise en main du langage est très rapide (Exemple : en 1h sur Udemy), car la syntaxe bien que limitée est réduite et non extensible
- Les données sont faciles à décrire
- Presque tous les langages de programmations ont un plugin pour décrire les données au format JSON
- Dans le cadre des micro-services il est très utile pour la communication des applications dans un milieu hétérogène.

Cependant dans certains cas d'usage il faut tenir compte des inconvénients du langage :

- Le langage est limité à quelques types généraux sans possibilité de les étendre (Exemple : les dates, les couleurs, etc.)

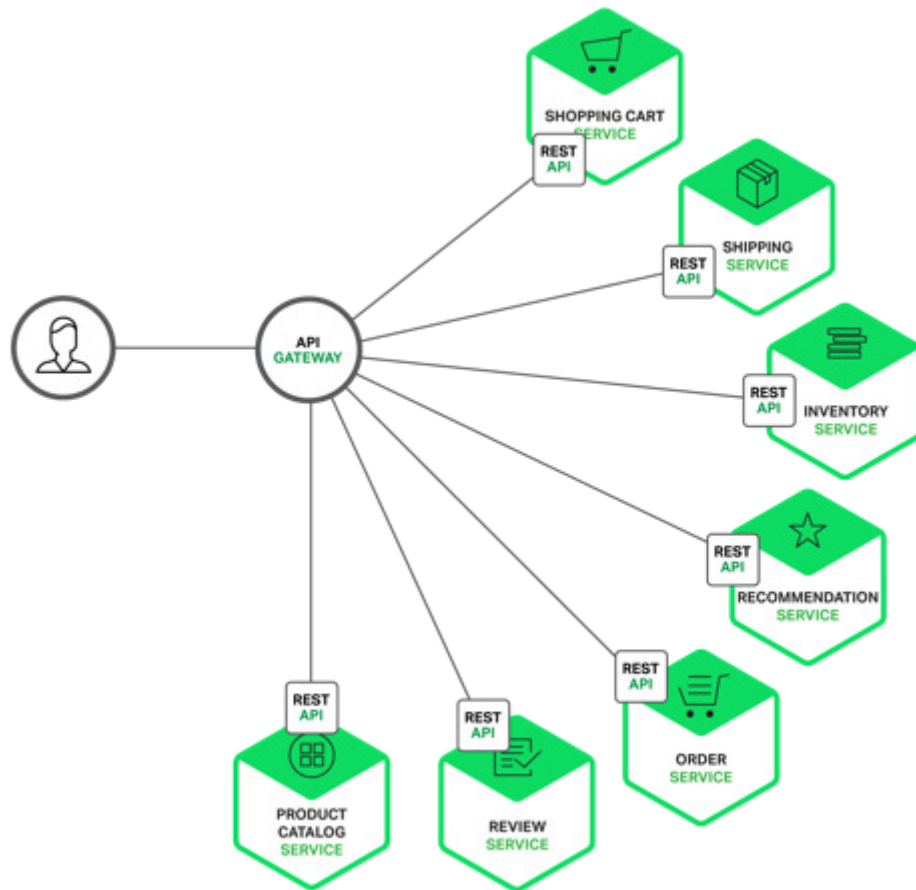
- Le typage faible est la principale faille de sécurité et de fiabilité du langage
- L'impossibilité d'ajouter des commentaires peuvent nuire à la compréhension d'un grand flux de données tels que les configurations et les métriques complexes
- Il n'est toujours compact dans tous les cas
- Ne disposant pas d'un système permettant de valider la structure, les fichiers massifs peuvent contenir des erreurs (nom mal orthographié, attribut manquant mais nécessaire, etc.)
- Il n'est pas adapté à la rédaction de documents
- Il ne dispose pas d'un système de transformation de données afin de les exporter sous différents formats

Tous ces éléments sont à prendre en compte par rapport aux types de projets que l'on souhaite implémenter, le JSON répond à une stratégie de performances au niveau des ressources machines et de rapidité d'implémentation plus qu'à des traitements plus sécuritaires ainsi qu'à un modèle de données complexe. Sachant que dans le cadre des microservices où on souhaite réduire la base de code, la limitation du modèle de données et être dans une stratégie de communication multi-plateforme - multi-technologie, ce langage sied bien à l'architecture.

2.3.3. L'API Gateway

Lorsqu'on implémente une architecture de microservices, il est nécessaire de décider comment les applications clients (mobile, web) généralement appelées Frontend vont interagir avec les microservices (Backend).

Dans une application monolithique, il est d'usage d'avoir et d'entretenir un ensemble de plusieurs points d'entrée (endpoints), qui seront répliqués avec un load-balanceur qui sera utilisé pour distribuer la charge entre ces derniers. Cependant dans une architecture de microservices, chaque microservices expose via une API un ensemble d'endpoints généralement fins. De ce fait pour les communications entre Frontend et Backend, une approche consiste à utiliser une passerelle d'API (API Gateway) pour faire le lien entre les 2 systèmes de l'application.



Source : « Building microservices using an api gateway » nginx.com

Dans cet exemple, NGINX permet d'observer qu'une API Gateway est un serveur qui constitue le point d'entrée unique dans un système, généralement interne comme le Backend. Elle encapsule le système interne et fournit une API adaptée à chaque client.

Le rôle majeur d'une API Gateway est d'intercepter toutes les requêtes en provenance des systèmes externes et de gérer le routage de ces derniers vers les microservices appropriés. Elle traite souvent une demande en appelant plusieurs microservices afin d'agréger les résultats. Elle peut faire la traduction entre des protocoles web comme le http, les websockets et les protocoles utilisés à l'interne (AMQP)

Une API Gateway pourrait également avoir d'autres responsabilités telles que :

- L'authentification
- La surveillance de l'équilibrage de la charge
- La mise en cache
- Le management des requêtes
- Le traitement des réponses statiques

Il est tout à fait possible de mettre en place une solution d'API Gateway maison, cependant il existe plusieurs solutions sur le marché qui ont permis de résoudre un ensemble de problème de conception qu'on devrait prendre en compte dans le cadre de l'intégration des microservices :

La performance et la scalabilité

Pour la plupart des applications la performance et la scalabilité de l'API Gateway est cruciale. Il est donc important de construire la passerelle sur une plateforme prenant en charge les **E/S asynchrones et non bloquantes**. Sur la JVM, on pourrait implémenter des Frameworks tel que **Netty**, **Vertx** ou encore **Spring Reactor**. Notez que la solution non-JVM la plus populaire est **Node.js** construite sur un le moteur javascript de Chrome.

L'utilisation d'un modèle de programmation réactive

Une API Gateway gère certaines requêtes en les acheminant simplement vers le service backend approprié. Cependant le traitement de certaines requêtes nécessite l'appel et l'agrégation des réponses en provenance de plusieurs services. Afin de minimiser le temps de réponse, l'API Gateway doit effectuer les requêtes de façon indépendantes simultanément. Parfois il peut exister des dépendances entre les API, il faut donc savoir orchestrer les appels.

Par exemple, quand un piéton va commander son voyage, la passerelle aura besoin d'authentifier l'utilisateur, de récupérer ses informations personnelles et les informations sur son trajet avant d'appeler les services principaux (dans l'API Voyage) qui vont déduire quel est le conducteur adéquat afin de valider la commande de la course.

La création de l'algorithme de composition des appels en utilisant les callbacks asynchrones traditionnels conduisent rapidement à un code enchevêtré, difficile à maintenir et sujet aux erreurs. Une meilleure approche consiste à écrire le code dans un style déclaratif en utilisant une approche réactive. L'approche réactive permet d'écrire le code de l'API Gateway de façon simple mais efficace. On peut penser à des solutions telles **ReactiveX** pour le .NET, **RxJava** pour la JVM, **RxJS** pour le Javascript.

L'invocation de service

Une application basée sur les microservices est un système distribué et doit utiliser un mécanisme de communication interservices. Comme nous le verrons plus en détail dans le point 3.4, il existe deux modes de communications pouvant être implémenter entre les services. Les communications asynchrones basées sur la messagerie, qui implémentent des messages-broker tel que **JMS** ou **AMQP**. Les communications synchrones tel que HTTP ou Thrift. Généralement, un système utilisera les 2 styles, par conséquent, l'API Gateway devra prendre en charge les deux mécanismes de communication.

Le service Discovery

L'API Gateway doit connaître l'emplacement (adresse IP et port) de chaque microservice avec lequel il communique. Dans une application traditionnelle, on pourrait probablement se connecter directement aux emplacements, mais dans une application moderne de microservices basée sur le cloud, trouver les emplacements est un problème non trivial.

Certes, les services d'infrastructure, tels qu'un bus de messages, auront généralement un emplacement statique, qui peut être spécifié via des variables d'environnement de système d'exploitation. Cependant, déterminer l'emplacement d'un service d'application n'est pas si facile. En effet, ces derniers ont des emplacements attribués de manière dynamique. En outre, l'ensemble des instances d'un service change dynamiquement en raison de la mise à l'échelle automatique. Par conséquent, l'API Gateway, comme tout autre client de service du système, doit utiliser le mécanisme de service Discovery (côté serveur ou côté client). Le point 3.6 décrit plus en détail la notion de service Discovery. Pour le moment, il est intéressant de noter que si le système utilise le discovery côté client, la passerelle API doit pouvoir interroger le service de registre, qui est une base de données de toutes les instances de chaque microservice et de leurs emplacements.

Le traitement des échecs partiels

Un échec partiel est un problème qui se pose dans tous les systèmes distribués lorsqu'un service appelle un autre et que ce dernier répond lentement ou est tout simplement indisponible. L'API Gateway ne devrait jamais rester bloqué en attente indéfiniment. Toutefois le traitement d'un échec dépend de la nature de ce dernier.

Par exemple, admettons qu'un piéton ait été pris en charge par un conducteur et que le service permettant d'afficher le nom du conducteur, l'API Gateway devrait envoyer les autres informations telles que le détail du véhicule, car cette information est toujours utile pour le piéton. Si toute fois le service de prise en charge du piéton, comme « Match » de l'API Voyage chargé de trouver le conducteur adéquat pour la prise en charge du piéton, est indisponible, il convient de renvoyer une erreur au client.

S'ils existent des ressources plus ou moins statique, l'API Gateway devrait être en mesure de les récupérer depuis son cache (ou un cache externe comme Redis), si le service chargé de les envoyer est indisponible.

Ce type de scénario, s'ils sont identifiés et gérés par l'API Gateway, alors cela pourrait garantir que les défaillances du système auront un impact minimal sur l'expérience utilisateur. La bibliothèque Hystrix (de Netflix) peut s'avérer être une solution particulièrement intéressante pour écrire du code permettant de gérer un cas d'échec partiel sur un service indisponible :

- On écrit un code effectuant des appels distants
- Hystrix met un time-out sur les appels de services
- Si le seuil est dépassé, Il implémente le pattern de circuit-breaker qui empêche le client d'attendre indéfiniment et définit une action de secours en cas d'échec de la requête vers un service donnée.
- Tout appel vers le service aura pour réponse l'action de secours d'Hystrix pendant une période bien définit (qui devrait correspondre au temps qu'il faudrait au service pour être à nouveau opérationnel)

Avantage et inconvénients

L'utilisation d'une API Gateway présente à la fois des avantages et des inconvénients.

Un important avantage à utiliser une API Gateway est qu'elle encapsule la structure interne de l'application. Plutôt que de devoir faire appel à des services spécifiques, les clients communiquent

uniquement avec l'API Gateway. Celle-ci fournit à chaque type de client une API spécifique. Cela réduit le nombre d'allers-retours entre le client et l'application et simplifie également le code coté client.

L'API Gateway présente également certains inconvénients. C'est encore un autre composant hautement disponible qui doit être développé, déployé et géré. Il existe également un risque qu'elle devienne un goulot d'étranglement pour le développement. Les développeurs doivent mettre à jour L'API Gateway afin d'exposer les endpoints des microservices implémentés. Il est important que le processus de mise à jour soit le plus léger possible.

Malgré ces inconvénients, cependant, pour la plupart des applications actuelles, utiliser une API Gateway dans une architecture de microservices fait partie des bonnes pratiques.

2.3.4. Le synchronisme vs l'asynchronisme

L'une des décisions les plus importante à prendre avant de faire des choix technologiques bien spécifiques est de savoir si la communication entre les services doit être synchrone ou asynchrone.

En effet ce choix fondamental peut être structurant pour la mise en œuvre de l'architecture, car la mise en place de l'un et/ou l'autre des deux modes de communication permettent deux styles de collaboration idiomatiques différents : la requête/réponse et les événements.

Avant de sélectionner un mécanisme de communication, il serait intéressant d'analyser la question en 2 dimensions. Premièrement :

- **One-to-one** : Chaque requête client est opérée par une unique instance de service
- **One-to-many** : Chaque requête est opérée par plusieurs instances de service

Ensuite, au niveau de l'interaction, déterminer si elle est asynchrone ou synchrone, après quoi on peut déduire quel type d'implémentation on devrait mettre en place :


	ONE-TO-ONE	ONE-TO-MANY
SYNCHRONE	Requête/Réponse	-
ASYNCHRONE	Notification	Publish/subscribe
	Request/ async response	Publish/ async responses

Maintenant explorons plus concrètement les 2 aspects.

Appels synchrones et collaboration requête/réponse

Les appels synchrones correspondent à une **collaboration request/response**. Ceci implique que le client doit s'adapter au temps de traitement du microservice et doit en tenir compte dans son implémentation. L'importance de la prise en compte du temps de traitement du service permet par exemple d'anticiper des timeouts dans le cas où le temps de réponse serait trop long.

Synchronous
all request/response
cycle



Source : « Communication dans une architecture de microservices », cas d'une communication synchrone.

<https://docs.microsoft.com/fr-fr/dotnet/architecture/microservices/architect-microservice-container-applications/communication-in-microservice-architecture>

Dans ce cas de figure, quand le client décide d'effectuer un appel http, un ensemble de services traite la requête et met en attente le client jusqu'à obtention de la réponse. Le temps de réponse est dépendant donc dépendant du nombre de services désignés dans le traitement de la requête.

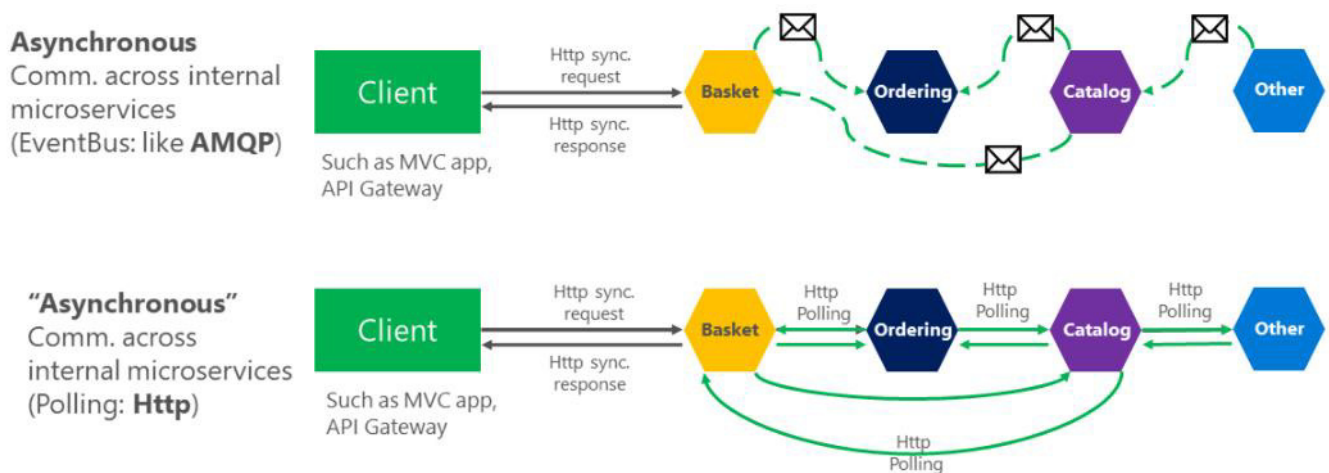
Le choix technologique pour gérer ce scénario devrait porter sur l'implémentation du **REST** et pour aller plus loin, il serait intéressant de considérer une alternative telle qu'**Apache Thrift** qui est un framework multi-langage permettant de faire du RPC. Ceci permet de réduire de manière significative la surcharge de programmation manuelle, et fournir des mécanismes efficaces de sérialisation et de transport à travers toutes sortes de langages de programmation et de plates-formes.

L'avantage d'une communication synchrone, est la certitude d'avoir une réponse sur le statut de la requête. Mais le fait qu'il faille qu'un émetteur doive s'adapter au temps de traitement de la requête est un type de couplage qui risque de se fortifier sur le long terme.

Appels asynchrones et collaboration basée sur les événements

Lors d'une communication asynchrone, l'appelant n'attend pas que l'opération soit terminée avant de poursuivre son processus. Dans ce cas de figure, un client envoie une requête au microservice mais n'attend pas pendant le traitement, il peut être notifié à la fin du traitement directement par ce service ou s'il est abonné à des événements déclenchés par le service de façon à recevoir les notifications.

Les appels asynchrones correspondent à une **collaboration basée sur les événements**, car le client s'abonne à des événements émis par le service en fonction de quoi il souhaite être notifié. Le service n'a pas de connaissance des clients qui sont abonnés à ses événements. Contrairement à une communication synchrone, il n'est pas nécessaire que le client s'adapte en fonction du traitement de la requête et doit être écrit en conséquence.



Source : « Communication dans une architecture de microservices », cas de communications asynchrones.

<https://docs.microsoft.com/fr-fr/dotnet/architecture/microservices/architect-microservice-container-applications/communication-in-microservice-architecture>

Les systèmes de messageries supportent des protocoles standard tel que AMQP et STOMP. Il existe sur le marché un large éventail de solution open-source permettant d'implémenter ce mode de communication, tel que **RabbitMQ**, **Apache Kafka**, **Apache ActiveMQ** pour ne citer que ceux-là.

L'avantage d'une communication asynchrone vient du fait qu'il n'est pas nécessaire pour un client de s'adapter en fonction des traitements des requêtes, cela peut s'avérer utile pour les travaux de longue durée, où il est peu pratique de maintenir une connexion ouverte pendant une longue période entre le client et serveur. De plus, ce mode peut s'avérer particulièrement judicieux face à des problèmes de latence, en effet, les blocages d'appels en attente de résultats peuvent significativement ralentir le trafic.

En conclusion : une communication synchrone semble facile à raisonner, car les informations sur la fin des traitements ainsi que les statuts de succès ou d'échec sont connus. Mais en raison de la nature des réseaux et des appareils mobiles, le fait de lancer des demandes et de supposer que le traitement de ces dernières est un succès permet de garantir la réactivité de l'interface utilisateur, même si le réseau est très lent, c'est ce que permet une communication asynchrone, bien qu'elle soit technologiquement plus complexe à implémenter.

Les communications basées sur les événements qui sont de nature asynchrone, sont privilégiées dans les architectures de microservices car elles permettent de respecter les principes de découplage et de tolérance aux échecs partiels prônés par l'architecture. Le choix technologique afin de gérer ce cas de figure pourrait se porter sur la mise en place d'un répartiteur de message léger (qui ne se limite qu'à la répartition des messages)

Une règle importante à garder à l'esprit consiste à utiliser la communication asynchrone entre les services internes et à utiliser uniquement la communication synchrone au premier niveau des microservices au plus près des applications Frontend.

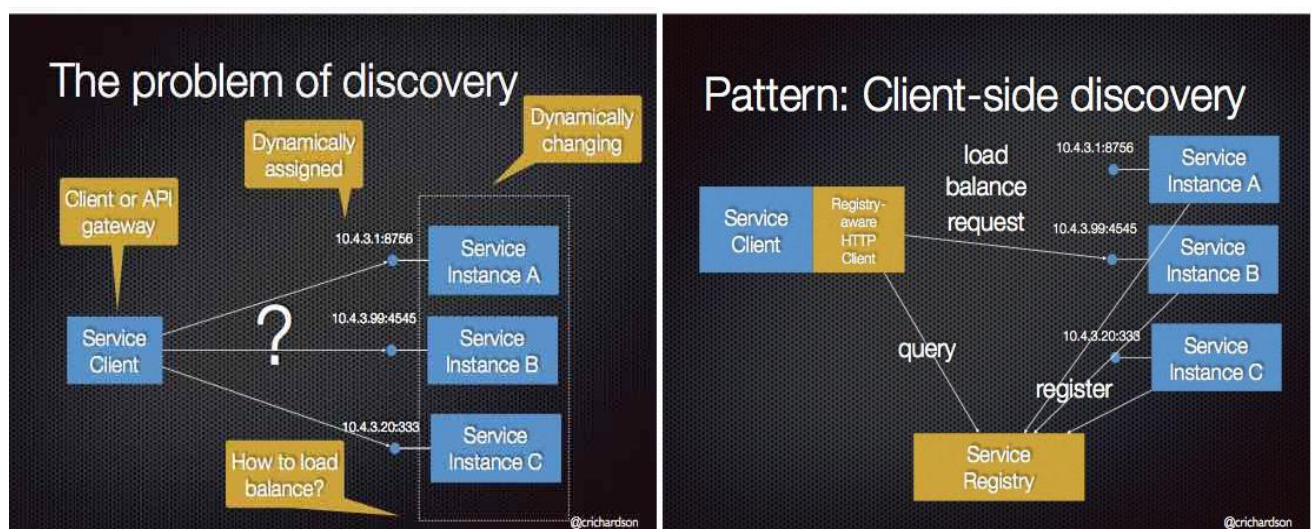
2.3.5. Le service Discovery

Dans le cadre de l'intégration, imaginons que nous ayons du code qui appelle une instance de service dotée d'une API REST. Afin d'envoyer une requête, ce code doit connaître l'emplacement réseau de cette instance, c'est-à-dire son adresse IP et son port. Dans une application traditionnelle fonctionnant sur du matériel physique, les emplacements réseau sont relativement statiques. Par exemple, les emplacements réseaux sont consignés dans un fichier de configuration qui est mis à jour de temps en temps. Cependant, dans une application moderne de microservices basée sur le cloud il s'agit d'un problème difficile à résoudre car les instances de services ont des emplacements réseau attribués de manière dynamique. De plus, ces emplacements changent en raison de la mise à l'échelle automatique et des échecs. Par conséquent il est d'usage d'utiliser un service élaboré appelé le service Discovery qui est capable de « découvrir » les adresses des instances de services avec lesquelles on souhaite communiquer dans une architecture de microservices hautement distribuée.

Il existe 2 principaux patterns du service Discovery, celui coté client et celui coté serveur. Commençons tout d'abord par le premier

Le pattern Discovery coté client

Quand ce modèle est utilisé, c'est le client (service appelant) qui est responsable de la détermination des emplacements réseaux des instances disponibles et qui effectue les requêtes d'équilibrage de charge entre ces instances. Le client interroge un registre de service, qui est une base de données regroupant les instances disponibles. L'emplacement d'une instance est automatiquement enregistré dans le registre des services, mis à jour périodiquement avec un mécanisme de pulsation (une requête GET/healthcheck vers l'instance dont le statut HTTP(OK/KO) permet maintenir l'instance dans le registre) et supprimée quand elle se termine. Ce client devra par la suite, utiliser un algorithme d'équilibrage de charge pour sélectionner l'une des instances.



Source : « Pattern: Client-side discovery »

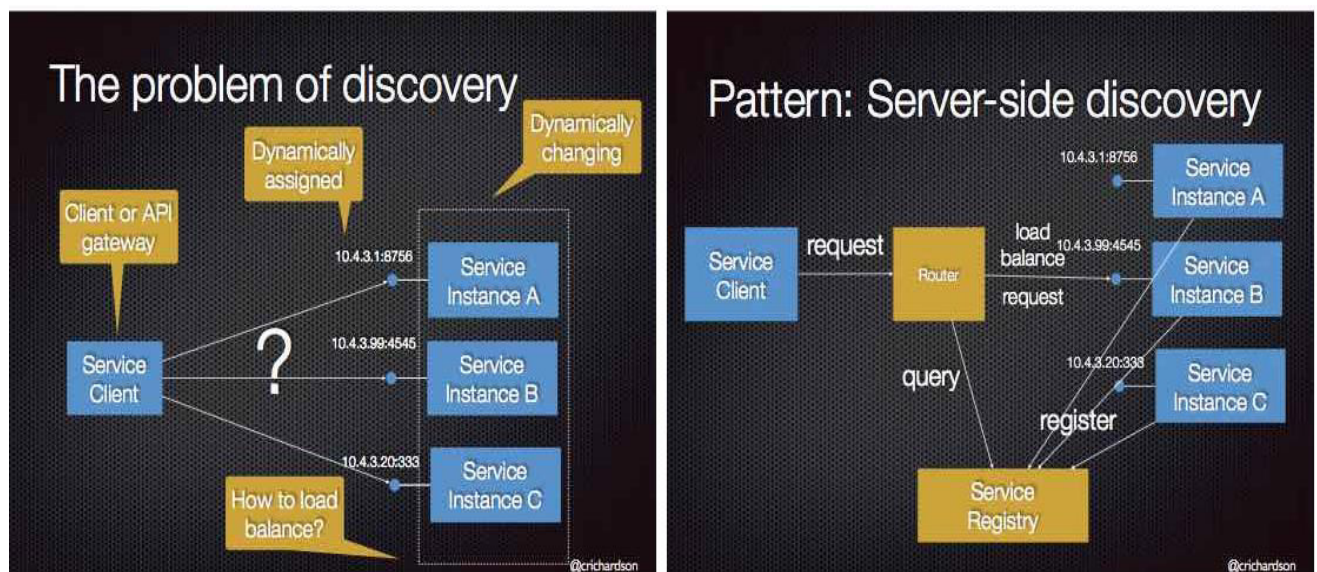
<https://microservices.io/patterns/client-side-discovery.html>

Ce modèle présente quelques avantages et inconvénients. Il est relativement simple à implémenter, mis à part le registre de services à mettre en place, les mécanismes restants sont faits automatiquement. De plus, la connaissance des instances de services disponibles par le client lui permet de prendre des décisions intelligentes d'équilibrage de charges en fonction des besoins de l'application. Un inconvénient majeur de ce modèle est qu'il couple le client au registre de services et qu'il faille implémenter cette logique de service discovery pour chaque langage de programmation d'un client.

Netflix OSS est un bon exemple de modèle de découverte coté client, il propose des services tout prêt (on parle de Edge microservices) tels que **Netflix Eureka** qui est un registre de services qui fournit une API REST permettant de gérer l'enregistrement des instances et d'interroger les instances tel que défini ci-dessus. **Netflix Ribbon** qui est un client qui fonctionne avec Eureka pour répartir les requêtes sur les instances de service disponibles

Le pattern Discovery coté-serveur

Lors de l'utilisation de ce modèle, le client effectue une requête à une instance de service via un load-balanceur. Ce dernier interroge le registre de services et par la suite route la requête vers l'instance de service disponible. Comme avec le pattern discovery coté client, les instances de services sont enregistrées et désenregistrées dans le registre de service



Source : « Pattern: Server-side discovery »

<https://microservices.io/patterns/server-side-discovery.html>

L'un des plus grands avantages de ce modèle est que les détails de découverte des instances sont abstraits pour un client. Les clients devront simplement interroger l'équilibreur de charge. Ceci élimine le besoin d'implémenter la logique de Discovery pour chaque langage de programmation et Framework utilisé par les clients de service. Aussi, bien que nous soyons dans la section liée à

l'intégration, il est intéressant de dire que certains environnements de déploiement fournissent cette fonctionnalité. De ce fait, cette information doit être prise en compte dans le choix technologique de la solution de déploiement.

Cependant, cette solution présente un léger inconvénient, le load-balanceur compte parmi les composants du système qui devra être hautement disponible et qu'il va falloir et gérer.

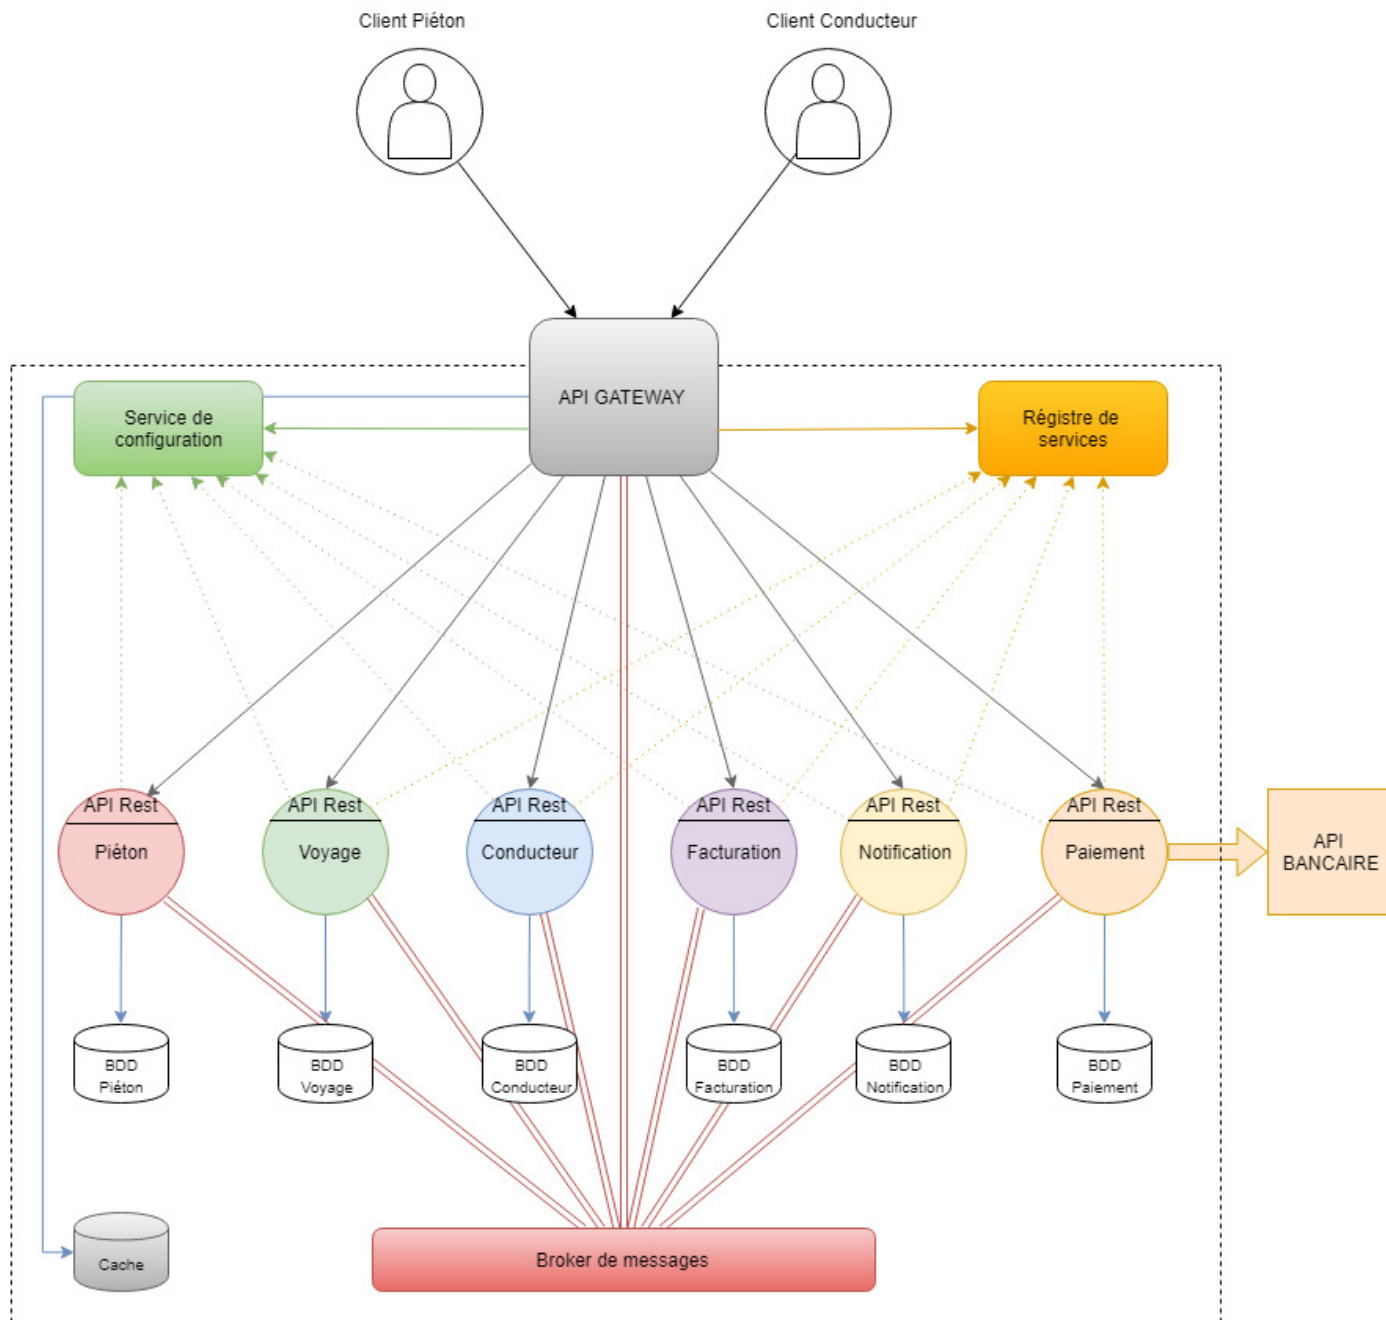
Une solution intéressante à explorer serait un serveur HTTP et load-balanceur telle que NGINX afin d'implémenter le pattern Discovery coté serveur.









Les edges microservices

Il s'agit de microservices génériques que l'on retrouve sur le marché qui assurent le fonctionnement et la cohésion globale du système. On pourrait citer entre autres :

- **Hystrix** : rend une application résiliente aux pannes de ses dépendances externes en arrêtant momentanément de les invoquer le temps de leur disponibilité.
- **Ribbon** : Permet les appels de procédure distante avec des équilibreur de charge logicielle intégrés.
- **Zuul** : Joue un rôle de reverse proxy, c'est un routeur qui va dispatcher vos utilisateurs sur vos différents services en fonction des URLs appelés.
- **Archaius** : propose un ensemble fonctionnalités pour la gestion des configurations des API.
- **Zipkin** : système de traçage distribué qui aide à rassembler les données de synchronisation nécessaires pour résoudre les problèmes de latence dans les architectures de microservices.
- **Zookeeper** : logiciel de gestion de configuration pour système distribué qui supporte une haute disponibilité grâce à des services redondants
- **Redis** : système de gestion de base de données clef-valeur scalable. Il est adapté aux bases de données non-relationnelle de type NoSQL et vise à fournir les performances les plus élevées possible.
- **Feign** : client de service web déclaratif qui facilite l'écriture de clients de services Web.

Architecture logicielle cible d'intégration de CoMove



-  Appels REST des client mobiles vers l'API Gateway
-  Appels REST de l'API Gateway vers les microservices
-  Récupération par l'API Gateway de sa configuration et des noms des services
-  Récupération de la configuration du microservice au démarrage
-  Consultation du registre des instances de services par l'API Gateway
-  Inscription de l'instance de service dans le registre de service
-  Canaux de communications AMQP
-  Accès à la base de donnée
-  Appels REST de l'API paiement vers l'API Bancaire

Technologies	
Applications mobiles	IOS, Android
Applications web	Angular 7+
Microservices	Spring Boot 2, .NET
Service de Configuration	Spring cloud – config server
Registre de service	Cloud Discovery – Eureka server
API Gateway	NGINX plus
Cache	Redis
Broker de message	Rabbit MQ
Base de données	MongoDB, Cassandra

3. API management

A ce stade de l'étude, nous avons observé comment les microservices sont élaborés et regroupés dans plusieurs API, comment on les concevait et comment ils s'intègrent entre eux au sein d'une application, ainsi les différentes stratégies permettant de les déployer. L'idée d'introduire à présent la notion de gestion d'API ou encore API management reviens à voir un aspect lié à la gouvernance des microservices via leur API. En effet les API sont conçues dans la stratégie d'une entreprise afin de permettre à cette dernière de lui générer du profit.

En effet, l'API management ou gestion des API est un processus de publication et de supervision des interfaces de programmation d'application (API) dans un environnement sécurisé et évolutif, dont l'objectif est de permettre aux entreprises qui publient ou utilisent une API d'en surveiller le cycle de vie et de s'assurer que les besoins des développeurs et des applications utilisant l'API soient satisfaits.

Les besoins en termes d'API management varient d'une organisation à l'autre, mais la notion d'API management en elle-même englobe certaines fonctionnalités de base, notamment en ce qui concerne :

- L'exposition et la documentation des services
- Gestion des authentification et habilitations
- La sécurité globale
- La supervision des services exposés au travers de métriques prédéfinies
- La gestion du trafic
- Le contrôle de version
- La transformation des données

Mais bien au-delà de l'aspect purement métier d'une organisation, l'API elle-même devient un véritable enjeu business. En effet, beaucoup d'entreprises souhaitent exposer leurs contenus et services sous forme d'API afin d'en monétiser les accès et/ou les commercialiser entièrement. Les organisations, quel que soit leur taille, cherche par ce biais un différenciateur concurrentiel très fort qui a mené à ce qu'on appelle aujourd'hui l'**API Economy**. En 2015 l'étude Tech Trends publiée par le cabinet Deloitte identifie l'API Economy comme une tendance majeure qui couvre les secteurs suivants :

- Les réseaux sociaux
- Le e-commerce via le Big Data
- Les télécommunications
- Les objets connectés (IoT)
- Les services de géolocalisation
- Les Apis bancaires

C'est notamment pour prendre en compte cet aspect business que l'API management est devenue de plus en plus importante. Il y a une dépendance croissante des entreprises vis-à-vis des API, une augmentation considérable du nombre d'API dont elles dépendent et de la complexité de ces dernières. Les exigences et processus de création et de gestion des API diffèrent de la plupart des autres applications. Pour être utilisées correctement, les API nécessitent une documentation solide, des niveaux de sécurité accrus, des tests complets, une gestion des versions de routine et une fiabilité élevée. Étant donné que ces exigences vont souvent au-delà de la portée des projets logiciels, les organisations sont ouvertes à l'idée d'utiliser des solutions d'API management.

3.1. Les API publiques et privées

Dans la mise en place d'une brique tel qu'un outil d'API management à la fondation de son architecture de microservices, une organisation doit en premier lieu définir ses enjeux stratégiques et économiques afin de décider si elle doit ou non ouvrir son API. Voyons maintenant quels sont les utilités d'ouvrir ou non un système au grand public ou à des partenaires au travers des définitions d'API publiques et privées.

Les API publiques

Comme le nom l'indique les API publiques sont ouvertes à tous. Elles sont conçues pour être accessible par une communauté de développeurs plus large (d'un point de vue mondial) pour la création d'applications mobiles et Web. Elles peuvent être observées comme des API utilitaires pour implémenter une solution interne en permettant aux organisations d'ajouter de la valeur à leur cœur de métier sans fournir un certain effort de réalisation. Les API publiques permettent essentiellement aux développeurs d'utiliser leur créativité et aident à réduire des coûts en termes de temps de développement. Elles peuvent aussi aider à générer de nouvelles idées commerciales.

Lorsqu'une entreprise décide d'ouvrir ses API, cela est fait dans le but d'accéder et de capter un marché d'utilisateurs.

Par exemple : en ouvrant ses API, une entreprise comme **Slack** (logiciel de messagerie) a réussi à créer un cercle vertueux en ayant une base large d'utilisateurs qui a attiré des développeurs qui ont intégré des services tiers. Ces services ont par la suite attiré d'avantage d'utilisateurs.

Start here ^{new}

An introduction to apps
Planning your app
Designing app experiences
Building an app
Changelog

App features

Internal integrations
Incoming webhooks
Slash commands
Building bots
Actions
Dialogs
App Home
Shared Channels
Enterprise Grid

Messaging

Overview
Managing messages
Composing messages
Interactivity



Visitbot APP 9:00 AM
Hey Bruce! Jimmy is here for you at the front desk.

Your Full Name
Jimmy West
Who are you here to see?
Bruce Sullivan

Send messages

Messages are the building blocks of apps and bots. Start from "Hello, world," or connect a service you already use.

Learn about [Messages & Incoming Webhooks](#).

Create simple workflows

Your app can respond to user activity, and buttons let users complete simple tasks (like requests and approvals).

Learn about [Interactive Components & Events API](#).



Hiretron APP 9:00 AM

Approval Request

Your approval is requested to make an offer to [Florence Tran](#).

[Approve](#)

[Deny](#)



Expensibot APP 9:00 AM
Good evening, Caroline, do you need to expense something?

Build bots

Add a bot to talk with users and

Nous pouvons aussi citer le **Facebook Connect** qui permet à des millions d'utilisateurs de se connecter à des applications tierces en quelques clics. En ouvrant cette API, Facebook s'est rapidement imposé comme une brique technologique pour un écosystème technique.

facebook for developers
Documentation
Outils
Assistance
Mes applications
Rechercher dans developers.facebook.com

ms_asl_app
ID de l'APP : 482333175745853
DÉSACTIVÉ
Statut : en développement
Voir Analytics
Aide

Tableau de bord
Paramètres
Rôles
Alertes
Contrôle app

PRODUITS
Facebook Login
Paramètres
Quickstart
Webhooks
Analytics

Journal des activités

Ajoutez facilement Facebook Login à votre app avec notre Quickstart

Paramètres OAuth clients

☒
Connexion OAuth client

Active le processus de token client OAuth standard. Sécurisez votre app et empêchez tout abus en verrouillant les URI de redirection de token autorisées avec les options ci-dessous. Désactivez-les complètement si vous ne les utilisez pas. [?]

☒
Connexion OAuth web

Active la connexion client OAuth web. [?]

☒
Imposer le HTTPS

Imposez l'utilisation du HTTPS pour les URI de redirection et le SDK JavaScript. Vivement recommandé. [?]

☐
Forcer la ré-authentification OAuth web

Une fois activée, invite les gens à entrer leur mot de passe Facebook avant de se connecter sur le web. [?]

☐
Connexion OAuth de navigateur intégrée

Activez les URI de redirection de webview pour la connexion client OAuth. [?]

☒
Utiliser le mode strict pour les URI de redirection

N'autorise que les redirections qui utilisent le SDK Facebook ou qui correspondent exactement aux URI de redirection OAuth valides. Hautement recommandé. [?]

URI de redirection OAuth valides

Entrez une URI de redirection OAuth valide.

☐
Connexion à partir des appareils

Active le processus de connexion client OAuth pour les appareils tels que les smart TV [?]

Le groupe **SNCF** est aussi un acteur majeur de l'open Data en France, grâce à la collecte et au partage de nombreuses données remontées par le transport quotidien de 10 millions de voyageurs. L'Open Data et les API proposés par la SNCF constituent un vecteur d'innovation sur les nouveaux challenges liés à la mobilité (cheminement, optimisation et valorisation du temps de voyage, adaptations aux besoins des voyageurs, etc.)

SNCF OPEN DATA

ACCÉDER À L'API SNCF DATA CGU CONTACT

Nancy Njeundji Déconnexion

1 enregistrement

Aucun filtre actif

Filtres

Rechercher...

Horaires des lignes TER

Informations Tableau Export API

Ce jeu de données peut être utilisé via une API qui autorise la recherche et le téléchargement d'enregistrements par plusieurs critères, exposés ci dessous.

Jetez un oeil à la [documentation de l'API](#) et utilisez la [console d'API complète](#) pour essayer les autres API !

dataset: sncf-ter-gtfs

ID du jeu de données

q

lang

rows: 10

start

sort

facet

```
{
  "nhits": 1,
  "parameters": {
    "dataset": {
      "sncf-ter-gtfs"
    },
    "timezone": "UTC",
    "rows": 10,
    "format": "json"
  },
  "records": [
    {
      "datasetid": "sncf-ter-gtfs",
      "recordid": "8182673e70697e2d782fa440e0f7be0b39880b",
      "fields": {
        "download": {
          "format": "zip",
          "thumbnail": false,
          "height": 300,
          "width": 300,
          "filename": "export-ter-gtfs-last.zip",
          "id": "24e02fa96949e2caa5863a365c66ec2"
        },
        "données": "Horaires des lignes TER",
        "format": "GTFS"
      },
      "record_timestamp": "2019-08-13T14:25:51+00:00"
    }
  ]
}
```

Partant toujours du principe que les utilisateurs cible des API sont ceux qui l'exploitent, c'est-à-dire les développeurs, le succès d'une API publique dépend de sa capacité à attirer ces derniers et à les aider à créer de véritables applications.

Les API privées

Il s'agit essentiellement d'API hébergées sur un réseau privé et qui sont exposées et utilisées à l'interne dans une organisation. Généralement, elles sont sécurisées avec des restrictions d'accès et des limites d'utilisation par un groupe de développeurs et de partenaires connus. Les ressources ne sont par conséquent pas accessibles, ni aux usagers, ni au grand public

Ce type d'API, permettent à des entreprises de centraliser les données nécessaires à leur bon fonctionnement. Elles conservent la main sur leurs données et informations partagées et cela pourrait avoir un impact positif sur la productivité de celles-ci.

Elles sont généralement destinées aux intégrations de partenaires B2B et à un usage interne. Ainsi on peut scinder des API privées en deux groupes :

- **API partenaires** : elles contribuent à une stratégie commerciale et économique pour fournir des services à des partenaires de business

- **API internes** : Elles contribuent à une stratégie de croissance et de gouvernance pour développer le cœur de métier d'une organisation et son savoir-faire. (Applications web ou mobiles utilisées strictement en interne)

L'intérêt d'utiliser des API fermées se porte sur la nature des données échangées, à l'exemple de tout type de données sensibles telles que des données personnelles, bancaires, des secrets industriels...Avoir un environnement clos pour ce type de données permet d'identifier et de traiter en amont des problèmes potentiels de sécurité.

Attention : Une pratique consiste à héberger des API sur un réseau public sans toutefois les exposer, c'est-à-dire sans partager leur existence et leur documentation. Ces API sont théoriquement privées parce qu'elles ne sont pas connues de la communauté des développeurs. Mais techniquement, les développeurs, dans leur phase d'expérimentation, de recherche et de tests peuvent les trouver et les utiliser accidentellement. Ce n'est donc pas la bonne approche !

Le site www.programmableweb.com répertorie l'ensemble des API du globe. On peut avoir un aperçu rapide de l'utilité de certaines API en fonction d'un besoin et d'un métier particulier :

Organisation	Adresse	Catégorie	Synopsis
Facebook	https://developers.facebook.com	<ul style="list-style-type: none"> • Social • Marketing • Publicité • Paiement • Réalité augmentée 	pour publier des activités sur les pages d'actualisation et de profil de Facebook, sous réserve des paramètres de confidentialité de chaque utilisateur
Google	https://developers.google.com.res.banq.qc.ca	<ul style="list-style-type: none"> • Cloud • Cartographie • Outils • eCommerce • Entreprise • Office • Photographie • Stockage de donnée • Etc. 	Pour la communication avec les services Google, tels que la recherche, la traduction, Gmail, les cartes géographiques, les vidéos, les réseaux sociaux et la publicité
Instagram	https://www.instagram.com/developer/	- photographie - social	Pour obtenir des photos à partir d'Instagram et de les afficher sur votre propre site Web ou application
Amazon	https://developer.amazon.com/	<ul style="list-style-type: none"> • Base de données • Email • Paas • Gestion de la relation client • eCommerce 	Pour les achats intégrés, les annonces mobiles, les notifications push, l'expérience utilisateur très poussée
AT & T	https://developer.att.com/	<ul style="list-style-type: none"> • Messagerie • Relation client • Urgences • Sécurité 	pour créer des applications pouvant envoyer des messages (SMS / MMS), localiser des utilisateurs, convertir du texte

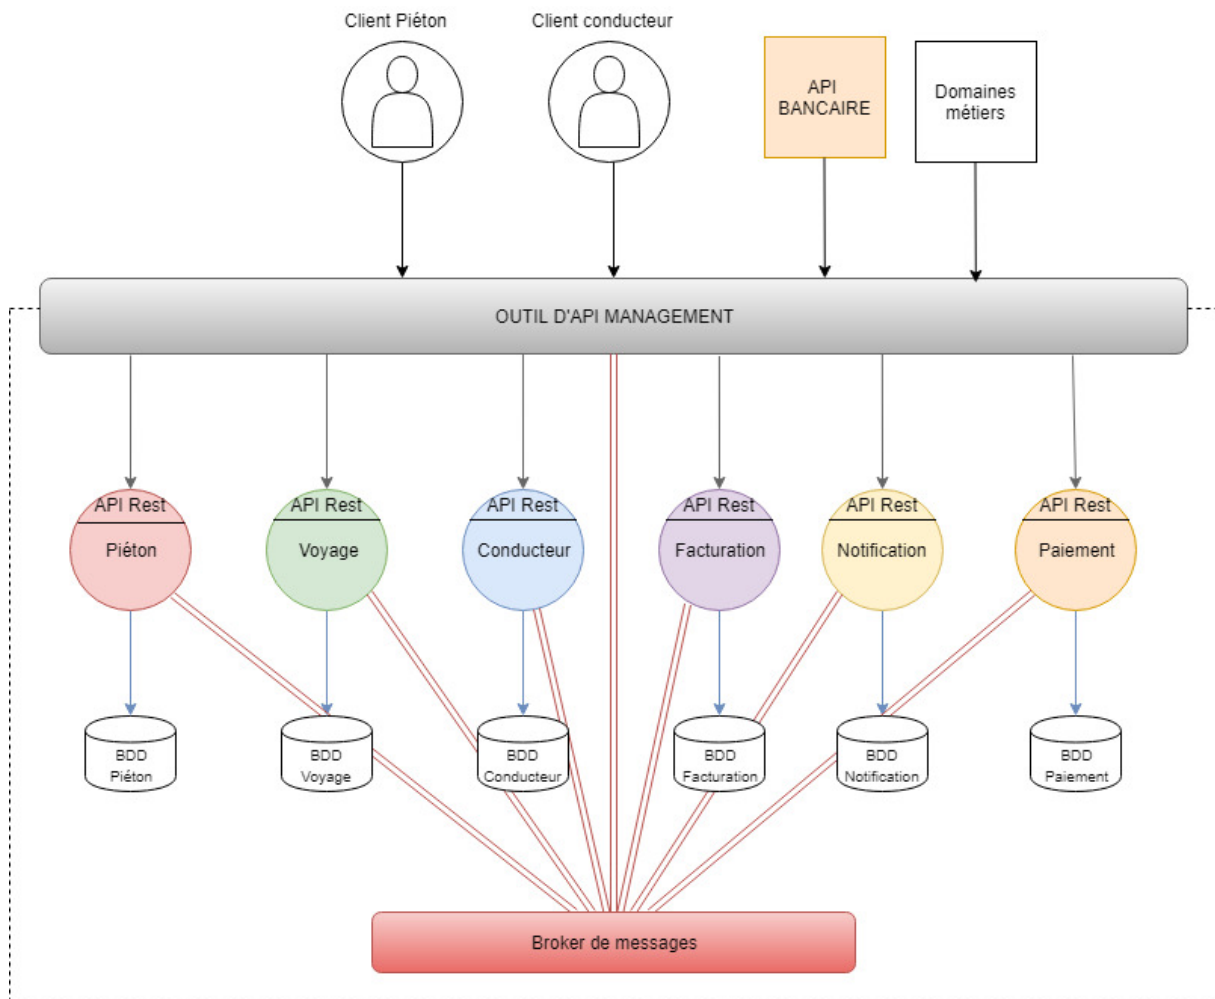
		<ul style="list-style-type: none"> • Management 	en parole et de la parole à texte, monétiser des applications via des publicités incorporées, utiliser les fonctionnalités M2X, etc.
--	--	--	--

Une fois les API créées, elles peuvent être gérées à l'aide d'une plateforme de gestion des API (API management). Une plateforme d'API management aide les organisations à publier des API (à l'interne et à l'externe), afin de fournir des services liés à leur expertise.

Pour les développeurs, l'API management permet d'analyser, sécuriser et documenter les API. En ce qui concerne les entreprises, elle permet d'accélérer leur déploiement sur les canaux numériques, à monétiser le savoir-faire, à optimiser les investissements de transformation numériques et améliorer la collaboration avec de nouveaux partenaires.

3.2. Les services principaux

Dans une architecture cible d'une application, un outil d'API management est positionné stratégiquement de telle sorte qu'il puisse permettre l'intégration entre les systèmes externes (Frontend et systèmes tiers) et internes (Backend). Ainsi il pourra réaliser les tâches aidant à l'interception, au routage et au contrôle des données.



L'API Gateway

La notion de passerelle d'API ou encore API Gateway constitue le cœur de toute solution d'API management, car elle permet une communication flexible, sécurisée et fiable entre les services principaux et les applications numériques. Elle permet d'exposer, de sécuriser et de gérer les données et services principaux en tant qu'API RESTful.

Tel un proxy très poussé, elle crée une façade en amont des services Backend qui intercepte les requêtes vers l'API afin de :

- Appliquer la sécurité
- Valider les données
- Transformer les messages
- Limiter le trafic
- Rediriger les réponses vers les différents services
- Mettre les données statiques en cache pour améliorer la performance
- Se connecter aux bases de données

(Pour plus de détail cf. le point ?)

Le service de routage

Bien qu'il soit possible de mettre en place un service (cf. 3.6.) uniquement dédié à gérer les redirections vers d'autres fonctionnalités Backend, il est possible de déléguer cette tâche à un outil d'API management. Elle doit pouvoir identifier et acheminer les demandes vers les bonnes instances, notamment via :

- **Le mappage d'URL** : le chemin de l'URL entrante peut être différent de celui du service principal. Une fonctionnalité de mappage d'URL permet à la plateforme de modifier le chemin d'accès dans l'URL entrante à celui du service principal. Ce mappage d'URL a lieu au moment de l'exécution, de sorte que le consommateur récupère la ressource demandée via la répartition des services.
- **La distribution de service** : cette fonctionnalité permet à la plate-forme de sélectionner et d'appeler le service principal approprié. Dans certains cas, il peut être nécessaire d'appeler plusieurs services pour effectuer une sorte d'orchestration et renvoyer une réponse agrégée au consommateur.
- **Le regroupement de connexions** : la plate-forme d'API management doit pouvoir conserver un pool de connexions au service principal. Le regroupement de connexions améliore les performances globales
- **Le load-balancing** : cela consiste à sélectionner un algorithme qui achemine les demandes vers les ressources appropriées afin de distribuer le trafic API vers les services principaux. Divers algorithmes de load-balancing peuvent être pris en charge. Ceci devrait améliorer les performances globales d'une API.
- **Service d'orchestration** : La fonctionnalité d'orchestration de service permet de créer un service grossier en combinant les résultats de plusieurs appels de services principaux dans une séquence particulière ou en parallèle. Cette fonctionnalité cible également l'amélioration de la performance globale en réduisant la latence que pourraient induire plusieurs appels d'API. L'API Gateway dans une solution d'API management peut jouer un rôle d'orchestrateur (plutôt léger) notamment en ce qui concerne les requêtes sans état et non transactionnelle.

Le contrôle et la gestion de version

En règle générale, le contrôle de version des API n'a qu'un objectif : celui d'éviter au maximum de changer passer d'une version à une autre. En effet, la publication d'une nouvelle version d'API contraint les développeurs d'applications de lancer un nouveau cycle de mise en production avec tout ce que cela comporte :

- Analyse d'impact sur les applications
- Mise à niveau/jour du code
- Débogage
- Déploiements sur différents environnements
- Les tests d'assurance de qualité....

De ce fait, le passage d'une version à l'autre est tout ce qui va **inévitablement** rompre cette communication et rien autre. Ainsi le contrôle de version des API doivent respecter quelques principes :

Ne pas bloquer le client : Une nouvelle version d'API ne doit bloquer aucun client existant depuis les versions antérieures. En effet, une fois publiée, il faut partir du principe que l'API est utilisée par des développeurs d'applications et changer fréquemment de version augmente le risque de régression et par conséquent de briser les applications clientes. Ceci peut nuire à la popularité d'une API auprès des développeurs. Il vaut mieux ajouter des modifications compatibles avec les anciennes versions plutôt que d'en ajouter systématiquement de nouvelles. Il s'agit plus d'entretenir cette idée pour faciliter les prises de décisions.

Faire de la rétrocompatibilité : La rétrocompatibilité consiste à apporter des modifications qui n'impacte pas le client. Par exemple :

- Exposer des nouveaux services qui ne sont pas nécessairement utilisés par le client
- Changer la structure d'une réponse en gardant ce qui existait dans les versions ultérieures
- Rendre les nouveaux paramètres d'entrée optionnels/facultatifs...

En principe, ce type de modifications n'impactent pas le client et ne nécessite pas un changement de version.

Oublier le logiciel : Le logiciel évolue très rapidement. Chaque version majeure, les améliorations et les corrections de bogues donnent lieu à une nouvelle version du logiciel. Lier la version du logiciel à celle de l'API entraînerait des changements trop réguliers et qui seraient ingérables par les fournisseurs des API et par conséquent très frustrant par ceux qui les consomment. Cette option ne devrait pas être envisagée.

Le caching

La mise en cache est un mécanisme permettant d'optimiser les performances en répondant aux requêtes avec des réponses statiques stockées en mémoire. L'outil d'API management positionné tel un proxy (API Gateway) dans le plan d'architecture, peut stocker les réponses des requêtes fréquemment appelées et les retourner au lieu d'interroger systématiquement les serveurs principaux en Backend. Cela permet d'améliorer les performances des API grâce à une réduction de la latence et du trafic réseau.

Tous les points évoqués ci-dessous forment un ensemble de bonnes pratiques à implémenter. Une solution d'API management adéquate devrait permettre au fournisseur d'API de maintenir plusieurs versions d'API suffisamment longtemps pour permettre une transition en douceur.

3.3. La documentation

Il a été évoqué à plusieurs reprises que les principaux consommateurs d'API étaient les développeurs. Et pour ces derniers, la documentation est certainement l'élément essentiel qui pourrait retenir leur attention et les fidéliser car elle communique une grande quantité d'informations utiles et

pertinentes sur l'API tel un manuel d'utilisation très détaillé. La documentation d'une API doit présenter certains aspects afin de permettre aux développeurs de se familiariser avec les fonctionnalités de façon intuitive, de commencer l'utiliser facilement et de l'adopter rapidement.

Le modèle de documentation

Pour que la documentation de l'API soit efficace et permette aux développeurs d'accélérer leur montée en compétence, elle doit inclure les aspects suivants relatifs à l'API :

- Le nom d'API
- Le nom du microservice et son rôle
- Les endpoints : Urls que les développeurs vont utiliser pour appeler les services présentés par l'API
- Les méthodes : principalement les verbes http (GET, POST, PUT, DELETE)
- Les paramètres dans les URL
- Les paramètres dans le corps de la requête (payload)
- Les paramètres d'en-tête (Headers)
- Les codes de réponses et d'erreur
- Un exemple de requête et de réponse avec de comprendre la structure des données échangées.
- Des tutoriels et visites guidées
- Les SLA : les contrats de niveau de services qui définissent les exigences non fonctionnelles

pet : Everything about your Pets — Nom et rôle du microservice

Show/Hide | List Operations | Expand Operations

POST /pet — endpoint (url) — Objectif de l'opération — Add a new pet to the store

Parameters — type de methode HTTP

Parameter	Value	Description	Parameter Type	Data Type
body	(required)	Pet object that needs to be added to the store	body	Model

Parameter content type: application/json — type de format des données

Exemple de requete

```
{
  "id": 0,
  "category": {
    "id": 0,
    "name": "string"
  },
  "name": "doggie",
  "photoUrls": [
    "string"
  ],
  "tags": [
    "string"
  ]
}
```

Response Messages

HTTP Status Code	Reason	Response Model	Headers
405	Invalid input		

Try it out! — Code et message d'erreur

PUT /pet — Update an existing pet — Autres opérations du microservice

GET /pet/findByStatus — Finds Pets by status

Les API de documentations

Une tâche recommandée est d'intégrer un outil qui va générer la documentation de l'API au fur et à mesure que l'API évolue. En effet, le risque principal que l'on court à essayer de gérer manuellement la documentation est de perdre la synchronisation de phase avec l'implémentation réelle. Cela peut arriver en cas d'oubli, de manque de rigueur ou tout simplement faute de temps car documenter une API est une tâche qui a un coût.

Il existe de nombreux outils sur le marché pour documenter une API qui, en important leurs packages et en les incluant dans les configurations des projets, vont être en mesure de générer la documentation en même temps que le déploiement de nouvelles versions de ces applications.

Bien qu'il existe de nombreuses solutions concurrentes, les 3 solutions les plus courantes sont à l'heure actuelle Swagger, RAML et Blueprint

Critères	Swagger	RAML	API Blueprint
Entreprise	Reverb	MuleSoft	Apiary
Sortie	07/2011	09/2013	04/2013
Communauté	Oui	Oui	Non

Approche design	Top-down et bottom-up	Top-down	Top-down
Outil de creation	Swagger.io	API Designer	Apiary.io
Ad-hoc testing	Swagger UI	API console	Apiary.io
Documentation	Supportée	Supportée	Supportée
Format	JSON	YAML	Markdown
Ressources	Oui	Oui	Oui
Methodes/Actions	Operations	Methodes	Actions
Paramètres(requetes, URL et Headers)	Oui	Oui	Oui
Code des status	Oui	Oui	Oui
Documentation	Oui	Oui	Oui
Nested resources	Non	OUI	Oui
Exemples d'utilisation	Oui	Oui	Oui
Versionning de l'API	Non	Oui	Oui
Parsing	Java, Js	Java	C++, C# et nodejs
Recherche google par nom	+ 6M	+70K	+ 807K

Toutes ces solutions sont disponibles en téléchargement sur GitHub

3.4. La gestion du trafic

Le trafic offre une très grande valeur commerciale à une API quand il s'agit de monétiser cette dernière. En effet, le fournisseur d'API peut proposer à ces utilisateurs un certain nombre d'appels d'API par jour / semaine / mois / illimités et des accès différents en fonction du budget (ou aussi gratuitement, par exemple aux développeurs) et de la période (heures creuses ou pleines). Une plateforme d'API management doit fournir un ensemble de fonctionnalités pour assurer la gestion du trafic.

Fixer le quota de consommation

Le quota de consommation définit le nombre d'appels d'API qu'une application est autorisée à effectuer sur un intervalle donné. Cette limitation est couramment appelée **Throttling**. Les appels dépassant la limite de quota peuvent être encore plus limités ou quasiment interrompus. Le quota autorisé pour une application dépend uniquement de la stratégie commerciale et du modèle de monétisation de l'API. Un objectif commun pour un quota est de diviser les développeurs en catégories, chacune ayant un quota différent et donc une relation différente avec l'API.

Exemple : les développeurs freelances qui s'inscrivent peuvent être autorisés à effectuer un petit nombre d'appels. Mais les développeurs payants (après leur identification) pourraient être autorisés à faire un nombre d'appels plus élevé.

Amorcer un arrêt rapide

L'arrêt rapide est très souvent une mesure prise lorsque la plateforme d'API management identifie une augmentation inattendue du trafic de l'API. Comme évoqué dans le point sur la sécurité, cette mesure aide à protéger les systèmes contre les attaques de déni de service mais pas seulement. Elle aide aussi à protéger les systèmes qui ne sont pas à la base conçus pour gérer une charge élevée

Exemple : Une petite entreprise commerciale durant la période de solde.

Limiter les utilisations

La limitation de l'utilisation fournit un mécanisme permettant de ralentir les appels vers une API. C'est une mesure qui aide à améliorer la performance globale d'un système et à réduire les impacts pendant les heures de pointe. Cela permet de contrecarrer certains problèmes de latence en s'assurant que l'infrastructure de l'API n'est pas ralentie par les volumes importants de requêtes provenant d'un certain groupe de clients ou d'applications.

Une sorte de limitation des utilisations consiste aussi à hiérarchiser les appels. En effet les clients prioritaires sont traités en premier. Cependant toutes les plates-formes d'API management ne prennent pas en charge cette fonctionnalité. Par conséquent, une autre approche ou conception peut être nécessaire pour mettre en œuvre la hiérarchisation du trafic.

3.5. Les métriques

Le trafic API passant par une plate-forme d'API management peut fournir aux entreprises de nombreuses informations utiles, qui peuvent aider à gérer efficacement un programme API d'entreprise. En analysant régulièrement ces données, une entreprise peut apporter des améliorations à son API et capitaliser ses investissements. Notamment en termes de popularité, de prévisionnel, d'amélioration, de chiffreage, d'aide à la prise de bonnes décisions

Les informations analysées

Le tableau de bord des métriques d'une solution d'API management permet d'obtenir des réponses selon les informations suivantes :

- Utilisation de l'API au fil du temps
- Pics et creux du trafic
- Les temps de réponses pour jauger la performance
- Les informations sur les utilisateurs principaux (développeurs et applications) et finaux (consommateurs du produit final)
- Le/les microservices de l'API qui génère le trafic maximal
- Comment l'API est utilisée suivant la zone géographique.
- Comment les investissements dans l'API sont rentabilisés.

Les métriques de trafic

Il s'agit de l'ensemble de données opérationnelles et métier collectées à partir du trafic API. Les mesures clés à analyser en provenance du trafic peuvent être classées comme suit :

Trafic au niveau d'une l'API surveillée	<ul style="list-style-type: none"> - Le total des API interagissant avec celle que l'on surveille et qui sont sur le même réseau - La répartition du trafic passant par le proxy - Le trafic par métier ou par actif technique - Les microservices les plus appelés - Les méthodes les plus appelées.
Le temps de réponse	<ul style="list-style-type: none"> - Le temps de réponse moyen de l'API - Le temps de réponse par service cible - La latence de traitement des requêtes et des réponses sur l'API Gateway
Le taux d'erreur	<ul style="list-style-type: none"> - La répartition des erreurs sur une durée - La répartition des erreurs par API - Le taux d'erreur par service cible - La répartition par code d'erreur (500, 502, 404, etc.)

Les métriques de popularité

Il s'agit de l'ensemble de données dont l'analyse permettrait de jauger la popularité de l'API auprès des développeurs. Cette démarche induit implicitement à une amélioration continue (maintenance) de la plateforme de développement et des bonnes pratiques de l'API du fait du succès ou non de cette dernière.

Les métriques suivantes sont particulièrement à surveiller pour améliorer la popularité :

L'implication des développeurs	<ul style="list-style-type: none"> - Le total des développeurs enregistrés avec le programme API - Le total des développeurs ayant des applications - Le total des développeurs actifs - Le trafic généré par développeur - Le trafic généré à partir d'applications de développeurs
Les classements dans le trafic	<ul style="list-style-type: none"> - Le trafic des meilleures applications - Le trafic des meilleurs développeurs - Le trafic des meilleurs produits
L'implication des utilisateurs finaux	<ul style="list-style-type: none"> - La répartition géographique du trafic API - Répartition par canal (mobile, desktop, tablette etc. - Répartition par systèmes d'exploitation - Répartition par navigateur

Dans certain cas, les données d'analyse par défaut capturées par la plate-forme d'API management à partir du trafic d'API peuvent ne pas être suffisantes pour fournir toutes les informations métier. On devrait alors capturer certaines données personnalisées de la charge utile du message et en tirer des informations d'analyse utiles. De nombreuses plates-formes de gestion d'API permettent d'extraire des données personnalisées à partir de messages et de les enregistrer dans leur base de données d'analyse. Ces données peuvent être extraites des en-têtes de message, des paramètres de requête ou des données utiles, et utilisées pour créer des rapports d'analyse personnalisés pertinents.

Exemple : Dans une API de réservation hôtelière, une entreprise peut être intéressée à connaître la répartition des réservations par ville ou hôtel. Ces informations peuvent aider les entreprises à prendre des mesures pour améliorer la satisfaction de leurs clients et développer leurs activités dans les différentes villes selon les conditions externes imposées (bord de mer, montagnes, camping, hiver, été, etc.)

Les analyses API fournissent des informations sur les mesures qui doivent être contrôlées régulièrement pour garantir le succès d'un programme API. Une baisse du trafic API peut signifier que l'intérêt de l'utilisateur s'éloigne de l'API, les raisons pouvant en être nombreuses. Cela pourrait être dû à la faible performance de l'API ou aux déplacements de clients vers des services fournis par d'autres concurrents sur le marché. Les propriétaires d'entreprise devraient examiner de manière critique les rapports d'analyse des API et réfléchir à la manière dont ils devraient alimenter et modifier leurs API pour les rendre plus compétitives et plus populaires sur le marché. La mise en œuvre appropriée des analyses d'API est la clé du succès du programme API d'une entreprise. La gestion des API est incomplète sans les informations appropriées fournies par les analyses API.

3.6. Le portail de développeur

La majorité des fournisseurs de solutions d'API management met en avant la qualité de leur portail développeur comme argument de vente. En effet, le succès d'une API se mesure à son niveau d'adoption par une communauté de développeurs. Les développeurs aimeraient connaître l'aptitude d'une API à implémenter leurs applications. Ainsi, en plus de parcourir la documentation de cette dernière, ils ont recours aux blogs et forums pour recueillir les avis honnêtes et chercher des éléments de réponses à leur question. En tant que fournisseur d'une API il est important de mettre à disposition un ensemble de fonctionnalités qui favoriserait une adoption plus rapide

L'enregistrement et la connexion du développeur utilisateur

La plateforme devrait permettre un processus d' enrôlement :

- Simple : un grand nombre d'informations peut empêcher le développeur de s'inscrire.
- Rapide : Il faut tenir compte de l'impatience que pourrait avoir un développeur à essayer les microservices qu'exposent les API, et par conséquent éviter un excès d'étapes intermédiaires entre l'inscription à la plateforme et son accès.
- Sécurisé : les données personnelles des développeurs sont des données personnelles standard et doivent être protégées comme telles. De plus, il faudrait aussi la possibilité d'avoir le droit à l'anonymat.
- Administré : en parallèle du portail du développeur, il devrait y avoir un portail administrateur afin de gérer les utilisateurs, notamment en ce qui concerne l'attribution des rôles pour contrôler les privilèges et les droits d'accès, la validation des inscriptions, les blocages de comptes.

Une console pour tester l'API

La mise à disposition d'une console pour tester une Api est un impératif du portail de développeur. Elle devrait permettre d'explorer les microservices et de soumettre du code pour les tester (notion de bac à sable). Elle devrait mettre à disposition la documentation, des exemples réels d'utilisation pour comprendre à facilement utiliser l'API. La console peut également inclure un guide de référence expliquant le vocabulaire commun, les formats de données, les meilleures pratiques, les codes de réponse HTTP courants et les messages d'erreur.

Cette partie à elle seule, peut être très déterminante pour assurer l'adoption des développeurs.

Enregistrement d'application et gestion des clés

Le portail devrait permettre d'enregistrer une application qui serait créé à partir de l'API ou qu'on souhaitera intégrer à l'API. L'approbation peut être automatique ou manuelle mais doit produire une clé d'API pour l'application enregistrée. Le cas d'une approbation manuelle implique qu'un administrateur a examiné et approuvé l'application et par la suite a généré la clé d'API. Un administrateur peut également révoquer des clés ou en régénérer de nouvelles.

Autres fonctionnalités intéressantes

L'enrôlement d'un utilisateur, la console de test et l'enregistrement d'une application constituent les prérequis d'un portail développeur. Cependant certaines fonctionnalités peuvent améliorer l'attractivité de l'utilisation de l'API :

- **Les forums et blogs** : Dans une stratégie marketing, il serait intéressant d'offrir à une communauté qui adopte une API, la possibilité de produire du contenu pour décrire leurs expériences. Une bonne rétroaction dans les forums et les blogs favorise une adoption plus rapide de l'API.
- **Les tableaux de bords** : Les développeurs souhaitent connaître et publier des informations statistiques sur leur applications. Un portail de développeur qui met à disposition un tableau de bord pour obtenir des métriques telles que le nombre d'utilisateurs consommant leurs applications, le nombre d'appels effectués par leurs applications vers l'API, les méthodes les plus utilisées et plus encore, est une bonne valeur ajoutée.
- **Un dispositif de support technique** : la mise en place d'une équipe ou des informations de support peut être très appréciée. Pour que cela soit fait efficacement, il faudrait mettre à disposition des contacts de développeurs en support (numéro de téléphone, adresse mail) à qui on pourrait poser des questions ou des problèmes liés à l'utilisation de l'API et qui sont particulièrement disponible pour cette tâche. En ce qui concerne les informations de support, la mise en place d'une page regroupant des FAQ, des avis ou des informations à venir devrait parfaitement convenir et devrait être régulièrement mise à jour.

3.7. Quelques solutions sur le marché

Le marché des solutions d'API management est en voie de consolidation, si l'on considère des rachats significatifs qui ont eu lieu ces dernières années : Google ayant racheté Apigee, Tibco ayant racheté Mashery, CA Technology s'étant offert Layer7 et Axway ayant rajouté Vordel à son catalogue.

Hormis les différents mouvements d'acquisition, la couverture fonctionnelle de ces solutions tend à s'homogénéiser à tel point qu'on pourrait parler d'uniformisation de l'offre des solutions d'API. Elles proposent toutes les solutions qui constituent la base permettant de piloter et gérer des APIs. De ce fait le choix de l'une d'entre elles est relativement difficile dans la mesure où les services proposés et les messages véhiculés sont à peu près similaires.

Le cabinet de conseil *IT Central Station*, qui effectue des sondages auprès de professionnels de l'IT, afin d'aider à la prise de décision concernant différentes acquisitions digitales, a mené une enquête auprès de 365 192 professionnels et a pu établir le guide des revues des acheteurs de solutions d'API management en septembre 2019.


Ci-dessous le répertoire des différents fournisseurs du marché :

Amazon	Amazon API Gateway	PokitDok	PokitDok
Axway	Axway API Management Plus	Red Hat	3scale API Management
CA Technologies	CA API Management	Rogue Wave	Akana API Management
Cloud Elements	Cloud Elements	Seeburger	SEEBURGER BIS
Google	Apigee	Sikka Software	Sikka Software
IBM	IBM API Connect	SmartBear	SwaggerHub
Kong	Kong Enterprise	Software AG	webMethods API Management
Microshare.io	Microshare.io	Software AG	CentraSite
Microsoft	Microsoft Azure API Management	Software AG	Software AG webMethods Integration Cloud
MuleSoft	Mulesoft Anypoint API Manager	Talena	Talena
OpenLegacy	OpenLegacy	TIBCO	TIBCO Mashery API Management
Oracle	Oracle API Management	Torry Harris Business Solutions	DigitMarket
Oracle	Aplary	Tyk	Tyk
Oracle	Oracle API Platform Cloud Service	WSO2	WSO2 API Manager
Oracle	Oracle Communications Services Gatekeeper		

Source : API Management Buyer's Guide and Reviews September 2019

Suites aux revues et comparaisons, des notes ont été déduites et le classement suivant des 10 premières solutions a été établi :

Chart Key



1 Apigee



2 CA API Management



3 SEEBURGER BIS



4 Mulesoft Anypoint API Manager



5 IBM API Connect



6 Microsoft Azure API Management



7 Amazon API Gateway



8 Apiary



9 Oracle API Platform Cloud Service



10 3scale API Management



Source : API Management Buyer's Guide and Reviews September 2019

Suite à ces statistiques, il est intéressant de remarquer, que les 5 solutions suivantes ont été fortement comparées aux autres produits, suscitant ainsi l'intérêt de la majorité :

1 – Apigee

2 - MuleSoft AnyPoint API Manager

3 - Microsoft Azure API management

4 - IBM API Connect

5 – Amazon API Gateway

Intéressons-nous de plus près aux 3 premières solutions :

Apigee

Google Apigee, est une plate-forme de gestion des API qui permet aux entreprises de sécuriser, de faire évoluer, de gérer et d'analyser leurs activités numériques et de développer les programmes d'API pour répondre à la demande croissante. Elle permet également aux entreprises de concevoir et de construire des API qui partagent en toute sécurité leurs services et leurs données.

Les fonctionnalités clés de la plate-forme de gestion des APIs Apigee incluent :

- La Sécurité : protégez les API, les messages et les backends avec des stratégies configurables telles que OAuth, la vérification des clés d'API, la protection contre les menaces XML / JSON, le contrôle d'accès.
- L'API Gateway : sécurise et gère le trafic entre les clients et les applications principales, ainsi qu'entre les API d'une société et les développeurs, les clients, les partenaires et les employés qui utilisent les API. *
- Un Portail des développeurs : attire et engage les développeurs d'applications pour leur permettre de découvrir, d'explorer, d'acheter (ou d'en tirer profit), de tester des API et de s'inscrire pour accéder aux API et les utiliser.
- Gestion du cycle de vie des API : gère le processus de conception, de développement, de publication, de déploiement et de version des API.

Quelques clients de la plateforme : Adobe, AT&T, Citrix, Dell, Equifax, HCSC, Orange, Pearson, etc.

Les axes d'amélioration selon l'avis des clients :

- Mauvais support des webhooks(fonctions de rappel http définies par l'utilisateur, qui récupère et stockent les données issues d'un événement, en général externe à l'application)
- La configuration initiale de gestion de version par URI n'est pas triviale
- Le modèle de support technique pour l'OPDK (kit de déploiement sur site) n'est pas assez mature

MuleSoft AnyPoint API Manager

API Manager est un composant de la plate-forme Anypoint de MuleSoft pour la conception, la construction, la gestion et la publication d'API. Anypoint Platform utilise Mule comme moteur d'exécution principal. On peut utiliser API Manager sur un cloud public, tel que CloudHub, un cloud privé ou un système hybride. Le déploiement Ahybrid est une API déployée sur un serveur privé mais dont les métadonnées sont traitées dans le cloud public.

Les fonctionnalités de la plateforme Mulesoft AnyPoint incluent :

- La gestion et adaptation centralisées des programmes d'APIs (sécurisation des APIs et microservices, portails personnalisables, gestion des accès de façon native ou intégrée) l'intégration, le B2B/EDI sur une seule plateforme
- La construction rapide des projets en réutilisant les ressources de sa propre entreprise et de l'écosystème MuleSoft
- La connexion aux pipelines CI/CD grâce à la prise en charge de Maven et Jenkins
- LE développement sur des plateforme sécurisée conforme aux normes ISO 27001, SOC 1, SOC 2, PCI DSS et RGPD
- La tokenisation des données sensibles
- La disponibilité des applications à 99,99%, les métriques, les alertes et tableaux de bords, les tests
- Le passage du cloud au multi-cloud

Quelques clients de la plateforme : Coca-Cola, Splunk, Citrix, National Post, Justice System, etc.

Les axes d'amélioration selon l'avis des clients :

- Aucune information n'est diffusée en ce qui concerne la fusion avec Salesforce, les professionnels se posent des questions
- Ne dispose pas de produit BPM/Workflow, BAM ou de gestion d'identités
- Les interfaces utilisateurs ne sont pas user-friendly par rapport à la concurrence
- Le cadre de gestion des transactions n'est pas directement fourni
- Le coût de la licence qui se trouve entre 300 000\$-400 000\$.

Microsoft Azure API Management

Microsoft Azure API Management est une solution permettant à une organisation de gérer son programme d'API. Avec la gestion des API, les organisations peuvent publier des services Web sous forme d'API fiables, sécurisées et à grande échelle, utiliser la gestion des API pour gérer la consommation de partenaires internes, de partenaires et de développeurs, tout en tirant parti des informations commerciales et opérationnelles du portail.

Les principales fonctionnalités proposées par Azure API Management sont :

- Création d'API Gateway et d'un portail de développement
- Gestion des APIs dans un seul emplacement
- Sécurisation et optimisation des APIs, identité
- Documentation
- Connexions aux services principaux en tout lieu
- Tableau de bord personnalisé
- Outils de développements, mise en réseau, stockage
- Métriques, analyses, AI et machine learning
- Intégration et migration

Quelques clients de la plateforme : adnymics GmbH, LG CNS, AccueWeather, Toyota, Medplast...

Les axes d'amélioration selon l'avis des clients :

- Console de développement pas assez intuitive
- La console de développement a besoin d'être améliorée pour les tests
- La gestion de la sécurité des API n'est pas assez fine.

Comme montré dans le répertoire des solutions d'API management, il existe un large panel de solution. La finalité de ces solutions est d'« APIser » un système, mais afin de faciliter la prise de décision, il peut s'avérer important de bien étudier ce dernier au préalable:

- Designer les APIs avec des documentations claires
- Faire des services modulaires
- Définir sa politique de gestion de version des services
- Savoir exactement quels traitements exposer ou pas
- Avoir des métriques

Avoir une idée de ses éléments devrait non seulement aider à la prise de décision mais aussi faire en sorte que l'implémentation de cette nouvelle brique au sein de l'architecture se passe sans difficultés bloquante avec une bonne gestion des couts d'utilisations.

4. Etude du cas CoMove

Présentation

CoMove est une idée d'application de covoiturage urbain dont l'idée est la suivante :

Lors d'un déplacement urbain ou péri-urbain l'automobiliste ouvert au covoiturage rentre dans l'application sa destination. Il dispose alors des fonctions classiques d'un GPS pour l'y guider.

- Le piéton qui souhaite « covoiturer » descend dans la rue et rentre dans l'application sa destination.
- Un système informatique va en permanence comparer les trajets prévus par les automobilistes et les piétons. Il va repérer si un automobiliste pourrait amener un piéton à proximité de sa destination, moyennant un détour limité pour aller le chercher. Si c'est le cas, il va proposer à l'automobiliste de prendre en charge le piéton en indiquant la nature du détour (temps et distance estimés).
- L'automobiliste peut accepter la prise en charge et se faire guider vers le piéton. Ce dernier recevra alors confirmation qu'un automobiliste vient à sa rencontre avec une description de son véhicule.
- Le système détecte que le piéton a été pris en charge en comparant les positions GPS des deux covoitureurs et garde trace du parcours effectué en commun afin de calculer le coût du partage (sur la base des forfaits fiscaux kilométriques)
- En fin de mois, le système organise le transfert d'argent entre les deux covoitureurs en prélevant une commission.

Principes du logiciel

Application Conducteur :

L'application Conducteur fonctionnera sur le principe suivant :

- Le conducteur crée un compte avec ses informations personnelles, la description de son véhicule et ses informations bancaires de manière à être rémunéré.

- Lorsqu'il démarre un trajet sur lequel il accepte de prendre des piétons, il renseigne sa destination dans l'application et le nombre de places disponibles. Via une fonction GPS, celle-ci lui indique le trajet préconisé et les temps estimé d'arrivée à destination.
- Lorsque le système estime que l'automobiliste peut prendre un piéton, il alerte le conducteur en indiquant le profil du piéton et la nature du détour (en temps et distance).
- Le conducteur dispose alors de 30 secondes pour accepter de prendre en charge le piéton en cliquant sur l'application. Au-delà de ce délai, la proposition disparaît (et le système part à la recherche d'un autre conducteur).
- Si l'automobiliste accepte la prise en charge, l'application le guide alors vers le piéton.
- Lorsque l'application constate que le mobile du piéton se déplace de manière identique au véhicule il en déduit que la course a commencé. A contrario, quand l'application constate que les deux mobiles ne se déplacent plus de la même manière il en déduit que la course est terminée (un mode manuel permet aussi de signaler la fin d'une course).
- A la fin de la course, le conducteur se voit créditer une rémunération correspondant aux frais de partage de la course. Il peut également évaluer le piéton.

Application Piéton :

L'application Piéton fonctionnera sur le principe suivant :

- Dans la rue, le piéton démarre l'application et renseigne sa destination.
- Lorsqu'un automobiliste accepte de prendre en charge le piéton ce dernier reçoit une confirmation sur son mobile que quelqu'un va venir le chercher. Cette confirmation s'accompagne d'une description du profil du conducteur et de son véhicule.
- Après être monté dans le véhicule, en comparant le déplacement des deux mobiles, le système déclare que la course a commencé.
- Lorsque le système constate que les déplacements des mobiles sont différents, il en déduit que la course est terminée.
- Il débite alors le compte du piéton et crédite celui de l'automobiliste, sur la base d'un partage des frais kilométriques (en suivant le barème fiscal en vigueur), moyennant une commission pour la société CoMove.
- Le piéton peut aussi évaluer son conducteur.

Fonctions principales du système :

Le système doit :

- Suivre en permanence les positions des automobilistes et des piétons déclarés.
 - Identifier l'automobiliste le plus pertinent pour chaque piéton. Un automobiliste sera jugé pertinent si :
 - o le temps de prise en charge du piéton est faible,
 - o le détour nécessaire pour prendre en charge le piéton est limité,
 - o le trajet de l'automobiliste permet de déposer le piéton à une distance raisonnable de sa destination
 - Identifier automatiquement les trajets effectués en co-voiturage, calculer leur distance et établir une redevance que le piéton devra verser à l'automobiliste, sur la base d'un partage de frais.
 - Gérer de manière automatique les transferts financiers entre utilisateurs à chaque fin de mois
- Le système doit aussi pouvoir générer des rapports individuels (pour les automobilistes et les piétons) et des rapports généraux sur l'usage du covoiturage (analyse de distances, temps passé, temps d'attente, taux d'occupation, etc. par heure de la journée, jour de la semaine, quartiers d'origine et destination, etc.) permettant à la société CoMove de mesurer sa contribution écologique.

Exigences non fonctionnelles :

Le système doit fonctionner H24 7/7 avec une très forte disponibilité.

Il doit être réactif en suivant le déplacement des véhicules toutes les 5 secondes et en proposant un « match » entre conducteur et piéton en 5 secondes (s'il existe un « match » évidemment).

Il doit supporter la charge suivante :

- Utilisation de l'application Conducteur sur 10% des déplacements urbains
- Utilisation de l'application Piéton par un nombre double de celui des conducteurs

Cette application devra s'intégrer à celles du groupe Ovalie qui gère des réseaux de transport (bus, métro, trams) dans de nombreuses agglomérations.

Le groupe Ovalie est dans une démarche de rénovation digitale.

Le système sera déployé sur l'aire urbaine de Toulouse et, si le système fonctionne, il sera étendu ensuite aux grandes villes françaises, puis mondiales.

Pourquoi faire des microservices

Bien qu'il s'agisse d'un cas d'utilisation permettant de démontrer par l'exemple la mise en place d'une architecture de microservices, il est important de faire remonter les points permettant de justifier qu'on aurait intérêt à se tourner vers cette architecture.

A la lecture des exigences de ce projet nous pouvons remonter quelques éléments et poser des réflexions :

Exigences	Réflexions
Le système devra être porté par 2 applications mobiles, celle du conducteur et du piéton	<ul style="list-style-type: none">- Approche Mobile-First- Api Gateway- Sécurité
Le système doit être hautement disponible à raison de 7j/7, 24H/24	<ul style="list-style-type: none">- Tolérance aux pannes- Disponibilité
Le système doit être capable de supporter la montée en charge	<ul style="list-style-type: none">- Scalabilité horizontale- Infrastructure cloud pour serveurs à la demande
Le système nécessite l'utilisation de fonctionnalités externes telles que le GPS, la banque et une fonctionnalité de notation	<ul style="list-style-type: none">- Recherche d'API publiques/ privées pour utilisation de services tiers
Le système doit remonter un ensemble de métriques (analyse de distances, temps passé, temps d'attente, taux d'occupation etc. par heure/jour/semaines/quartiers d'origine et destination, etc.) permettant de mesurer la contribution écologique de la société CoMove	<ul style="list-style-type: none">- Mise en place d'une solution de traçage de données directement dans le code- Utilisation de service de métrique (possibilité de mettre en place une solution d'API management)
Le système doit être à jour dans ses technologies car il sera intégré au système Ovalie qui est en pleine rénovation digitale	<ul style="list-style-type: none">- Microservices, petits et modulaires facilitant l'ajout de nouvelles fonctionnalités- APIs facilitant l'intégration à d'autres systèmes
Le système doit pouvoir exposer des services	<ul style="list-style-type: none">- APIs facilitant l'intégration à d'autres

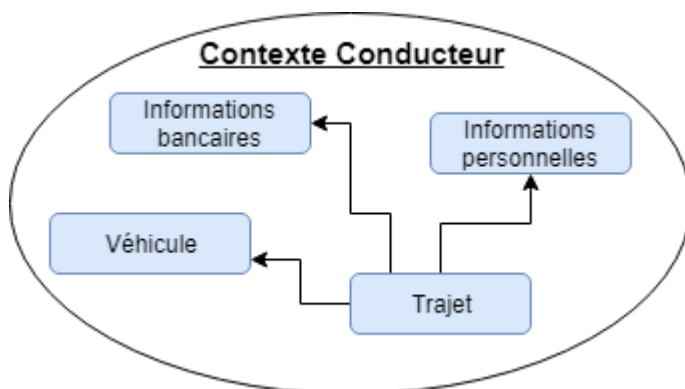
car il sera intégré à une nouvelle offre de service avec Ovalie	systèmes <ul style="list-style-type: none"> - Outil d'API management pour gérer l'intégration avec d'autres APIs
Il faudra prévoir que l'application soit hautement distribuée au-delà de l'agglomération de Toulouse	<ul style="list-style-type: none"> - Nécessité de concevoir des services petit, modulaires, portés par le cloud avec de faciliter la distribution dès le départ.

Conception

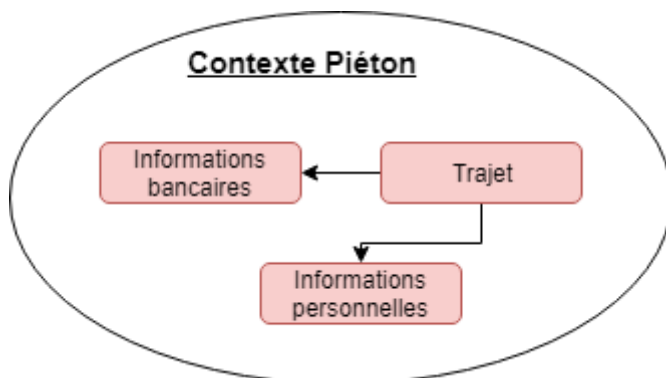
Comme présenté dans la phase de conception de ce document nous allons implémenter des techniques de Domain-Driven-Design.

Découpons l'application en rassemblant logiquement des informations liées à des domaines définis, nous devrions à la fin de cet exercice avoir une liste de tous les contextes bornés du système et un aperçu des premières APIs et équipes de développement

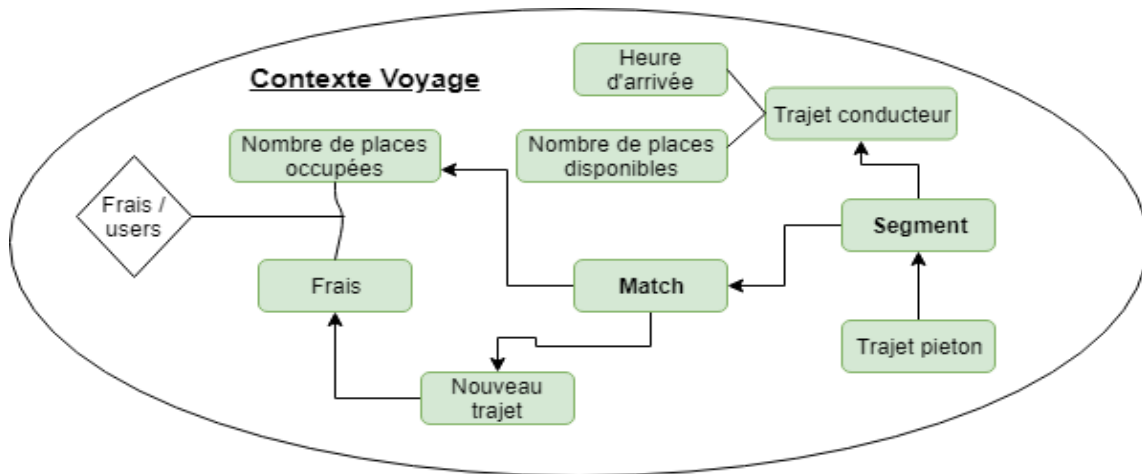
Contexte Conducteur : Ce contexte prend en charge des données liées à un conducteur, son véhicule ses informations personnelles et son trajet



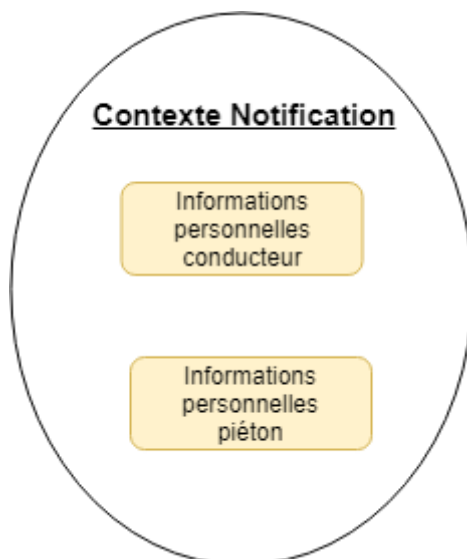
Contexte Piéton : Ce contexte prend en charge les données liées à un piéton ses informations personnelles et des informations liées à son trajet



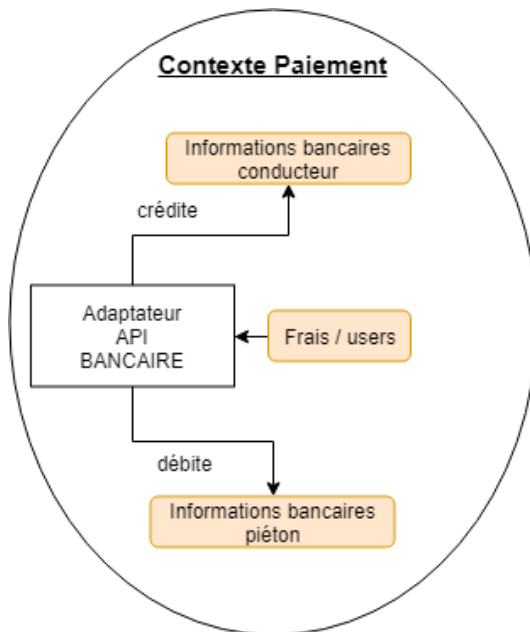
Contexte Voyage : ce contexte englobe le traitement principal de calcul du voyage en fonction des trajets du conducteur et du piéton. Il permet d'implémenter les algorithmes de segment pour définir la probabilité de prise en charge et l'algorithme de match qui permet de valider la prise en charge et définir le nouvel itinéraire du conducteur. Il permet également de déduire les frais à partager quant au nouveau trajet.



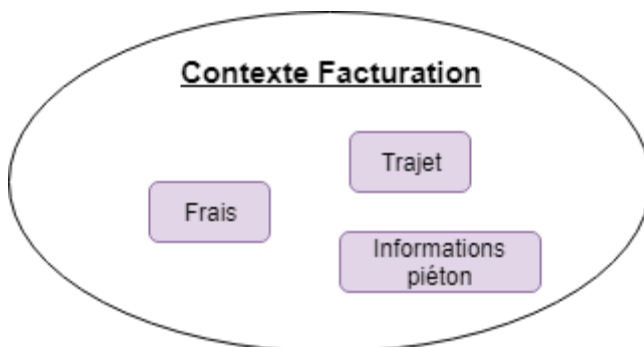
Contexte de Notification : Ce contexte se base sur les informations personnelles du piéton et du conducteur afin d'effectuer l'envoi des différents types de notifications nécessaires pour une bonne communication entre les deux utilisateurs. Exemple : confirmation de prise en charge, demande de regroupement au point de rendez-vous, connaissance du conducteur et informations sur le véhicule etc.



Contexte Paiement : le contexte de paiement permet en fonction des frais générés par le nouveau trajet et des informations bancaires du piéton et du conducteur de réaliser les différentes transactions de débit/crédit de l'un vers l'autre.

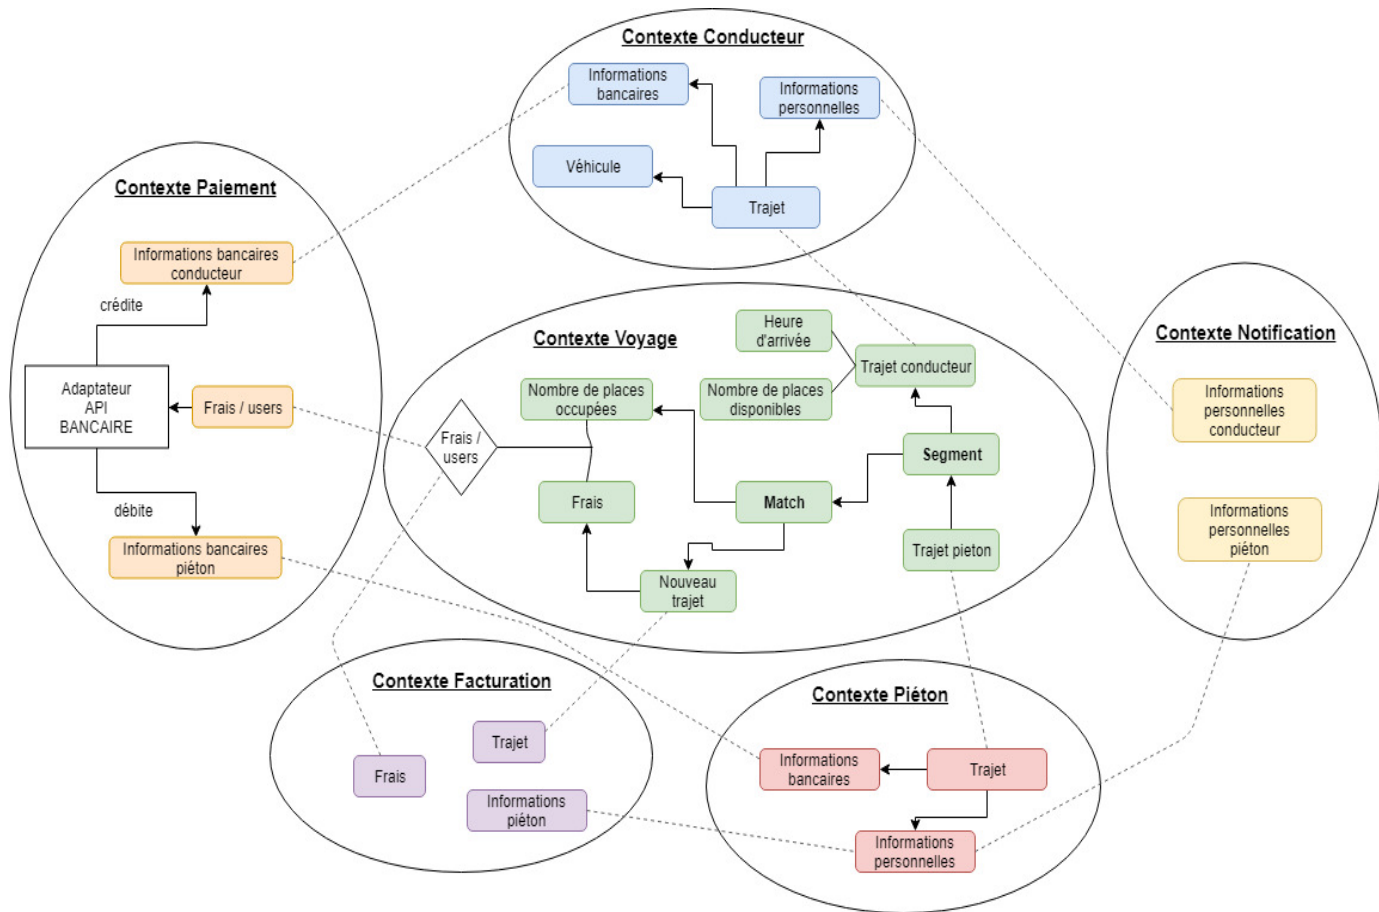


Contexte Facturation : Ce contexte permet de gérer un ensemble de données permettant de produire la facture à envoyer par mail au piéton

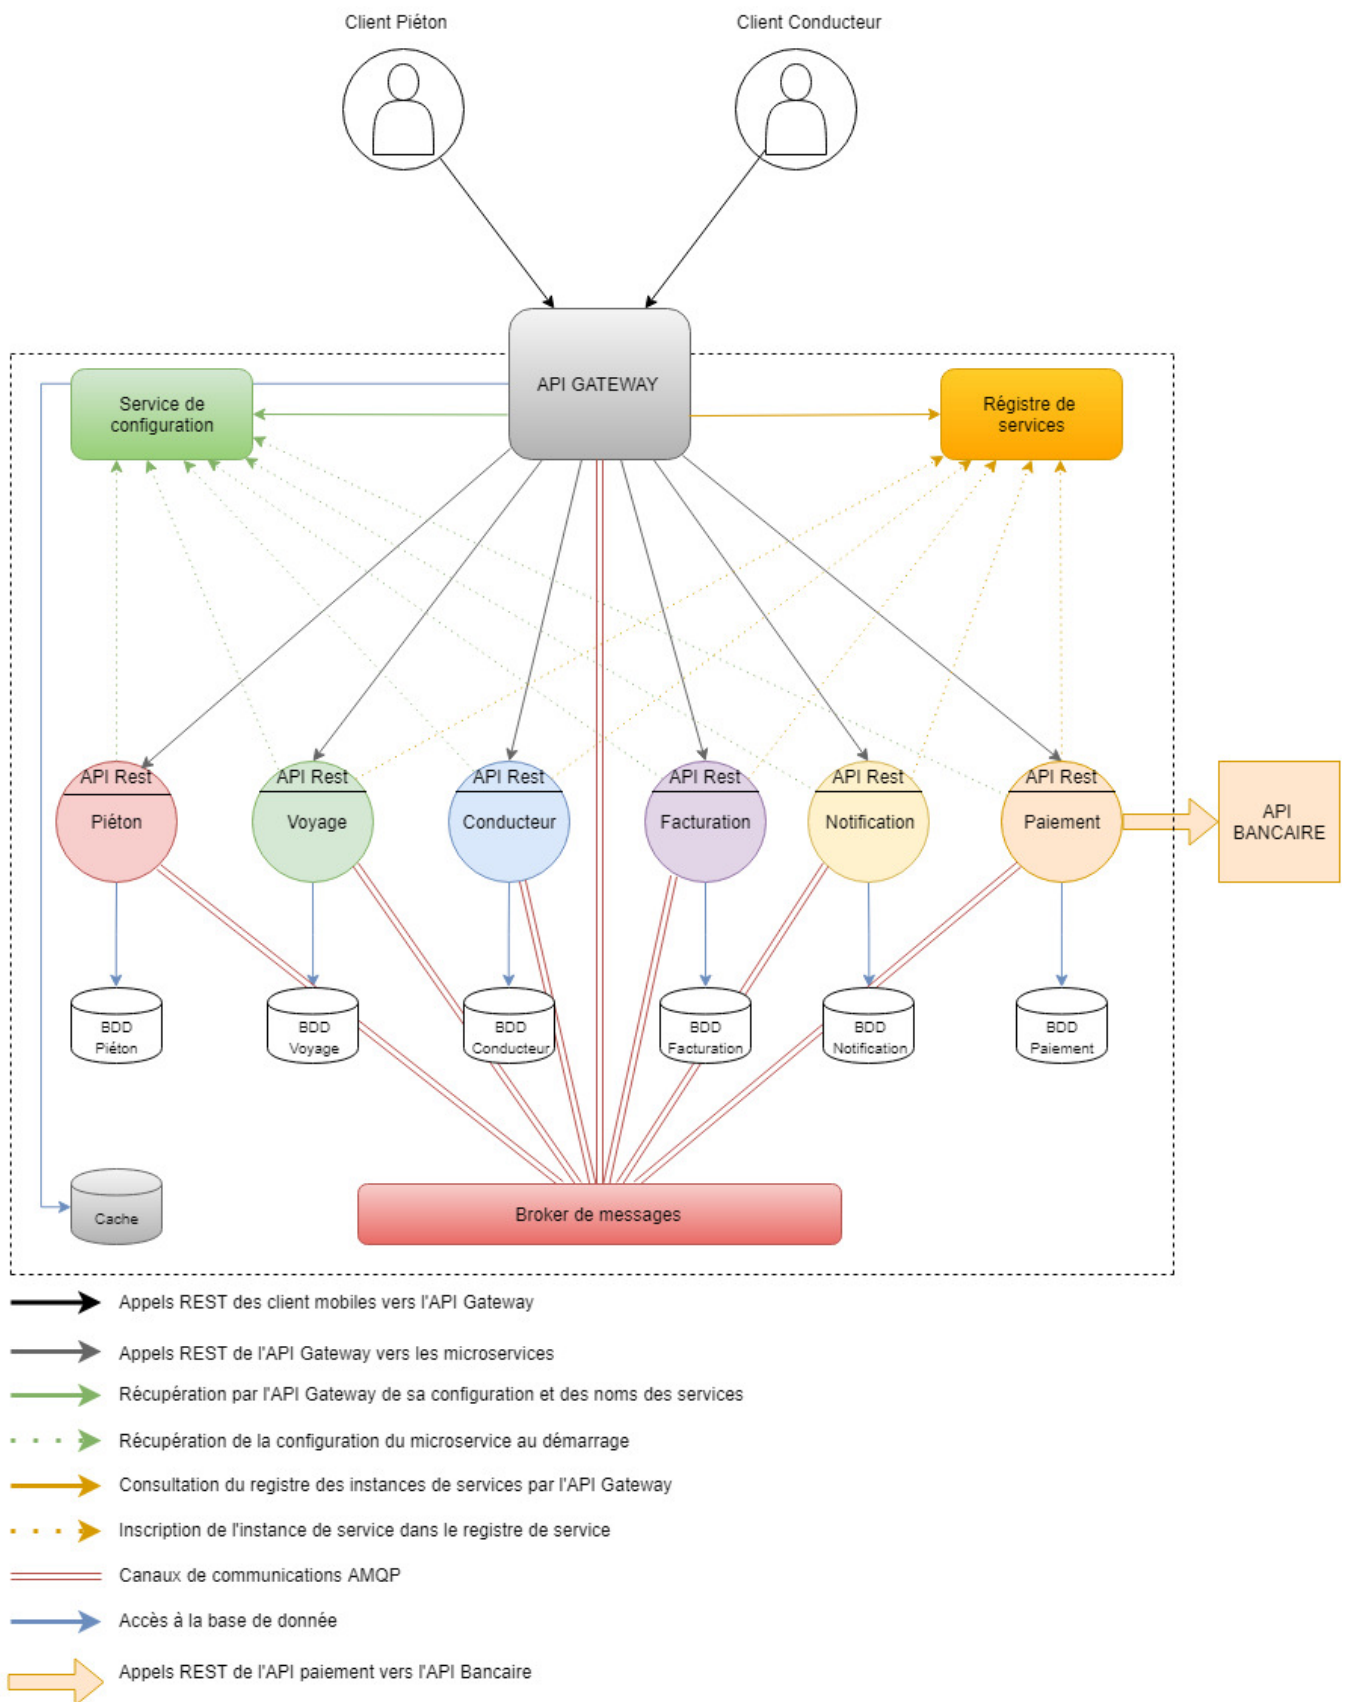


La carte de contextes

Maintenant que nous avons défini l'ensemble des contextes bornés de l'application, il est primordial de faire une cartographie de ces contextes pour avoir une vision d'ensemble des communications entre ces derniers et entre les différentes équipes qui en ont la prise en charge.

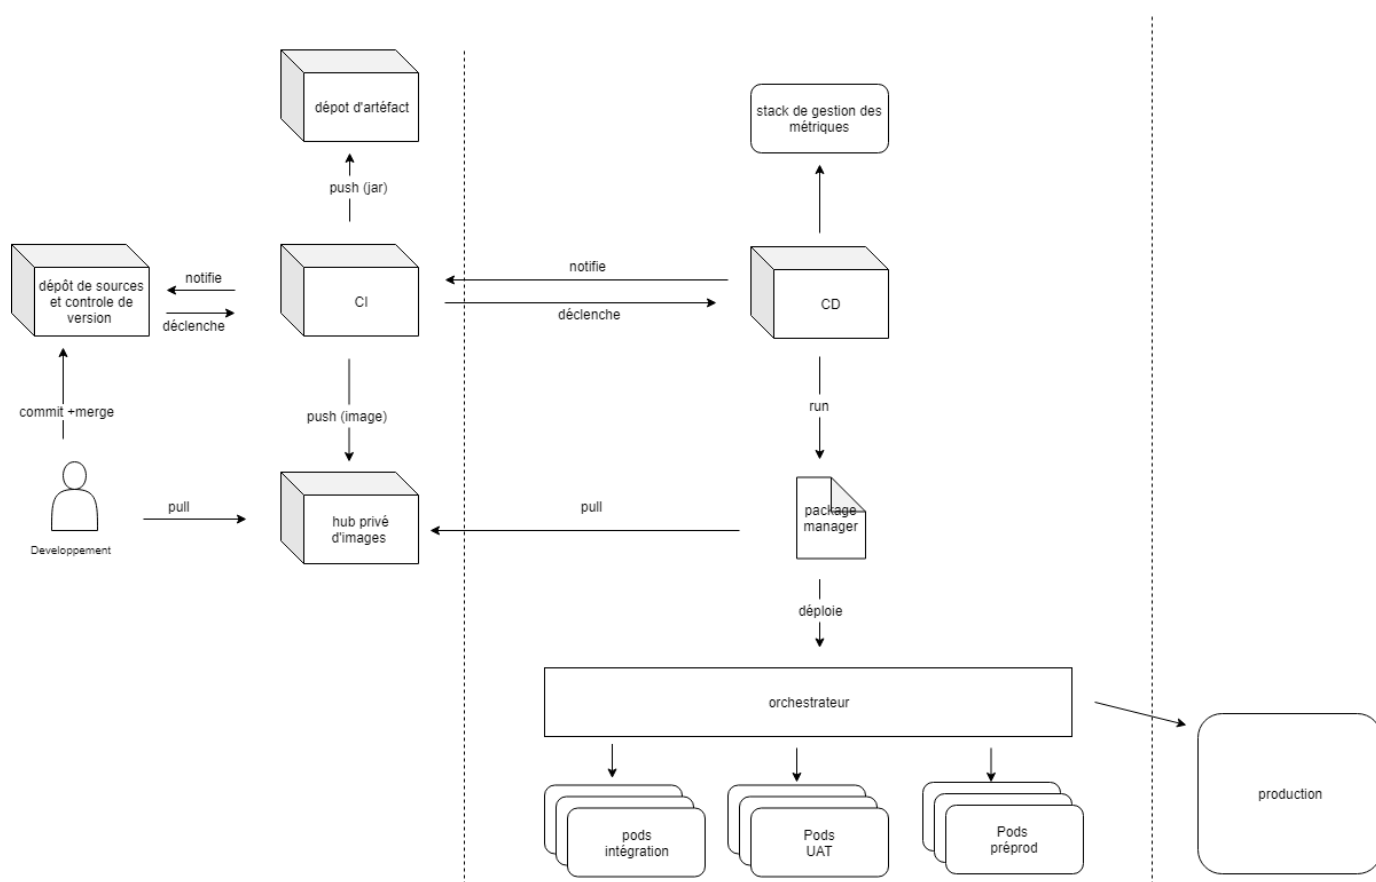


Architecture cible d'intégration :



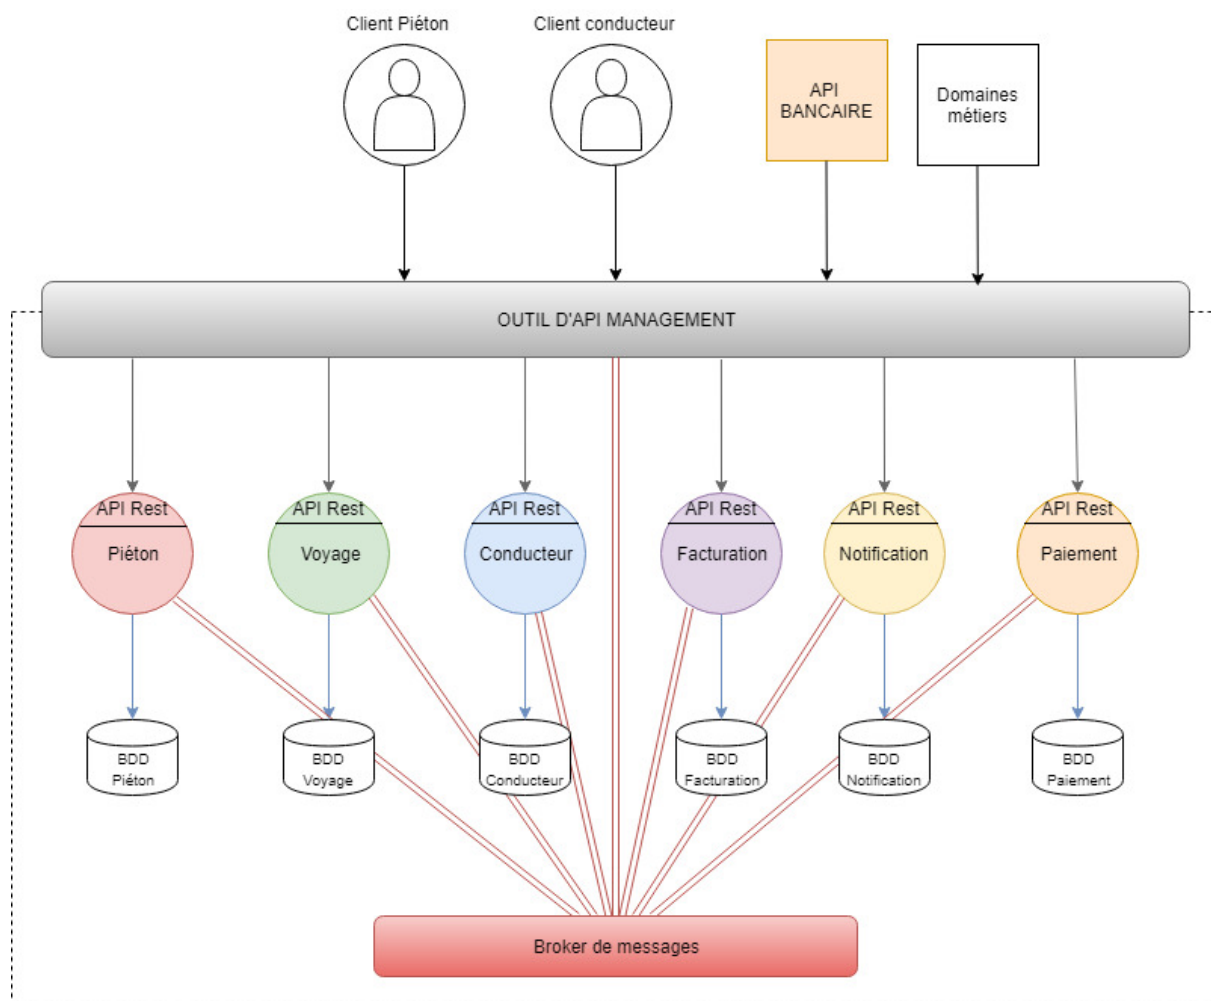
Proposition d'une stack technologique	
Applications mobiles	IOS, Android
Applications web	Angular 7+
Microservices	Spring Boot 2, .NET
Service de Configuration	Spring cloud – config server
Registre de service	Cloud Discovery – Eureka server
API Gateway	NGINX plus
Cache	Redis
Broker de message	Rabbit MQ
Base de données	MongoDB, Cassandra

Architecture cible de déploiement :



Proposition d'une stack technologique	
Dépôt de sources et contrôleur de version	Bitbucket
CI / CD	Jenkins
Hub privé d'image Docker	Nexus Sonatype
Dépôt d'artéfact	JFrog Artifactory
Package manager	HLEM
Orchestrateur d'images	Kubernetes
Stack de gestion des métriques	ELK(Logstack, Kibana,Elastique search)

Architecture centrée autour d'un outil d'API management :



Benchmark de solutions :

Solution d'API Management	Interessant pour	Taille de l'entreprise	Livraison	Plan de facturation par version	Portail de développeur
Apigee	Des outils de monétisation	PME, PMI	Proxy, Agent, Hybride	Evaluation : gratuite, Equipe : 500€/mois, Entreprise : 2500€/mois	Oui
3Scale	Portail des developper	Startups, PME, PMI	Proxy, Agent, Hybride	Pro : 750€/mois, Entreprise : Devis sur mesure	Oui
IBM API Management	User-friendly	Entreprise (par taille)	Proxy, Agent	Lite : gratuite, Entreprise : 100€/ 100k d'appels API,	Oui

				Autres plans en fonctions de la taille de l'entreprise	
Akana	Les outils de gestion du cycle de vie	Startup, Entreprise	Proxy, Agent, Hybride	Essai : gratuit, Startup : 4000€/mois, Entreprise : Devis sur mesure	Oui
Kong	API Gateway open source	Startup, PME, PMI, Entreprise	Proxy	Gratuite	Non

5. La sécurité

De base, les systèmes à grande échelle qui exposent les données sont sujet aux failles de sécurité. Dans une ère comme celle -ci, où les clients et les entreprises ont conscience de la valeur économique des données, il est indispensable de ne pas négliger le volet de la sécurité lors de la conception et l'implémentation des systèmes. Il est nécessaire de réfléchir à une stratégie de protection des données lorsqu'elles transitent sur un réseau, ainsi que de la protection de ce réseau lui-même.

Le défi que représente les microservices en termes de sécurité vient de leur surface d'attaque qui est bien plus grande que celle des applications monolithiques. En effet, dans une architecture de microservices, il ne s'agit plus d'assurer la protection d'une ou deux applications monolithiques, mais plutôt de celles de plusieurs dizaines de petits services qui interagissent les uns avec les autres de plusieurs manières. Sécuriser des microservices revient à les protéger des agressions extérieures mais aussi de mauvais usages internes :

- Les accès aux microservices doivent être authentifiés et autorisés
- Les communications entre microservices doivent être sécurisées
- Les restrictions doivent être mise en place entre les services et les utilisateurs
- Les opérations doivent être enregistrée pour assurer la traçabilité

Ces actions correctement suivies devraient permettre de constituer un bon niveau de sécurité. Voyons un peu plus en détails

5.1. L'authentification et l'autorisation

L'authentification et l'autorisation sont des concepts fondamentaux pour les personnes et les éléments qui interagissent avec un système.

L'authentification est un processus par lequel on confirme l'identité d'une tierce partie (login/mot de passe, clé d'accès, jeton de sécurité, empreinte digitale, etc.) pour lui permettre d'accéder à une information.

L'autorisation est un mécanisme de mappage de l'authentié à l'ensemble des actions qu'il est autorisé à effectuer sur les informations (lecture, écriture, etc.) en fonction de ses informations remontée par l'authentification.

Une approche commune en matière d'authentification et d'autorisation consiste à utiliser une **solution d'authentification unique (SSO)** auprès d'un **fournisseur d'identité** qui valide les informations d'accès aux données et l'accès aux ressources. Le SAML est l'implémentation en vigueur dans l'espace d'entreprise et OpenID Connect dans le domaine public, mais ce dernier gagne en popularité notamment grâce à des travaux importants sur le protocole de sécurité OAuth.

Un fournisseur d'identité peut être un système hébergé en externe ou au sein de l'entreprise. Par exemple, Google et Facebook sont des fournisseurs d'identité OpenID Connect et pour les entreprises il est courant d'avoir une solution telle que Keycloak qui est liée à un service d'annuaire comme le protocole LDAP ou Active Directory. Ces systèmes permettent de stocker des informations sur les utilisateurs et leurs rôles dans l'organisation.

SAML est un standard basé sur SOAP et est connu pour être assez complexe à utiliser malgré les bibliothèques et les outils disponibles pour le prendre en charge. OpenID Connect est un standard qui a émergé comme une implémentation spécifique d'OAuth 2.0, basé sur la façon dont Google et d'autres géants du Web traitent l'authentification unique. Ce dernier utilise les appels REST plébiscité par les architectures de microservices et est de plus en plus populaire au sein des entreprises en raison de sa facilité d'utilisation qui a été continuellement améliorée.

- **Focus sur OpenID Connect (OIDC) :**

Bien qu'une entreprise souhaitant garder davantage de contrôle et de visibilité sur le mode de l'emplacement de ses données partirait sur un fournisseur d'identité interne, il est important de maintenir une veille de sur l'avancée des technologies des fournisseurs externes tels que Google qui implémente de l'OpenID Connect.

OIDC est une couche d'authentification basée sur le protocole OAuth 2.0, qui autorise les clients à vérifier l'identité d'une partie tierce en se basant sur l'autorisation fournie par un serveur d'autorisation en suivant le processus d'obtention d'informations du profil de l'utilisateur final. Il spécifie une interface HTTP RESTful en utilisant le JSON comme format de données, ce qui lui permet notamment d'échanger des informations avec un vaste panel de clients web, mobiles et utilisant des Framework Javascript.

OAuth2 (voir : <http://tools.ietf.org/html/rfc6749>) est un protocole qui permet à des applications tierces d'obtenir un accès limité à un service via HTTP à partir d'une autorisation du détenteur des ressources. Entre d'autres termes, si un client (applications, site internet...) demande accès à des ressources, il doit obtenir des autorisations ou s'identifier à la solution qui héberge les ressources.

OAuth2 définit 4 rôles principaux :

- Le détenteur des données
- Le serveur de ressources
- Le client

- Le serveur d'Autorisation

On distingue 2 types de tokens :

- **L'Access Token** : il donne directement accès aux ressources
- **Le Refresh Token** : permet de lancer la demande d'un Access Token quand ce dernier est expiré.

Un Token peut être envoyé de plusieurs façon au serveur de ressource :

- Directement dans une requête GET ou POST (non recommandé)
- En entête des requêtes (Headers- Authorization)

Selon l'emplacement et la nature des données, peut choisir parmi 4 types d'autorisations :

- **L'autorisation via un code** : permet d'obtenir les Access et Refresh Tokens pour accéder directement à la ressource. Le client est un serveur web.
- **L'autorisation implicite** : Permet d'obtenir un Access Token mais pas le Refresh Token. Le client est une application web
- **L'autorisation via un mot de passe** : les identifiants sont envoyés au client et au serveur d'autorisation
- **L'autorisation serveur à serveur** : Quand le client est lui-même le détenteur des ressources il se flague pour ne pas s'empêcher lui-même d'accéder aux données.

Il est à noter que OAuth2 correspond à **99%** des exigences et typologies du client car il permet, contrairement à OAuth1, de gérer l'authentification et l'habilitation des ressources par tout type d'application (native mobile, native tablette, application javascript, application de type serveur, batch/back-office, ...). De ce fait, il est le standard par excellence de sécurisation des API.

NB : Il faut systématiquement utiliser le protocole **HTTPS** pour l'utiliser.

5.2. La sécurité entre les services

La plupart des organisations assurent la sécurité sur le périmètre de leur réseau en contrôlant les accès aux ressources par les utilisateurs et supposent par conséquent qu'il n'y a pas de nécessité à implémenter de la sécurité entre les services quand ces derniers communiquent entre eux à l'intérieur d'un réseau. C'est sans compter sur le fait que les pirates informatiques opèrent généralement en interceptant, lisant et modifiant des données et en s'insérant dans un réseau pour commettre des impairs. Selon le niveau de sensibilité des données, il est nécessaire de pousser plus loin le modèle de confiance au-delà du réseau en implémentant des modèles de sécurité à l'échelle du service.

• L'authentification HTTPS basique

Via HTTP, les données de connexion ne sont pas envoyées de manière sécurisée vers les serveurs d'authentification et transitent par toutes les parties intermédiaires qui peuvent consulter ces informations dans les entêtes des requêtes.

L'authentification HTTPS qui est la combinaison du HTTP avec un couche de chiffrement telle que **SSL** (Secure Socket Layer) ou **TLS** (Transport Layer Security) devient un niveau de sécurité standard permettant à un client d'obtenir la garantie que le serveur avec lequel il communique est bien celui avec qui il est supposé établir cette communication. Les services intermédiaires ne pourraient à priori

pas lire les données d'authentification en entête et juste router les requêtes vers leur destinataire final.

Cependant le serveur doit gérer ses propres certificats SSL, ce qui a tendance à présenter un fardeau administratif et opérationnel supplémentaire avec la génération et le partage des certificats.

- **Les certificats clients**

Une approche pour confirmer l'identité d'un client consiste à utiliser les fonctionnalités de TLS (qui succède à SSL) sous forme de certificats de client. Ainsi chaque client dispose d'un certificat (X.509) permettant d'établir un lien avec le serveur. Ce dernier vérifiera l'authenticité du certificat client en fournissant des garanties solides que ce client est valide.

Le défi de ce processus repose en partie sur la gestion des certificats qui est plus laborieuse que leur utilisation proprement dite. La création d'un certificat est très procédurale, sujette à des erreurs qui entraînent des révocations et réémission. Cette technique est à envisager si la nature des données est très sensible ou si la maîtrise des données qui transitent sur le réseau est faible. Il est fréquent de rencontrer ce processus répandu dans des institutions bancaires.

- **Le code d'authentification d'une empreinte cryptographique de message avec clé**

En termes de sécurité, une meilleure alternative au HTTP serait le HTTPS, mais la gestion des certificats et du trafic HTTPS impose une charge supplémentaire aux serveurs. Une autre approche, largement utilisée par les API S3 d'Amazon pour AWS et dans certaines parties de la spécification OAuth, consiste à utiliser un code d'authentification d'une empreinte cryptographique de message avec clé, communément appelé **HMAC**, calculé en utilisant une fonction de hachage cryptographie combinée à une clé privée, pour signer une requête.

Avec le HMAC, le corps d'une requête ainsi qu'une clé privée sont hachées et le résultat du hachage est envoyée dans le corps de la requête. Le serveur utilise ensuite sa propre copie de clé privée et le corps de la requête pour recréer le hachage, si les deux HMACs correspondent, la requête est acceptée et traitée. L'avantage de ce processus c'est qu'il réduit considérablement les tentatives d'interception des données qui auront alors tendance à changer la signature des requêtes et le fait que la clé privée n'étant jamais envoyée dans la requête, elle n'est pas comprise en cours de route.

L'inconvénient de cette approche réside dans le partage de cette clé privée. Elle peut soit être mise en dure, soit gérée et envoyée par une tierce partie qui se doit d'être particulièrement sécurisé. De plus, la notion de HMAC n'est pas normée, donc tout le monde est libre d'implémenter les fonctions de hachage comme il le souhaite, cependant il vaut mieux partir sur une fonction sensible avec une clé suffisamment longue de type SHA-256. Cette approche n'est garantie que si la clé privée reste privée !

5.3. La sécurité entre les API

En raison du fait que la plupart des API sur les réseaux publiques sont accessibles à tous, elles sont vulnérables à diverses attaques pirates. La question de la sécurité est très cruciale dans le choix

d'une solution d'API management. S'agissant d'un enjeu majeur et critique, il convient donc de s'assurer qu'un ensemble de mesure de sécurité soit mis en place afin de protéger les données.

L'authentification d'une API via une clé

Une API est identifiée par son nom et par un **UUID** unique appelé clé d'application ou clé d'API ou encore ID client. Elle est émise par l'entreprise qui expose l'API ainsi que d'autres informations concernant les accès. Une plateforme d'API management devrait être en mesure de créer, d'émettre, gérer, suivre et révoquer l'UUID. Il devrait donc être impossible de franchir le premier pallier de sécurité s'il manque dans les appels de services, l'UUID de l'API à laquelle on souhaite accéder.

Certains services d'authentification peuvent également nécessiter une intégration avec des systèmes de gestion des identités qui contrôlent l'accès des utilisateurs aux API. Il est possible de générer manuellement des UUID, directement à l'accueil du site <https://www.uuidgenerator.net/>. Le site propose aussi plusieurs services au travers d'une API permettant de générer de UUID de diverse catégorie : <https://www.uuidgenerator.net/api>.

L'autorisation à l'aide d'un token

L'autorisation contrôle le niveau d'accès fourni à une application effectuant un appel API. Il contrôle les ressources et les méthodes de l'API qu'une application peut appeler. Lorsqu'une application effectue un appel API, elle transmet normalement un jeton d'accès OAuth (Tokens cf. le point 6.1. openID Connect) dans les en-têtes HTTP. Ce jeton de sécurité permet de définir la portée d'accessibilité des API (limite à une ou plusieurs API ou webservices) durant une période bien définie pouvant aller de plusieurs secondes, minutes, jours ou mois.

Si le jeton a expiré, un nouveau jeton d'accès doit être généré. Une solution d'API management peut le faire automatiquement en présentant un jeton d'actualisation (le '*refresh Token*'). Le jeton d'actualisation devra être échangé pour obtenir un nouveau jeton d'accès avec une nouvelle période de validité.

La médiation d'identité (TODO A RETRAVAILLER)

Les API utilisent généralement les protocoles OAuth (plus spécifiquement OAuth2) pour implémenter la sécurité. Toutefois, les services principaux peuvent être sécurisés à l'aide de SAML ou de tout autre entête WS-Security. Par conséquent, la plate-forme de gestion d'API doit pouvoir s'intégrer aux plates-formes IDM backend et faire la médiation d'identité. '*OAuth to SAML*' est une exigence de médiation d'identité très courante.

5.4. Quelques menaces à considérer

- ✚ Une attaque très courante sur les API est le **DoS** (Deny-of-Service) : Les attaques par déni de service consistent à faire tomber des systèmes back-end en augmentant significativement le trafic via les API. Par conséquent la solution d'API management devrait être capable de détecter cette anomalie et prendre les mesures nécessaires.

- ✚ Une faille privilégiée par les pirates est le contenu des données : Les attaques basées sur le contenu peuvent prendre la forme de XML ou JSON mal formés, de scripts malveillants ou de SQL dans les données utiles. Bien qu'étant une attaque fréquente sur les API publiques, elle peut également se produire sur des API privées et d'entreprise. La plate-forme d'API management doit être capable d'identifier les formats de requêtes mal formés ou les valeurs malveillantes dans le contenu des données, puis de se protéger contre de telles attaques.

6. Déploiement

Après un travail de conception fonctionnel à l'aide des techniques de conception DDD et d'identification des processus d'intercommunications permettant d'intégrer les services les uns aux autres, il est donc nécessaire de définir une stratégie de déploiement.

En ce qui concerne ce dernier, l'intérêt des microservices se porte sur la capacité à déployer les services individuellement et fréquemment en minimisant l'interruption complète d'une l'application. L'automatisation du processus de déploiement est essentielle et vivement recommandée dès le début, même si l'architecture est composée de très peu de services.

Afin de conserver l'indépendance de chaque équipe, il est nécessaire que ces dernières aient leur propre chaîne de production. Cela passe par la mise en place d'une chaîne d'intégration continue et des mécanismes de livraison continue vers des environnements dédiés afin de gérer les livraisons fréquentes.

Le besoin d'automatisation du déploiement remonte à l'ère des applications monolithique, ce qui fait qu'à ce jour, le marché regorge de multiples solutions permettant d'implémenter ce processus. En admettant que la plupart des tests aient été couverts voyons plus en détail l'intérêt qu'il y aurait à faire du CI/CD dans une application de microservices ainsi que les stratégies de déploiement possible.

6.1. L'intégration continue

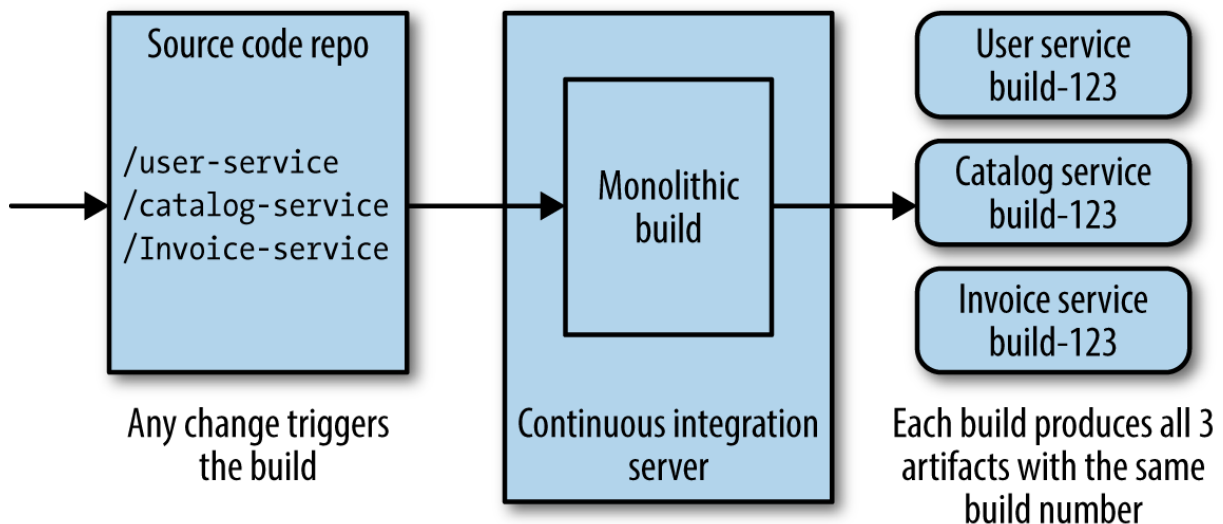
Couramment, dans une application en monolithe, l'intégration continue consiste à exécuter tous les tests de l'application globale. Bien qu'on serait tenté de procéder de la même sorte pour une application découpée en microservices à son début d'implémentation (car très peu de services) afin de garantir que l'approche en microservices ne dégrade pas l'application, il faudrait cependant tenir compte du fait qu'il serait plus intéressant de tirer parti du découpage en microservices.

En effet, des microservices bien définis fonctionnellement apportent une certaine flexibilité en matière d'intégration continue. Cela permet de créer une chaîne d'intégration par microservice, afin de permettre d'effectuer et de valider rapidement un changement. Chaque microservice devrait avoir son propre référentiel de code source et déployer un seul artefact.

L'alignement sur la propriété de l'équipe est également plus clair, si cette dernière prend en charge un microservice, elle devrait posséder un référentiel de construction, être capable d'effectuer des modifications sur ces référentiels.

Analysons l'intégration continue dans les situations de build unique et de build par microservices :

- **Build de l'application en microservices**



Source : « *Building Microservices* » Sam Newman, Figure 6.1

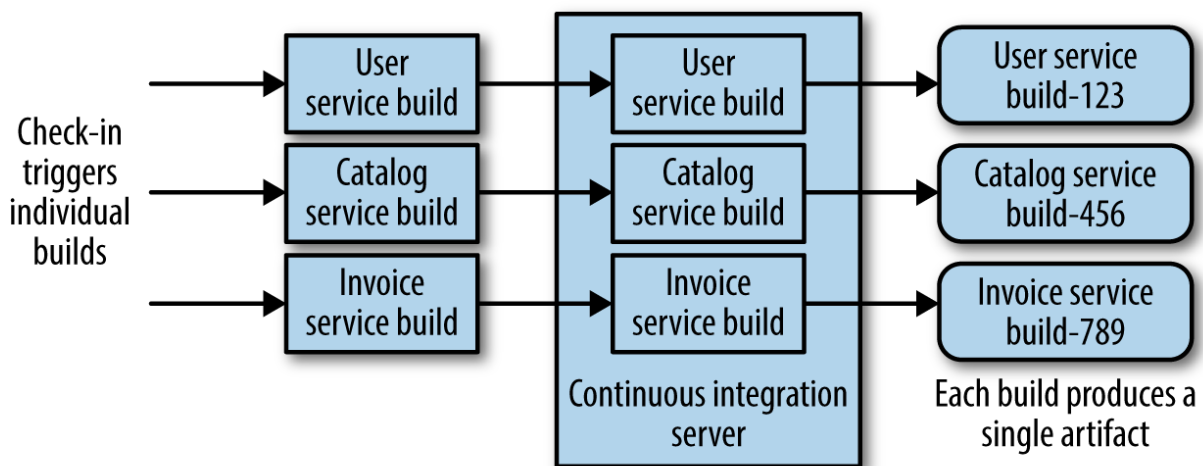
Présentation de l'utilisation d'un référentiel de code source unique et d'une génération de CI pour tous les microservices.

Cette approche consiste à builder l'application entière et de générer les différents artefacts des microservices après chaque commit. Il faut noter que chaque artefact aura un même numéro de version. Cette information est particulièrement biaisée, car le numéro de version sur un artefact n'indique pas forcément qu'il y ait eu des modifications sur ce dernier.

L'avantage de cette approche est sa facilité de mise en œuvre dans la mesure où il ne suffira que d'installer une usine de build qui prendra en charge tous les services.

Cependant, si le nombre de services et de développeurs venait à s'accroître, on pourrait être confronté à des problèmes de gestion et de latence de l'usine suite à un nombre fréquents de commit.

- **Build par microservices**



Source : « Building Microservices » Sam Newman, Figure 6.3

Présentation de l'utilisation d'un référentiel de code source et de la création d'un CI par microservice

Ici comme on peut le comprendre il s'agit d'implémenter **une usine de build par microservice** et non pour toute l'application. Cela rendrait les microservices indépendants les uns des autres en ce qui concerne leur livraison.

Cette approche est plus complexe à mettre en œuvre cependant elle présente certains avantages non négligeables en termes de finesse :

- Les tests sont exécutés de façon plus ciblée.
- Le fait de déployer un service à la fois et indépendamment des autres, qui ici est une caractéristique essentielle de cette architecture est ce qui permet de gagner du temps et de la disponibilité.
- Sachant qu'un microservice correspond à une équipe, cela responsabilise d'avantage cette dernière.

Cette approche est efficace quand les contextes fonctionnels sont clairement définis et stables. Bien qu'elle nécessite plus de travail fonctionnel et technique, elle répond bien à une stratégie basée sur la **performance** et le **time-to-market** et par-dessus tout à l'intérêt de mettre en œuvre cette architecture

6.2. La livraison continue

La livraison continue (**CD : Continuous Delivery**) est l'approche permettant d'obtenir un retour constant sur l'état de production de chaque enregistrement comme candidat à la publication sur un environnement donné. Elle s'appuie sur le concept de mise en place des **pipelines** qui sont des découpages de build en plusieurs étapes et regroupant des exécutions de tests sur certains critères (rapides, de petite taille, lent, de grande taille). Ce système va du constat qu'un cas très commun comme celui des tests peut ralentir un déploiement s'ils sont tous exécutés en même temps.

La procédure consiste à modéliser tous les processus nécessaires pour faire passer les sources logicielles de l'enregistrement à la production et savoir où une version donnée du logiciel est en cours de validation. En livraison continue cela se fait en implémentant des pipelines de build à plusieurs étapes de façon très automatisée.

Focus sur les pipelines

Un pipeline de déploiement en livraison continue est un circuit configurable que parcourra les changements apportés au code à partir du commit jusqu'à la mise en production.

L'objectif de cette méthode est de gagner en performance sur la livraison des services en **ciblant les tests qui vont être (ou pas) exécutés de façon continue**. En effet, certains tests qui impliquent plusieurs services ou qui sont basés sur des **workflows complexes** peuvent être long à exécuter. Afin qu'un build ne soit pas pénalisé par ces derniers, il faudrait construire des pipelines de déploiement entre les tests s'exécutant rapidement pour un feedback rapide et ceux qui sont long et spécifiques.

Sur une application donnée, on peut configurer au minimum les 2 types de pipelines suivants :

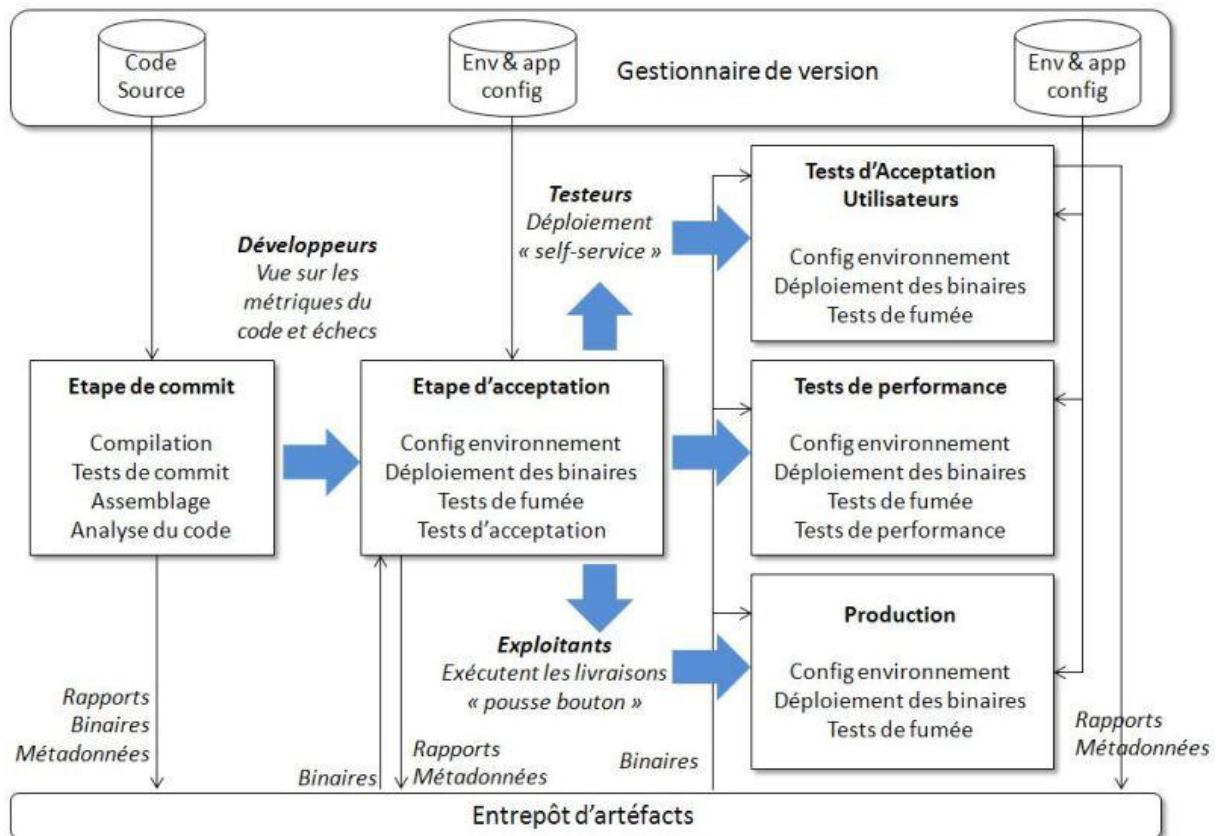
Pipeline 1 : Build de tests rapides

- Les tests sont exécutés à chaque commit
- Le feedback d'exécution des tests sont considérés et prise en charge à l'instant

Pipeline 2 : Build de tests longs

- Les tests ne sont pas exécutés après chaque commit
- Les tests sont exécutés à un moment différé

On pourrait aussi envisager de créer une tâche dédiée à leur exécution et la prise en charge de leur feedback.



Source : « Continuous Delivery » de Jez Humble et David Farley


Dans cette présentation Jez Humble et David Farley qui ont publié d'importants travaux sur la culture DevOps et l'intégration continue/livraison continue proposent un modèle pour montrer comment placer stratégiquement les pipelines dans la chaîne afin d'obtenir des informations sur la visibilité, avoir du feedback et où intervenir en cas d'erreur

6.3. Les stratégies de déploiement

Il existe sur le marché, plusieurs outils permettant de mettre en place une stratégie de déploiement efficace. Pour une architecture de microservices, la stratégie pour gérer un grand nombre d'hôtes consistera à trouver des moyens de diviser des machines physiques en machines plus petites. En allant du principe que nous allons déployer une instance de service par hôte, on peut déjà dire que la virtualisation traditionnelle telle que VMWare ou virtualisation moderne telle que celle proposée par AWS a apporté d'énormes avantages en réduisant les coûts de gestion de hôtes. Cependant de nouveaux progrès dans cet espace, tel que les conteneurs Linux méritent d'être explorés, car ils ouvrent des possibilités encore plus intéressantes pour traiter les architectures de microservices.

La virtualisation

Dans une stratégie consistant à déployer un microservice à l'aide de la virtualisation, chaque service devra être empaqueté en tant qu'**image VM** et chaque instance de ce service sera exécuté dans une machine virtuelle lancée à l'aide de cette image VM :



Ce procédé a été largement popularisé par AWS avec la solution **Amazon Elastic Compute Cloud (EC2)**, qui permet de créer une VM image appelée EC2 AMI et la plateforme AWS créera des instances EC2 sur le cloud conformément aux besoins de l'application. Plusieurs compagnies telles que **Boxfuse** ou encore **CloudNative** proposent des solutions permettant de créer des image EC2 et des solutions de packaging de services ou autres projets vers EC2 telles que **Aminator** et **Packer** sont de plus en plus répandues.

Un l'avantage du déploiement par VM est que chaque instance est encapsulée (peu importe la technologie) et exécutée de manière isolée (les valeurs de CPU et de mémoire sont fixes et l'instance de service ne peut pas voler des ressources aux autres). Mais un autre avantage à apprécier c'est la capacité à exploiter des infrastructures cloud très mature comme AWS, qui fournit un large éventail de services prêt à l'emploi tel que le loadbalancing ou encore l'autoscaling, déploiement est simple et fiable.


Toutefois, l'inconvénient de cette approche est que l'utilisation des ressources n'est pas tout à fait optimisée, en effet chaque instance de service est surchargée par le système d'exploitation de la VM, ce qui pourrait impacter son démarrage. De plus, les IaaS facturent les VM de tailles fixes, qu'elles soient occupées ou non, ainsi il est plutôt fréquent d'avoir des VM sous-utilisées engendrant des coûts de déploiement élevés. Autre constat, les déploiements des nouvelles versions de services sont lents du fait de la lourdeur des images VM et du démarrage de leur système d'exploitation. Mais il y'a une forte tendance dans la recherche pour alléger ce processus.

[La conteneurisation](#)

Les conteneurs sont le plus souvent présentés par opposition aux systèmes de virtualisation standards afin de démontrer tous les bénéfices que ceux-ci peuvent apporter en termes de rapidité et de limitation des coûts. Car contrairement à une VM qui exécute une copie complète d'un système d'exploitation et une copie virtuelle de tout le hardware dont le système a besoin pour fonctionner

(ce qui augmente le nombre de cycles de RAM et CPU qui entraîne les problèmes de latence évoqués dans le point précédent), un conteneur utilise un système d'exploitation, des programmes, des bibliothèques compatibles et des ressources système pour virtualiser des composants.

Dans cette stratégie de déploiement, chaque service devrait être empaqueté en tant qu'image de conteneur avec les applications et fichiers nécessaires pour exécuter le service. Habituellement un conteneur utilise le minimum pour exécuter un service, la taille d'une image de conteneur est beaucoup plus limitée que celle d'une image de VM, il devient alors possible de créer plusieurs conteneurs en provenance de cette image sur un hôte (physique ou virtuel) :



La solution de conteneurisation la plus populaire reste **Docker** suivi de près par **Solaris**.

Habituellement plusieurs conteneurs peuvent être déployés sur un hôte, il faudrait donc utiliser un gestionnaire de cluster tel que **Kubernetes** ou **Marathon** pour gérer les conteneurs. Celui sera en charge de décider où placer les conteneurs en fonction des ressources requises par ces derniers et celles disponibles sur les hôtes.

Les bénéfices des conteneurs sont quelque peu similaires à ceux des VM, notamment en ce qui concerne la problématique d'isolation des services les uns des autres. Il est plus facile de surveiller les ressources consommées par chaque conteneur. Les conteneurs encapsulent aussi la technologie utilisée pour mettre en œuvre un service. Cependant leur technologie est beaucoup plus légère et les images de conteneur sont beaucoup plus rapide à construire. Cet avantage est particulièrement apprécié quand on doit mettre à jour les services de façon régulière.

Cependant, il a été reproché aux technologies de conteneurisation, bien qu'étant en plein essor, de manquer de maturité et par conséquent de **sécurité**, notamment du fait que plusieurs conteneurs partagent le noyau d'un même système d'exploitation (point of failure). Il faut aussi noter que les

conteneurs ont tendance à bloquer les ressources serveur qui leur sont allouées et cela peut également impacter des coûts d'exploitation. Un autre inconvénient vient aussi de la responsabilité à administrer soi-même les conteneurs si l'on décide de ne pas s'orienter vers des solutions de conteneurs hébergés comme **Google Container Engine** ou encore Amazon **EC2 Container Service**, ce qui peut s'avérer fastidieux à grande échelle.

Le Serverless

Le Serverless est une architecture sans serveur regroupant les principes de type BaaS et FaaS (Backend as a Service et Function as a Service). L'idée est d'héberger le code sur une architecture qu'on offre comme un service, par conséquent qu'il n'est pas nécessaire de maîtriser. On accède à une console de la solution où on téléverse le code zippé, on ajoute quelque metadata (nom du service, langage et version utilisée, etc.). Le code est ensuite exécuté, se connecte aux différents services dont il a besoin (API, base de données, bucket de fichiers statiques, etc.) et se déploie automatiquement :



Le principe du Serverless est d'externaliser complètement le déploiement et de ne payer que la consommation des services (bande passante et espace de stockage). Grâce à l'élasticité, les coûts d'exploitations sont optimisés et il n'est pas nécessaire de gérer l'infrastructure et sa disponibilité.

La solution la plus connue actuellement sur le marché est **AWS Lambda**. Les fonctions lambda qui encapsulent le code profitent de la force des solutions AWS pour fournir ce service. **Google** et **Azure** offrent aussi ce type de solution.

L'avantage certain est l'optimisation des coûts et des ressources, ce que l'on ne retrouvait pas systématiquement avec la virtualisation et la conteneurisation. Mais contrairement à ce que l'on pourrait penser, bien que tout soit externalisé et qu'il ne faille juste se concentrer sur l'écriture du code, la prise en main de ce type de solution nécessite un montage en compétence qui a un coût et une veille de la solution pour avoir connaissance des différentes mises à jour et nouveautés. Cela tient du fait qu'il s'agisse d'une nouvelle technologie, pas assez mature et que l'on pourrait considérer comme nouvelle étape dans la culture DevOps.

7. Le monitoring

Le monitoring reste un élément essentiel de la gestion des systèmes informatiques et les défis associés à la surveillance des microservices sont particulièrement uniques. Les applications basées sur une architecture de microservices ont des exigences de surveillances différentes et plus intensives que celles des applications traditionnelles de type monolithique. Cela tient du fait qu'une logique métier peut être répartie sur plusieurs services distincts, que ces services sont amenés à être distribués, répliqués et portés par le cloud.

Pourquoi monitorer les microservices ?

La première raison pour laquelle on surveille un système distribué c'est parce que tous les systèmes échouent. Une architecture de microservices est tolérante aux pannes, cela signifie qu'au sein du système, il existe des services en échec qui n'ont cependant pas d'effet de cascade sur tout le système. Il est donc important de connaître les raisons de ces échecs, d'apporter une analyse et de trouver une solution.

Une autre raison particulièrement importante découlant de la première est la performance du système. En effet, les données liées à la performance apportent des informations sur les états de dégradations du système. Si ces états ne sont pas pris en charge, il en résultera inévitablement des échecs. Surveiller la performance du système permet ainsi de prévenir l'échec de ce dernier.

Mais la raison pour laquelle on associe indubitablement la performance au monitoring, c'est que l'ensemble des services fournis (en interne ou à l'externe), le sont dans le cadre d'un contrat de niveau de service (SLA). Sans monitoring, il est impossible de savoir si le SLA est respecté ou violé et sans surveillance de la performance il est difficile d'anticiper les défaillances qui pourraient à terme faire perdre des contrats de services, voire pire, générer des attaques en justice. Le monitoring de la performance des applications (APM) constitue un marché à part entière, sur lequel on peut retrouver un panel intéressant d'outils open source et commerciaux, permettant de publier, rassembler et stocker des données de métriques :

Figure 1. Magic Quadrant for Application Performance Monitoring



Comment déterminer les métriques à monitorer dans une architecture de microservices ?

Les grands systèmes distribués traitent chaque jour d'un grand volume de données, générant ainsi des giga-octets de nouvelles métadonnées sur leur comportement. On distingue cependant quelques groupes de métriques :

- Les métriques d'application : elles sont spécifiques à l'application et permettent donc de remonter des informations liées au comportement de cette dernière. Exemple : le nombre d'utilisateurs connectés à l'application à un instant T ; les id de ceux qui commandés un produit X, le produit Y dont la vente génère 1000 transactions par heure et que dans l'heure qui suit le nombre de transactions chute à 100 (cela pourrait par exemple lever une alerte) etc.
- Les métriques de plateforme : elles sont spécifiques à l'état de l'infrastructure et sont généralement retransmises sur un tableau de bord analytique des performances dégradées susceptibles d'affecter la débit et/ou la défaillance du système. Exemple : le nombre de requêtes traitées par un service par minutes ; le taux de réussite / échec pour un service, une attaque DoS.
- Les métriques basées sur les événements externes aux systèmes : elles impliquent l'ensemble des informations à répertorier quand serait survenue une force externe agissant sur le système. Dans le cadre des microservices, il s'agit généralement des déploiements fréquents qui peuvent être de potentiel suspect en cas de

dysfonctionnement du système après que l'un d'entre eux n'ait été effectué. Le travail ici consistera plus à journaliser ces événements afin d'analyser des corrélations avec l'état du système. Exemple : déploiement après ajout de nouveau code, de correctifs de code, d'ajout de configuration.

Le type de métriques à monitorer sera donc en fonction de chacun de ces aspects et aidera aux choix des outils permettant d'implémenter cela.

Quelques solutions et outils de monitoring

Les technologies de monitoring se scindent habituellement en deux catégories :

- Les librairies : qui sont intégrées à une application au moment de son développement. Ces ressources peuvent être utilisées pour faire de la journalisation et améliorer les rapports de métriques
- Les plateformes : qui se concentrent sur la collecte et l'analyse des données d'applications et d'infrastructures.

Les solutions commerciales sont généralement un mix de ces deux catégories. On peut également trouver des solutions open-source qui pourraient entrer dans une stratégie de mise en place du monitoring :

Solutions	Type de métriques	commentaires
ELK (Elastic Search, Logstash , Kibana)	Application	Permet de parser des logs, les stocker sur un serveur, les indexer afin d'y effectuer de la recherche
Zipkin	Application, Infrastructure	Permet de tracer les appels entre microservices et de remonter des problèmes de latence
Grafana	Application, Infrastructure	Outil de visualisation web utilisé pour créer des tableaux de bord visuel quand il est connecté à une base de données de métriques
Prometheus	Infrastructure	Outil de surveillance des événements, qui enregistre les métriques en temps réel dans une base de données. Peut être utilisé avec Grafana et d'autres outils de visualisation
Azure Monitor	Infrastructure	Collecte analyse et affiche des données sur la santé des clusters.

Dynatrace	Application, Infrastructure, évènements	Solution commerciale complète permettant de remonter une grande variété d'informations sur tout le système, de façon automatique, avec des résultats d'analyse remonté par de l'Intelligence Artificielle. Numéro 1 mondial du monitoring
------------------	---	---

Pour ne citer que ceux-là.

En somme :

Les exigences de monitoring doivent être prises en compte dès le début du cycle de vie d'une application. La surveillance des systèmes nécessite des contributions du développement et des opérations. C'est une partie essentielle du support opérationnel de tout système distribué. Les architectures de microservices sont encore plus distribuées que les applications monolithiques typiques. Elles nécessitent plus d'attention en temps réel et une surveillance proactive.

Il est tout aussi important de collecter des données pertinentes que d'analyser les données collectées. Il devient nécessaire que les développeurs soient initiés à la culture DevOps car ces derniers sont au début de la chaîne et doivent implémenter des pratiques de capture de métriques directement dans le code des applications pour signaler les événements spécifiques à chaque application. Les équipes opérationnelles doivent collecter des données non seulement à partir d'applications, mais également des plates-formes et des systèmes de déploiement associés.

Des solutions open source et payantes sont disponibles pour prendre en charge à la fois la publication et le stockage des événements de surveillance. Ces données sont essentielles pour prendre en charge un système distribué résilient, fiable et disponible.

8. Transformer un monolithe en microservices

Bon nombre des organisations actuelles ont des systèmes bâtis sur une architecture monolithique. L'avantage certain de ces derniers est qu'ils génèrent des revenus pour les entreprises qui les possèdent. Mais à la longue ces systèmes sont de plus en plus coûteux :

- Les échecs des systèmes sont de plus en plus fréquents
- Les fonctionnalités tardent à être livrées
- Il est difficile d'inclure de nouvelles technologies qui pourraient s'avérer bénéfiques
- Le processus d'introduction de nouveaux employés prend de plus en plus de temps
- Les employés existants commencent à envisager un cheminement de carrière en dehors de l'organisation. Etc.

Ces symptômes, pour ne citer que ceux-là, indiquent que l'architecture du système a cessé de répondre aux exigences de la société. Il y a de plus en plus d'organisation qui ont lancés des

processus de « rénovation digitale » de leurs systèmes. Une importante question reste donc de savoir, comment migrer d'une application monolithique vers une application de microservices ?

Voici quelques éléments de réponse avec un approche « étapes par étapes »

Etape 1 : Bien définir les raisons qui poussent à la migration

La mise en œuvre d'une telle démarche constitue un défi important et nécessite des investissements conséquents. Il faut s'assurer que les démarches sont motivées et permettent de répondre positivement à la question de savoir s'il faille une architecture de microservices.

Quelques questions à se poser :

- Quels sont les objectifs, les priorités et les besoins de l'entreprise ?
- Est-ce que le système actuel est éprouvé sur le marché ?
- Y' a-t-il eu une évaluation de l'existant ?
- Les ressources compétentes existent -elles en interne ? Les collaborateurs sont -ils prêts ?
- Etc.

En général on pourrait 4 raisons principales pour lesquelles la migration devrait être amorcée :

- a- Une partie du système va opérer de grands changements (refactoring structurant, rénovation digitale, etc.)
- b- La structure de l'équipe change (multi office, multi régionale, internationale, etc.)
- c- Des problématiques de sécurité (échecs, attaques, pertes de données, etc.)
- d- L'obsolescence de la technologie en cours (désuète, non maintenue par les concepteurs, ressources compétentes de plus en plus rare, etc.)

Etape 2 : Définir la stratégie de conception en sous-domaines

Selon Martin Fowler, toutes les personnes qui ont commencé à développer des microservices dès le départ, ce sont heurté à des difficultés car ils n'ont pas su découper l'application aux bons endroits et ont engagés des refactoring massifs. Donc il serait plus simple de partir d'un monolithe vers une architecture de microservices car on est en mesure de savoir comment découper le système vu que l'on sait déjà où sont les problèmes, autrement dit les couplages.

Comme préconisé en début de ce document, une première stratégie serait d'implémenter des techniques de Domain-Driven-Design pour définir les différents contextes bornés, structurer les équipes et établir la carte des contextes.

Il serait aussi intéressant d'utiliser des Seams. Dans son livre « Working Effectively With Legacy Code », Michael Feathers, pionner et chef de file du mouvement Agile, définit le concept de Seams comme un « Morceau de Code pouvant être isolé et sur lequel on peut travailler sans impact sur le reste de la codebase ». En effet, dans une stratégie de migration, ces éléments sont très vite connus, et il s'avère que l'extraction des seams est une approche plutôt populaire, le but est donc d'identifier les seams qui pourraient devenir des microservices ou des APIs. Ce travail nécessite une collaboration entre l'équipe de développement qui a une vision limitée à son domaine de développement et l'équipe d'architecture qui a une vision un peu plus globale du système et qui validera que les seams sont bien des seams dans la mesure où leur extraction n'aura aucun impact

sur le reste du système. Le code restant nécessitera un travail de conception en sous-domaine en fonction du volume restant.



Etape 3 : Procéder par itérations

Qu'il s'agisse de construire une application en microservices correspondant à un monolithe en partant de zéro ou en démantelant graduellement le monolithe, il faut penser à procéder par itération à l'aide des techniques d'agilité.


Se donner des objectifs macro que sont les Milestones et les découper en objectifs micro que sont les Sprints et essayer de tenir la feuille de route.

Etape 4 : Stratégie de transformation graduelle


Admettons que la conception en sous domaine ait été préalablement effectuée et partons d'un exemple général pour illustrer la transformation : Soit une application monolithique classique qui roule dans un conteneur :



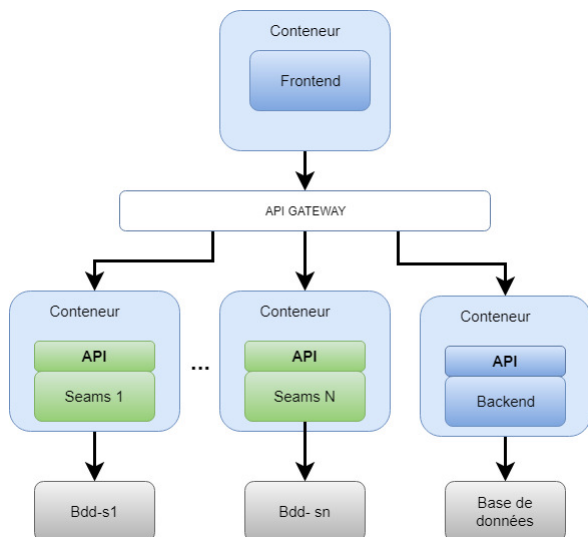
1- Séparer le Frontend du Backend de façon partielle : Le traitement des commandes de la logique applicative est délégué à la couche Service et les requêtes prenant en charge les vues sont dirigées vers la base de données. A ce stade aucune modification de la base de données ne doit être effectuée.



2- Séparer le Frontend et le Backend de façon logique : Mettre en place une couche Controller dans le Backend qui regroupera tous les points d'entrées dont a besoin de Frontend pour accéder à la base de données via des services.



3- Séparation physique du Frontend et du Backend : Créer une API pour le Backend et établir la communication du Frontend vers le Backend via l'API



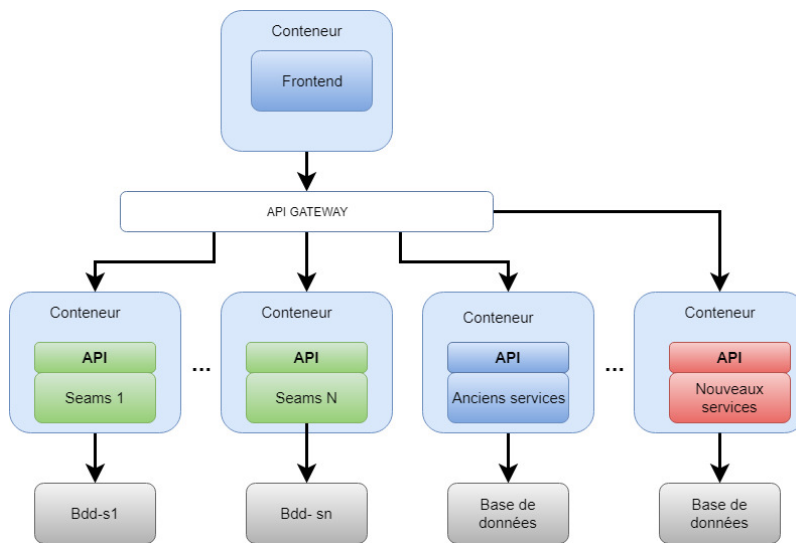
4- Extraction des seams dans le Backend : Créer des API pour tous les services ayant été identifié comme naturellement isolés et sans impacts et mettre en place l'API Gateway.

5- Pour le reste de l'application, implémentation du « Strangler Pattern »

Le Strangler Pattern est un modèle de conception populaire permettant de transformer progressivement une application monolithique en microservices en remplaçant une fonctionnalité particulière par un nouveau service. Quand la nouvelle fonctionnalité est prête, l'ancien composant est « étranglé », autrement dit hors service. Tout nouveau développement est effectué dans le cadre du nouveau service et surtout pas dans le monolithe, les deux fonctionnalités coexistent jusqu'à ce que le nouveau service réalise entièrement la tâche de l'ancien. Pour implémenter ce modèle, il faut itérer en 3 temps :



On devrait avoir la configuration ci-dessous en cours de migration :



En somme,

Une fois la migration terminée, il est utile de vérifier si les résultats attendus ont été obtenu en introduisant des procédés de monitoring (voir chapitre 7) afin de mesurer la performance, le temps moyen pour localiser et éliminer les défaillances, les temps de réponses etc. afin d'évaluer l'effet de la transformation. Le processus de migration d'un monolithe vers des microservices demande un investissement qui devrait apporter des 1ers résultats avant la fin du processus complet.

Conclusion générale (EN COURS)

Tout au long de ce document nous avons commencé par comprendre pourquoi les architectures cloud natives ont émergées durant la dernière décennie et en quoi elles constituent la signature d'une nouvelle ère digitale centrée autour des technologies du cloud. Due à un intérêt fort de la part des organisations traditionnelles à se tourner vers cette nouvelle architecture, il était nécessaire d'explorer les concepts de microservices et d'API qui sont au cœur de cette architecture.

En partant du principe qu'on serait en train de monter cette architecture de zéro, la première phase a consisté à mettre l'accent sur la nécessité à définir correctement le découpage fonctionnel du système à l'aide de techniques de Domain Driven Design. A la suite de quoi, nous avons vu quelques éléments essentiels pour permettre la communication entre les microservices, tel que les API RESTful, le choix du JSON comme format d'échange, l'importance d'une API Gateway dans une ère digital très axée Mobile-First, les notions de synchronisme et d'asynchronisme, et le Service - Discovery Pattern. A ce stade, on a constaté qu'une bonne pratique, si ce n'est la plus importante est de bien regrouper les microservices et d'utiliser une API comme interface de communication. Dans un souci de gouvernance, il était important d'introduire la notion d'API management afin de se doter des outils permettant de gérer efficacement un systèmes découpé s en APIs.

Afin de permettre une bonne compréhension des notions introduites jusque-là, une étude de cas d'une application mobile basée sur une architecture de microservices, a été proposée. On a pu voir conformément aux exigences fonctionnelles et non-fonctionnelles, comment concevoir le système en établissant une carte des contextes bornés (technique de DDD). Une architecture cible d'intégration (d'intercommunication) en interne et avec des systèmes externes a été proposée ainsi qu'un choix de technologies divers et varié permettant de montrer qu'il est tout à fait possible et recommandé de choisir pour l'implémentation d'une API, la technologie la plus à même de répondre au besoin fonctionnel. Nous avons également vu comment cette architecture a mutée avec la mise en place d'une brique d'API management, qui permet la gestion des API, l'APIsation (API economy) du système et l'imbrication avec des systèmes tiers. Un choix technologique succinct de solution d'API management pouvant convenir à tout type de budget a été soumis.

Une architecture cible de déploiement a été proposée afin de permettre la compréhension du fonctionnement d'une chaine d'intégration et de livraison continue. Un choix de technologies a été proposé, pour mettre la création d'une solution maison. Mais cette architecture, proposée à titre informatif a permis d'introduire les notions de d'intégration et de livraison continue, les stratégies de déploiement et solutions de CI/CD de plus en plus florissante sur le marché dans le chapitre 6.

Les données ayant une valeur économique et leur manipulation étant régie par un ensemble de règles strictes de non-divulgaration, un point sur lequel il a été important de mettre l'accent a été celui de la sécurité. Nous avons vu comment l'accès aux microservices devait être authentifié et autorisé, comment les communications entre microservices devaient être sécurisées, les restrictions d'accès aux APIs devaient être mise en place et comment implémenter la traçabilité des opérations.

Nous avons également abordé l'importance du monitoring des architectures basées sur les microservices, car bien qu'étant tolérantes aux pannes, il est important de récolter les informations sur les pannes survenues et les résoudre afin d'améliorer la performance du système sur les tous les aspects architecturaux (entreprise, logiciel et infrastructure). Une analyse de quelques solutions de monitoring disponible sur le marché a été proposée.

Après avoir consulté un document comme celui-ci, les organisations se demandent comment transformer leurs systèmes, qui sont en grande partie des monolithes, en architecture de microservices afin de pouvoir bénéficier de tout les avantages qu'apportent le cloud. Le dernier chapitre propose une stratégie en plusieurs étapes : déterminer les motivations de la migration,

utiliser les techniques de DDD, mais également les Seams (morceaux de code isolés dont l'extraction a un impact minime sur le système), procéder par itération à l'aide des techniques d'agilités et faire une transformation graduelle en introduisant Strangler Pattern (exemple à l'appui).

Ci-dessous, un tableau synthétique des notions introduites dans ce documents et les réponses apportées :

Notions	Questionnement	Éléments de réponses
Contexte	Pourquoi faire des applications cloud natives ?	<ul style="list-style-type: none"> • Solution apportée contre les difficultés rencontrées par les géants du Web. • Besoin de rapidité pour être market-ready • Besoin de sécurité • Nécessité d'une mise à l'échelle horizontale • Pour les applications centrées sur le mobile • Par souci d'innovation en utilisant les dernières technologies et en bénéficiant • Bénéficier de l'API Economy qui est un nouveau modèle économique basé sur la monétisation de l'accès aux ressources de son système.
Architectures de microservices		
Microservice, API, API Management	De quoi s'agit-il ?	<ul style="list-style-type: none"> • Microservice : service métier regroupant un ensemble de service technique de manipulation des ressources • API : Interface de programmation permettant d'accéder à un ou plusieurs microservices liés par une logique métier • API management : gestion de toutes les APIs constituant le système et de celles externes aux systèmes et qui apportent de la complétude au service fourni par le système.
Conception des microservices	Quelle est la recommandation pour une MSA ?	<ul style="list-style-type: none"> • Prendre connaissance des techniques de Domain-Driven-Design pour savoir comment découper un système • Insister sur les notions de contexte borné qui est un cadre

		<p>logique et limité dans lequel un modèle fonctionnel devra évoluer</p> <ul style="list-style-type: none"> • Etablir une carte des contextes afin de voir comment ces derniers communiquent les uns avec les autres pour donner le modèle global
Communication entre les microservices	Quelles sont les bonnes pratiques ?	<ul style="list-style-type: none"> • Garder les APIs « technology-agnostic » • Rendre les services simples pour les consommateurs • Masquer les détails d'implémentations • Préférer le HTTP comme protocole de communication • Faire des API RESTful (de niveau 3 avec le contrôle Hypermédia) • Préférer le JSON comme format d'échange • Utiliser systématiquement une API Gateway lors d'une approche Mobile-first • Déterminer les besoins de synchronisme et d'asynchronisme pour implémenter les solutions adéquates • Implémenter systématiquement le Service Discovery afin de retrouver les services quand ils seront distribués sur le Cloud.
API Management		
API publiques et privées	Quelle différence ?	<ul style="list-style-type: none"> • API publique: ouvertes à tous et conçues pour être accessibles par une large communauté de développeurs • API privées internes : utilisées et exposées à l'intérieur d'une organisation. • API privée partenaire : Elles peuvent être ouverte à un autre système dans le cadre d'une stratégie économique (B2B, API Economy)
Outil d'api management	Quels sont les services principaux ?	<ul style="list-style-type: none"> • L'API Gateway • Le service de routage : mappage d'URL, distribution de service, regroupement des connexions, loadbalancing, orchestration des services

		<ul style="list-style-type: none"> • Contrôle et gestion des version des APIs • Le Caching • La documentation • La gestion du trafic : fixation des quotas de consommation, amorçage des arrêts rapides, limitations des utilisations • Les métriques sur : le trafic, la popularité, • Le portail de développeur : enregistrement et connexion des utilisateurs, console pour tester l'API, enregistrement des applications et gestion des tokens
Etude de cas		
Application COMOVE	Que va-t-on y voir	<p>Un exemple de cas pratique de mise en place d'une architecture de microservices sur une application axée mobile-first et portable par le cloud</p> <ul style="list-style-type: none"> • Conception DDD • Architecture cible d'intégration • Architecture incluant la mise en place d'une brique d'API management • Architecture cible de déploiement maison (Bonus)
La sécurité		
Authentification et l'autorisation	Quelles sont les connaissances à maîtriser ?	<ul style="list-style-type: none"> - OAuth2 - l'OpenID Connect (OIDC) -HTTPS
La sécurité entre les microservices	Quelles sont les connaissances à maîtriser ?	<ul style="list-style-type: none"> • L'authentification HTTPS basique • Les certificats clients (TLS) • Le code d'authentification d'une empreinte cryptographique de message avec clé (HMAC)
La sécurité entre les APIs	Quelles sont les connaissances à maîtriser ?	<ul style="list-style-type: none"> • L'authentification d'une API via une clé : UUID • L'autorisation à l'aide d'un token • La médiation d'identité.
Les menaces	Sur quoi faut-il être vigilant	<ul style="list-style-type: none"> • Le DoS (Deny-of-Service) • Les attaques basées sur e contenu
Déploiement		
	Que retenir ?	<ul style="list-style-type: none"> • L'intégration continue : 1 build par microservices • La livraison continue : Faire des pipelines pour gagner en performances • Les stratégies de déploiements :

		la virtualisation (AWS), La conteneurisation (Docker), le ServerLess(AWS, Google,Azure)
Le Monitoring		
	Pourquoi monitorer une architecture de microservices ?	<ul style="list-style-type: none"> • Pour détecter les pannes, les analyser et apporter des solutions • Pour améliorer les performances du système. • Pour augmenter la qualité d'un contrat de niveau de service (SLA)
	Quelles métriques doit-on surveiller ?	<ul style="list-style-type: none"> • Les métriques d'applications • Les métriques de plateformes • Les métriques basées sur les événements externes au systèmes
Transformation digitale		
Transformer un monolithe en microservices	Comment procède t'on ?	<ul style="list-style-type: none"> • Bien définir les raisons qui poussent à la migration • Définir la stratégie de conception en sous-domaines : contextes bornées, seams et carte de contextes • Procéder par itérations • Utiliser une stratégie de transformation graduelle via le Strangler Pattern

Au final...

Il y'a plus d'une décennie, on présentait les architectures SOA comme une solution intrinsèque pour mettre fin à la principale problématique rencontrée sur les solutions en monolithe qui était la capacité à intégrer entre elles, des applications hétérogènes, les rendant ainsi, plus flexibles, adaptables et agiles. Cependant, c'était sans compter sur les plateformes d'ESB complexes qui devaient effectuer le transcodage des données et leurs orchestrations et qui étaient le point central de ces nouvelles architectures. La déception des grandes entreprises réside dans le fait que non seulement ces plateformes étaient couteuses et de plus étaient le point des faiblesses de leur architecture. En effet, le moindre problème survenu sur cet élément avait un impact immédiat sur l'architecture et par conséquent sur le métier de l'entreprise. L'idée d'avoir une deuxième ESB comme solution de bascule en cas de problème semblait être la solution la plus appropriée.

Au même moment, les géants du Web (Google, Facebook, Amazon...) ont bâti des systèmes d'informations d'une incroyable performance, en gérant des volumes de données et de requêtes gigantesques, avec des règles métiers simples tout en se basant sur des architectures de services à taille réduite dont l'implémentation était inspirée sur quelques concepts seulement des architectures SOA. L'architecture de microservices avait fait ses preuves.

L'architecture des microservices ne s'oppose pas à la SOA, puisque qu'elle en est l'implémentation à un niveau de criticité plus fin et avec certaines normes qui ne nécessite pas forcément la présence d'un élément central pour rendre les applications autonomes. Si la SOA demeure une technique d'urbanisation du SI et de ses applications, une approche basée sur les microservices remet en cause l'architecture au sein même des applications en réduisant leur base de code, en découplant au maximum les éléments de différents domaines fonctionnels et en normalisant les échanges de données à un seul format de données (JSON) et en communiquant via un seul protocole (HTTP). Cette séparation des responsabilités permet à un système d'améliorer sa résilience globale, de le décomplexifier et de le faire évoluer tant sur le plan technique que technologique (capacité à innover).

La mise en place d'une architecture de microservices, nécessite une organisation et une structuration des échanges de données entre les services ainsi qu'une harmonisation en termes de sécurité et des informations de l'ensemble d'entre eux. Cette gestion induit de disposer d'une vue macroscopique sur les microservices. C'est pour cette raison que le concept d'interface d'entrée/sortie qui permet d'accéder aux différentes ressources via les microservices est si précieux. En effet, les API permettent de consommer de la donnée des microservices sans exposer la complexité de leur implémentation et également à ces derniers d'échanger des données entre eux.

Dans un processus de croissance et de gouvernance, la brique d'API management permet de référencer différentes API en les gérant de façon centralisée via des fonction d'authentification, de métriques, de contrôle d'usage (throttling), de documentation, de transformations de données, d'orchestration et de sécurité. L'API management permet d'implémenter une stratégie de transformation digitale en gérant le cycle de vie des API qui regroupent chacune des groupes d'un ou plusieurs microservices.

Bien qu'une approche en microservices consiste à éviter les risques d'avoir des systèmes trop complexes et trop couplés afin de garder le contrôle de l'architecture, il n'en demeure pas moins que son implémentation nécessite une certaine rigueur, un environnement adapté et un respect des normes et bonnes pratiques afin de ne pas accumuler les inconvénients. Le choix d'une solution d'API mangement ne doit pas se faire de façon précipitée ni anodine afin d'éviter une dépendance avec le fournisseur de solution. Dans tous les cas, il faut se poser les questions de savoir si la mise en place d'une architecture de microservices :

- Permet de résoudre les problèmes qui surviennent dans le système d'information
- Est en accord avec la stratégie de l'entreprise
- Est possible avec les conditions existantes
- Est adaptable aux besoins (présents et futurs) de l'entreprise
- Peut avoir des impacts mesurables sur le système d'information

Une fois décidé une architecture de microservices peut être une bonne solution à implémenter surtout s'il s'agit d'éviter des systèmes complexes et de garantir la flexibilité à l'innovation.

BIBLIOGRAPHIE

TODO Ranger par ordre alphabetique ou par categorie(livres, cours, blogs, chaine youtube)

- ✚ SOA, microservices & API management : le guide de l'architecte des SI agiles, Morel Fournier. Dunod
- ✚ API management: An architect's guide to developping and managing APIs for your organization, DE Brajesh. Apress
- ✚ Restful API Design: Best practices in API design with REST, Mathias Biehl.
- ✚ Enterprise API management, Luis Augusto Weir.
- ✚ REST API Design Rukebook: Designing consistent RESTful web service Interfaces, Mark Masse. O'REILLY
- ✚ API development: A practicalguide for business implementation success, Sascha Preibisch.
- ✚ OAuth 2.0: Getting started in API security, Mathias Biehl.
- ✚ Amazon webservises for dummies, Bernard Golden.
- ✚ Microservice architerture: alignin principles, practices and culture, Nadareishvili Irakli. O'reilly
- ✚ APIs are different than intégration, Ed Anuff. Apigee.
- ✚ APIs for dummies – Sharif Nijim, Brian Pagano. Apigee Special Edition.
- ✚ Microservices Reference Acrhitecture, Chris Stetson. NGINX. O'reilly Media
- ✚ 0000, RV Rajesh. Packt Publishing
- ✚ Buliding Microservices, Samuel Newman. O'REsilly Media
- ✚ Spring: Microservices with Spring Boot, Rao Ranga Karanam. Packt Publishing
- ✚ Developping microservices with Node.js, David Gonzalez. Packt Publishing

- ✚ Docker : Déploiement des microservices sous Linux ou windows, Jean-Philippe Gouigoux.
Edition ENI
- ✚ RESTful Web APIs: Services for a changing worl, Leonard Richardson, Mike Amunden & Sam Ruby. O'REILLY

- ✚ Construisez des microservices - cours Openclassroom
- ✚ Utilisez des API REST dans vos projets web - cours Openclassroom
- ✚ Optimisez votre architecture microservices - cours Openclassroom
- ✚ Google Maps Javascript API V3 – cours OpenClassroom
- ✚ Utiliser l'API MySQL dans vos programmes – cours OpenClassroom
- ✚ Developpez des applications web avec Angular 5.x – cours OpenClassroom
- ✚ Apprendre Node.js & créer une API REST de A a Z – cours Udemy
- ✚ Les web Components par la pratique – cours Udemy
- ✚ Learn to Develop for Cloud with Pivotal Cloud Foundry

LISTE DES FIGURES